

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/311843554>

车辆多目标协调式自适应巡航控制【博士】

Thesis · July 2009

CITATIONS

0

READS

1,697

1 author:



Shengbo Eben Li

Tsinghua University

305 PUBLICATIONS 11,796 CITATIONS

SEE PROFILE

Some of the authors of this publication are also working on these related projects:



Optimization-based deployment and environmental object perception of networked low-cost sensors for automated driving [View project](#)



Distributed Periodic Control of Fuel Economy Oriented Automated Vehicle Platoon [View project](#)

车辆多目标协调式 自适应巡航控制

(申请清华大学工学博士学位论文)

培 养 单 位： 汽车工程系

学 科： 机械工程

研 究 生： 李 升 波

指 导 教 师： 李 克 强 教 授

二〇〇九年七月

车辆多目标协调式自适应巡航控制

李升波

Vehicular Multi-Objective Coordinated Adaptive Cruise Control

Dissertation Submitted to

Tsinghua University

in partial fulfillment of the requirement

for the degree of

Doctor of Engineering

by

Li Shengbo

(Mechanical Engineering)

Dissertation Supervisor: Professor Li Keqiang

July, 2009

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：（1）已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；（2）为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容；（3）根据《中华人民共和国学位条例暂行实施办法》，向国家图书馆报送可以公开的学位论文。

本人保证遵守上述规定。

（保密的论文在解密后遵守此规定）

作者签名： _____

导师签名： _____

日 期： _____

日 期： _____

摘 要

新一代自适应巡航控制 (ACC, Adaptive Cruise Control) 系统中, 同时具备自动跟车行驶、低燃油消耗和符合驾驶员特性三类功能对于全面提升行车安全性、改善燃油经济性、减轻驾驶员疲劳具有重要的意义。但是已有研究多面向单一功能的实现, 忽略了三者之间的制约关系, 且未考虑驾驶员行为的非线性, 这导致现有的线性最优控制方法难以解决三类功能的矛盾。针对此问题, 本文首次提出并建立了一种车辆多目标协调式自适应巡航控制系统。论文在定义新一代 ACC 控制目标的基础上, 应用模型预测控制理论建立系统的控制结构, 依次解决驾驶员特性建模、性能指标设计和实用化问题处理等关键技术, 并通过实车实验验证系统性能。

首先, 为满足控制系统融合驾驶员特性的需求, 分析驾驶员对跟踪误差的敏感度特性, 建立具有准线性结构的驾驶员跟驰模型; 同时提出基于假设检验理论的模型比较验证方法, 消除实验过程中驾驶随机性对模型评价的影响。其次, 利用逆模型法补偿车辆纵向非线性, 结合车间动力学模型建立跟车系统的离散状态空间方程; 以二次型代价函数和线性不等式为框架, 设计跟踪性能目标、燃油经济性目标和驾驶员感受目标的数学量化方法, 建立 ACC 控制系统的预测优化问题, 实现最优控制算法的综合。然后, 为实现该算法的实车应用, 基于反馈校正法设计跟车预测模型, 增强闭环系统对模型失配的鲁棒性; 采用约束管理法松弛跟车系统的输入输出硬约束, 扩展最优控制量的可行域; 综合变量集结策略和约束集压缩策略, 提出预测优化问题的规模缩减框架, 提高在线优化的计算效率。

最后, 为了验证本文系统的有效性, 利用四类前车特定工况和两组前车循环工况, 进行试验场实车实验, 并与基于 LQ 方法的 ACC 控制系统进行对比。实验结果表明, 本文开发的多目标协调式自适应巡航控制系统, 在保障必要跟踪性能的前提下可有效降低车辆油耗, 且符合期望车距、动态跟车和乘坐舒适性等多类驾驶员特性。

关键词: 驾驶辅助系统; 自适应巡航控制; 多目标协调; 模型预测控制

Abstract

In next generation Adaptive Cruise Control (ACC) systems, further enhancing vehicle safety, improving fuel economy and reducing drivers' workload requires a comprehensive functions, e.g. necessary tracking capability, low fuel consumption and good driver desired response. Most current researchers, however, focus only on the partial function and neglect the contradiction of the three functions. Together with the neglect of nonlinearities in driver behaviors, linear optimal control methods can hardly achieve satisfactory adaptive cruise control performances. To address those issues, a Multi-Objective Coordinated Adaptive Cruise Control (MOCACC) system is firstly proposed and developed in my doctoral research. After defining its control objectives, this thesis establishes the control architecture of MOCACC based on Model Predictive Control (MPC) theory, and solve such key technologies as modeling of driver behaviors, design of performance indices, and processing of practical problems.

For the purpose of merging driver characteristics into ACC algorithm, driver's sensitivity to tracking errors is analyzed and consequently a driver car-following model with quasi-linear structure is constructed. Its precision and applicability are verified by the proposed comparative evaluating method based on the hypothesis testing theory in order to eliminate the influence resulting from driver randomness. After compensating vehicle longitudinal dynamics using the inverse model linearization method, a time-discrete state space model is built for the vehicular following system by combining inter-vehicle longitudinal dynamics together. Following the mathematicization of the tracking capability objective, fuel economy objective and driver feelings objective, the corresponding predictive optimization problem with quadratic cost functions and linear constraints is derived and then its optimal open loop sequence is numerically solved. To realize its application on vehicles, three practical problems of MPC theory are analyzed and processed. A predictive vehicular following model is designed by using the feedback correction

method, improving the robustness of the closed loop system to the model uncertainties. The constraint management method is employed to soften the hard I/O constraints of the predictive optimization problem, extending the feasible range of the optimal control law. Combined variable aggregation strategy and constraint set compression strategy, a scale reduction framework of the predictive optimization problem is proposed, thus decreasing the on-line computing complexity of the MPC algorithm.

The vehicular MOCACC system's performances are investigated by field tests under four specified speed profiles and two driving cycles of the preceding vehicle. It is concluded that compared with LQ control system, the proposed MOCACC system can not only reduce effectively vehicular fuel consumption on the premise of maintaining necessary tracking capability, but also enable the adaptive cruise process to accord with such driver characteristics as desired clearance feature, longitudinal ride comfort, dynamic car-following feature etc.

Key words: Driving assistance system; Adaptive cruise control; Multiple objectives; Model predictive control

目 录

第 1 章 引 言	1
1.1 概述	1
1.2 车辆 ACC 系统的发展动态	3
1.2.1 考虑燃油经济性问题的 ACC	3
1.2.2 考虑驾驶员感受问题的 ACC	5
1.3 模型预测控制方法	8
1.3.1 MPC 在车辆控制领域的应用现状	10
1.3.2 MPC 理论实用化技术的研究现状	13
1.4 本文研究内容	18
第 2 章 车辆新一代 ACC 系统的体系结构设计	20
2.1 新一代 ACC 系统的控制目标	20
2.2 多目标协调式自适应巡航控制方案	21
2.3 车辆 MOCACC 方案的关键技术	22
第 3 章 驾驶员跟车特性的分析与非线性建模	25
3.1 驾驶员特性实验及其有效数据集选取	25
3.1.1 驾驶员特性道路实验介绍	25
3.1.2 离线平均滤波器的设计	27
3.1.3 跟车工况的有效数据集选取	28
3.2 驾驶员跟车特性的建模和参数辨识	30
3.2.1 驾驶员期望车距特性的分析与建模	30
3.2.2 驾驶员对跟踪误差的敏感度分析	32
3.2.3 基于驾驶敏感度的跟驰模型结构	37
3.2.4 驾驶员跟驰模型的参数辨识	38
3.3 基于假设检验理论的跟驰模型比较验证	42
3.3.1 模型误差的均值与方差分析	43
3.3.2 基于 F-P 法的模型误差分布特性分析	44
3.3.3 基于 t 检验法的模型误差均值比较	47

3.3.4 基于 F 检验法的模型误差方差比较	49
3.4 驾驶员期望跟踪误差特性的分析与建模	51
3.4.1 期望跟踪误差特性的一维分布模型	51
3.4.2 期望跟踪误差特性的二维分布模型	55
3.4.3 两类分布模型的对比	58
3.5 本章小结	59
第 4 章 基于 MPC 的 MOCACC 控制算法设计	60
4.1 乘用车纵向动力学系统的分析与建模	60
4.1.1 车辆纵向动力学系统的基本结构	60
4.1.2 车辆纵向动力学模型及其参数	61
4.1.3 车辆纵向动力学模型的实验验证	66
4.2 自适应巡航控制对象建模	67
4.2.1 车辆纵向非线性的逆模型补偿	68
4.2.2 广义车辆纵向动力学系统的特性辨识	72
4.2.3 跟车系统动力学特性的集成式建模	74
4.2.4 跟车系统动力学模型的离散化	76
4.3 车辆 MOCACC 的性能指标设计	78
4.3.1 跟踪性能目标的性能指标	79
4.3.2 燃油经济性目标的性能指标	80
4.3.3 驾驶员感受目标的性能指标	84
4.3.4 性能指标的代价函数和约束条件设计	85
4.4 MOCACC 预测优化问题的推导	87
4.4.1 代价函数的预测型转化	88
4.4.2 约束条件的预测型转化	88
4.4.3 预测优化问题设计及其参数选取	90
4.5 基于 MPC 的车辆 MOCACC 控制算法	92
4.6 本章小结	92
第 5 章 模型预测控制算法实用化问题分析与处理	94
5.1 用于 ACC 的 MPC 算法实用化问题分析	94
5.2 基于反馈校正法的系统鲁棒性增强	95

5.2.1	鲁棒跟车预测模型的设计	95
5.2.2	前车加速度的预测器设计	97
5.2.3	前车加速度预测器的效果验证	99
5.2.4	鲁棒跟车预测模型的矩阵型转化	101
5.3	基于约束管理法的求解可行域扩展	103
5.3.1	输入输出硬约束的松弛化	103
5.3.2	带松弛因子的代价函数设计	104
5.3.3	代价函数和约束条件的矩阵型转化	105
5.4	基于规模缩减法的计算效率提升	109
5.4.1	静态优化问题的计算复杂度分析	109
5.4.2	静态优化问题的规模缩减框架	111
5.4.3	基于规模缩减法的 MPC 快速算法	114
5.4.4	集结矩阵和压缩矩阵的构造方法	114
5.5	MOCACC 控制算法的滚动时域优化求解	120
5.5.1	实用化处理后的预测优化问题	120
5.5.2	代价函数的二次规划型转化	122
5.5.3	约束条件的二次规划型转化	123
5.5.4	基于 Dantzig-wolfe 有效集法的 QP 问题求解	124
5.6	实用化问题处理效果的仿真验证	126
5.6.1	车辆 MOCACC 系统的仿真工况设置	126
5.6.2	反馈校正法增强系统鲁棒性的效果	127
5.6.3	约束管理法扩展求解可行域的效果	129
5.6.4	规模缩减法提升计算效率的效果	131
5.7	本章小结	134
第 6 章	车辆 MOCACC 系统的实验研究	135
6.1	车辆实验平台的设计与开发	135
6.1.1	改进的实车实验平台总体方案	136
6.1.2	平台 CAN 应用层协议的设计	137
6.1.3	xPC 控制器的软硬件设计与开发	140
6.1.4	执行器控制算法的设计与验证	143
6.1.5	实车平台各部件的集成	148

6.2 对比 ACC 系统与实验工况设计	150
6.2.1 用于性能对比的 ACC 控制算法设计	150
6.2.2 “虚拟雷达”的前车工况设计	151
6.2.3 实验场的实车实验过程描述	153
6.3 前车特定工况的实验验证	155
6.3.1 前车定加速工况	155
6.3.2 前车紧急制动工况	158
6.3.3 前车切出工况	159
6.3.4 前车正弦加减速工况	161
6.4 前车循环工况的实验验证	165
6.4.1 城市道路工况	165
6.4.2 高速公路工况	167
6.4.3 燃油经济性和跟踪性能对比	170
6.5 实验结果的补充说明	172
6.6 本章小结	173
第 7 章 结 论	174
参考文献	176
致谢与声明	185
个人简历、在学期间发表的学术论文及研究成果	186

主要符号对照表

$(k+i k)$	第 k 时刻对 $k+i$ 时刻的预测
a_f	自车加速度
a_{fdes}	期望纵向加速度
a_{fmax}, a_{fmin}	加速度的上下界
A, B, G	跟车系统状态空间方程的系数矩阵
A_{cstr}, b_{cstr}	二次规划约束条件的系数
$A_{safe}, D_{safe}, T_{safe}$	跟车安全性约束的系数
b_s	稳态燃油消耗率
C	跟车系统输出方程的系数矩阵
d	车间距离
d_{des}	驾驶员期望车距
d_{s0}	固定安全车距
D^A, D^B	驾驶员 A 组和 B 组数据集
D_n^A, D_n^B	驾驶员 A 组第 n 段数据和 B 组第 n 段数据
e	跟车系统的状态预测误差
e_{CF}	跟驰模型与跟车工况数据集的误差向量
e_{CFn}	跟驰模型与第 n 段跟车工况数据段的误差向量
e_L, e_M	LCF 模型和 MLCF 模型的误差变量
e_{Ln}, e_{Mn}	误差变量 e_L 和 e_M 的样本
E	跟驰模型与跟车工况数据集的总体误差
f_{opt}	二次规划代价函数的一次项矩阵
$F(a,b)$	以 a,b 为自由度的 F 分布
$Fuel(\cdot, \cdot)$	发动机稳态油耗特性
GVL D	广义车辆纵向动力学特性(Generalized Vehicular Longitudinal Dynamic)
H	跟车预测模型的校正矩阵

主要符号对照表

H_0, H_1	零假设, 备选假设
\mathbf{H}_{opt}	二次规划代价函数的 Hessian 矩阵
i_g	变速器挡位
j_{fmax}, j_{fmin}	加速度导数的上下界
k_D, k_V	驾驶员对 Δd 和 Δv 的名义控制增益
k_q	动态油耗补偿系数
k_{SDE}, d_{SDE}	SDE 模型的系数
k_{SVE}, d_{SVE}	SVE 模型的系数
K_b	制动系统增益
K_D, K_V	驾驶员对 Δd 和 Δv 的实际控制增益
K_G	GVL D 系统的增益
$L(\mathbf{y}, \mathbf{u}, \Delta \mathbf{u})$	MOCACC 性能指标的代价函数
LCF	线性跟驰 (Linear Car-Following) 模型
L_{DC}	驾驶员感受目标的二次型指标
L_{FC}	燃油经济性目标的二次型指标
L_{TE}	跟踪性能目标的二次型指标
M	等效整车质量
$\text{MAP}(\cdot, \cdot)$	发动机速度特性函数
MLCF	修正线性跟驰 (Modified Linear Car-Following) 模型
\mathbf{M}_T	集结矩阵
\mathbf{M}_U	与控制输入相关的压缩矩阵
$\mathbf{M}_{\Delta U}$	与控制增量相关的压缩矩阵
\mathbf{M}_Y	与系统输出相关的压缩矩阵
$N(a, b)$	均值为 a , 方差为 b 的正态分布函数
N_A	A 组跟车工况数据集的段数
N_B	B 组跟车工况数据集的段数
P	预测时域长度
P_{brk}	制动压力
P_{brkdes}	期望制动压力

主要符号对照表

P_e	发动机净功率
QDC	二次型期望车距(Quadratic Desired Clearance)
Q_s	发动机瞬时油耗
r, τ_h, d_0	QDC 模型的系数
SDE	驾驶员对距离误差的敏感度(Sensitivity to Distance Error)
SVE	驾驶员对车速误差的敏感度(Sensitivity to Velocity Error)
S_x, S_{ul}, S_u, S_e	跟车预测模型的系数
$t(n)$	自由度为 n 的 t 分布
T_e	发动机动态转矩
T_G	GVLD 系统的时间常数
T_s	采样时间
TTC	碰撞时间(Time To Collision)
T_{ul}, T_{du}	控制输入与控制增量关系式的系数
u	跟车系统的控制输入
u_{\max}, u_{\min}	控制输入的上下界
U	预测控制输入向量
U_{\max}, U_{\min}	预测控制输入向量的上下界
v	外部干扰
$v_{\max}^{\Delta u}, v_{\min}^{\Delta u}$	控制增量上下界的松弛系数
v_{\max}^u, v_{\min}^u	控制输入上下界的松弛系数
v_{\max}^y, v_{\min}^y	系统输出上下界的松弛系数
v_f	自车车速
v_{fmean}	平均车速
v_p	前车车速
V	预测时域的外部干扰向量
$V_{\max}^{\Delta u}, V_{\min}^{\Delta u}$	预测控制增量上下界的松弛向量
V_{\max}^u, V_{\min}^u	预测控制输入上下界的松弛向量
V_{\max}^y, V_{\min}^y	预测系统输出上下界的松弛向量
w_{du}	期望加速度导数的权系数

主要符号对照表

w_u	期望加速度的权系数
$w_{y\alpha}$	纵向加速度的权系数
$w_{y\Delta d}$	车距误差的权系数
$w_{y\Delta v}$	相对车速的权系数
W	跟驰模型误差的权矩阵
W_u	预测控制输入的权矩阵
$W_{\Delta u}$	预测控制增量的权矩阵
W_y	预测系统输出的权矩阵
x	跟车系统的系统状态
y	跟车系统的系统输出
y_{\max}, y_{\min}	系统输出的上下界
Y	预测系统输出
Y_{\max}, Y_{\min}	预测系统输出的上下界
Z	集结变量
α	显著性水平
β	置信度水平
α_{thr}	节气门开度
α_{thrdes}	期望节气门开度
Δd	车距误差
$\Delta d_{\max}, \Delta d_{\min}$	车距误差的上下界
Δu	控制增量
$\Delta u_{\max}, \Delta u_{\min}$	控制增量的上下界
ΔU	预测控制增量
$\Delta U_{\max}, \Delta U_{\min}$	预测控制增量的上下界
Δv	相对车速
$\Delta v_{\max}, \Delta v_{\min}$	相对车速的上下界
$\phi(M_\phi)$	以 M_ϕ 为压缩矩阵的压缩映射
λ	跟车模型离散化的模糊因子
ω_{CF}	跟车特性矩阵

Ω_{CF}	预测时域的跟驰特性矩阵
$\Omega_{\min}^U, \Omega_{\max}^U$	预测控制输入的约束集合
$\Omega_{\min}^{\Delta U}, \Omega_{\max}^{\Delta U}$	预测控制增量的约束集合
$\Omega_{\min}^Y, \Omega_{\max}^Y$	预测系统输出的约束集合
Ω_{safe}^Y	预测系统输出的补充约束集合
ω_e	发动机转速
$\psi(y, u, \Delta u, \varepsilon)$	带松弛因子的代价函数
χ^2	χ^2 分布的检验量
$\chi^2(m)$	自由度为 m 的 χ^2 分布
$\Theta_{\max}^U, \Theta_{\min}^U$	预测控制输入的压缩约束集合
$\Theta_{\min}^{\Delta U}, \Theta_{\max}^{\Delta U}$	预测控制增量的压缩约束集合
$\Theta_{\min}^Y, \Theta_{\max}^Y$	预测系统输出的压缩约束集合
Θ_{safe}^Y	预测系统输出补充约束的压缩集合

第1章 引言

1.1 概述

汽车产业的蓬勃发展，为人类出行提供了巨大的便利。然而，随着汽车保有量的增加和道路车流的增多，道路堵塞、交通事故、能源短缺和环境污染等问题日益严重^[1-3]，引起全社会的高度关注与重视。目前，依托智能交通系统(ITS, Intelligent Transportation Systems)框架提出的驾驶辅助系统(DAS, Driving Assistance Systems)旨在提升“人”对“车-路”系统的感知、决策和控制能力，为解决上述问题提供了一种有效的思路和技术手段^[4]。作为 DAS 的重要分支，自适应巡航控制系统(ACC, Adaptive Cruise Control system)因具有减轻驾驶员疲劳强度、提高车辆行驶安全性和增加道路交通流量的潜力，得到各研究机构和汽车厂商的广泛关注。该系统的基本原理是利用车载传感器感知自车及前向交通流的状态，结合驾驶员操作信息，根据一定的算法对驱/制动系进行自动控制，使车辆保持期望的纵向运动状态，实现定速巡航或跟车行驶等功能。

目前，ACC 系统的研发已经历两代，正进入新一代发展期。第一代 ACC 始于上个世纪 90 年代初，适用于城际交通流，以高速工况的自动跟车为主要功能^[5]。第二代 ACC 又称走-停巡航控制系统(Stop&Go Cruise Control System)。它始于本世纪初，适用范围扩展至城市交通流，以自动起步、停车和低速跟车为主要功能^[6]。随着世界范围内石油危机的加剧，燃油费用占整车成本的比重不断攀升，自适应巡航过程的油耗问题也成为不可回避的热点课题。

自适应巡航过程中，ACC 代替驾驶员调节油门开度或制动压力（甚至包括变速器挡位），因此，该过程的车辆油耗与 ACC 的控制特性密切相关。与驾驶行为差异会影响车辆油耗类似，不同的 ACC 控制策略，对应的车辆油耗也是显著不同的。以美国 PATH (Partners for Advanced Transit and Highways) 项目的研究成果为例，同一前车加速工况下，优化设计的 ACC 算法可使车辆节油 6% 以上^[7]。与改变车辆驱动系结构，达到省油效果的混合动力等系统不同，ACC 基本不改变原车结构，其节油功能的实现是以合理调节油门、制动和挡位为基础的。从微观角度看，节油型 ACC 仍可借用前两代 ACC 的结构，不增加任何硬件成本，这对降低车辆，尤其是商用车的运营成本具有重要的现实意义；从宏

观角度看, 装备该类 ACC 的车辆可平滑后向交通流, 提高道路运输的能源利用效率, 为解决严峻的能源问题提供了一条新的技术途径。因此, 新一代 ACC 系统中, 除了已有的自动跟车功能外, 降低自适应巡航过程的车辆油耗也成为日益迫切的功能需求。

然而, 这一节油潜力仅在自适应巡航期间有效, 它的实用化必须以系统的高使用率为基本前提。文献[8]指出, 作为一种驾驶辅助系统, ACC 的使用率很大程度上取决于用户对它的接受度。自适应巡航过程中, ACC 代替驾驶员控制车辆纵向运动状态, 驾驶员虽然不操作油门和制动踏板, 但仍处于驾驶位置, 可感知自车本身以及前后车之间的运动状态。自车加减速形成的体感以及车间相对运动形成的视感, 共同构成自适应巡航过程的驾驶员乘坐感受, 这是影响用户接受度的关键因素。文献[9]指出, 自适应巡航控制特性和驾驶员跟车特性的符合程度直接影响驾驶员乘坐感受。当两种特性相符, 即自车以及车间运动状态与驾驶员的心理预期一致时, 会增强用户的信任度, 提高系统的使用率。否则, 驾驶员极易主动干预油门和制动, 甚至弃用 ACC。这说明, 自适应巡航控制特性与驾驶员特性相符是保障 ACC 高使用率的必要条件, 它与上文提及的两类功能, 自动跟车行驶和低燃油消耗, 同等重要。

综上所述, 自动跟车行驶、低燃油消耗和符合驾驶员特性已成为新一代 ACC 系统不可缺少的基本功能。自动跟车行驶是 ACC 的基本功能; 低燃油消耗对于降低车辆运营成本、提高道路运输的燃油效率具有重要意义; 符合驾驶员特性是良好乘坐感受的基础, 也是驾驶辅助功能顺利实施的保障。

为满足上述要求, 与三类功能相关的跟踪性能目标、燃油经济性目标和驾驶员感受目标必须同时纳入新一代 ACC 控制系统的设计范畴。然而, 自适应巡航过程中, 这三类目标通常是相互制约的。过于追求跟踪性能往往导致自车强加速或强制动, 恶化车辆的燃油经济性, 影响驾驶员的乘坐感受。反之, 过于追求燃油经济性, 则意味着自车加减速强度的降低。当前车加速或制动时, 因自车加速或制动能力不足, 会造成过大的跟踪误差, 容易引起频繁的前车切入或追尾碰撞危险。类似, 若 ACC 系统完全模拟当前用户的跟车行为, 这相当于驾驶员操控车辆。因驾驶员本身的操作不一定使车辆具有高跟踪性和低油耗性, 所以完全模拟驾驶员的操控并不能保障另外两类目标的实现。而且, 车辆对象中, 驱制动系是强非线性环节, 道路坡度等外部干扰强烈, 不可避免存在较大建模误差。实际交通流中, 驾驶员跟车特性存在控制增益时变等非线性, 难以

融于控制算法的设计过程。这些因素使得新一代 ACC 的控制系统成为一个极其复杂的多目标协调控制问题。目前,国内外在解决单一目标的控制问题,如燃油经济性问题或驾驶员特性问题,已有初步的控制方法,但综合协调三目标的自适应巡航控制方法还未见诸报道。

为同时满足新一代 ACC 系统的三类功能需求,即自动跟车行驶、低燃油消耗且符合驾驶员特性,本文首次提出并建立了车辆多目标协调式自适应巡航控制(MOCACC, Multi-Objective Coordinated Adaptive Cruise Control)系统,重点研究该系统设计和应用过程涉及的基础理论与共性技术,包括驾驶员行为特性的分析与建模技术、多目标协调式控制技术和模型预测控制理论的实用化技术。首先,针对已有自适应巡航控制方法的不足,提出基于模型预测控制(MPC, Model Predictive Control)理论的车辆 MOCACC 体系结构。其次,分析驾驶员跟车过程的三类关键特性,即期望车距特性、动态跟车特性和期望跟踪误差特性,建立相应的数学模型;在此基础上,设计跟踪性能目标、燃油经济性目标和驾驶员感受目标的数学量化方法,综合新一代 ACC 系统的模型预测控制律;为实现该控制律的实车应用,分析模型预测控制理论三类实用化难点问题,并研究相应的解决措施。最后,开发实车实验平台,对本文方法的有效性进行实验验证。本文研究是已有 ACC 系统的进一步发展与提高,为国内外 ACC 系统尚未解决的难点问题和系统功能变革提供了新的理论方法和技术支撑。

1.2 车辆 ACC 系统的发展动态

前两代 ACC 系统中,车辆驱/制动系的强非线性、建模不确定性和坡道等外部干扰是控制算法设计的主要难点。这方面的研究已取得显著成果^[10-12]。随着 ACC 的逐渐普及,单独考虑燃油经济性或驾驶员感受问题的自适应巡航控制技术正日益受到关注。

1.2.1 考虑燃油经济性问题的 ACC

ACC 系统中,燃油经济性问题起源于节油型巡航控制(CC, Cruise Control)技术的研究^[13-16]。与 CC 相比,ACC 的工作车速更宽,适用范围更广,其节油型控制技术的研究更具应用价值。

这一技术的早期探讨集中于 ACC 节油的可行性。2000 年,英国 Southampton

大学的 Marsden G 等人实验分析指出,与手动驾驶相比,ACC 车辆的纵向加速度更加平稳,标准差可降低 44%~52%,具有节油的潜在能力^[9]。与此同时,美国 California 大学的 Ioannou P 研究指出,混合交通流中,当 ACC 车辆达到 10% 时,其整体油耗约降低 8%^[7]。结合上述研究成果,文献[17]、[18]和[19]指出可用于 ACC 的省油策略有:第一,调整发动机工作状态,使之工作于低油耗区;第二,缓加速和缓制动,降低车辆加速度水平;第三,近距跟车行驶,利用前车的气流,降低自车的风阻损耗。

基于第一类机理,针对挡位连续的 CVT 车辆,重庆大学的秦大同等人提出了发动机和 CVT 联合作动的 ACC 下位控制方法^[20]。该法的基本思想是同时控制油门开度和 CVT 速比,使发动机工作在最佳燃油经济线附近,在保证输出功率不变的前提下,获得最小的燃油消耗率。类似,日本 Nissan 公司的 Ino J 等人以发动机和 CVT 集成控制系统为基础,设计了一种下位驱动控制算法,使发动机尽量工作在低油耗区,以提高车辆的燃油经济性^[21]。针对挡位离散的 AMT 车辆,清华大学 Li S 等人拓展了该思想,提出油门和 AMT 联合作动的下位控制方法,利用加速过程提前升挡、减速过程提前降挡等方式降低车辆油耗^[22]。仿真表明,与基于逆模型法的下位控制方法相比,该法可降低油耗约 6%,且基本不影响跟踪性能。然而,该策略中,发动机工作点准确跟踪最佳燃油经济线是以变速器传动比和油门开度的频繁调节为代价的。二者的快速变化,尤其是挡位的频繁切换,一方面会造成较大的纵向冲击,影响驾驶员的乘坐舒适性,另一方面会加大离合器等传动系部件的磨损,影响车辆的使用寿命。而且,发动机和自动变速器的协调机制本身已经比较复杂。ACC 下位控制功能的添加,无疑会增大二者协调控制的难度,故,近期内难以实用化。

与调整发动机工作点策略相比,降低车辆加速度水平是一类具有实用化前景的省油策略。

美国加州 Berkeley 大学的 Zhang J 提出带非线性滤波器的 PI 控制策略,利用非线性滤波器平滑车间状态轨迹,使自车无紧急加速或紧急制动过程^[23]。仿真表明,前车紧急加速工况中,该策略可省油 5%~6%,但是与已有 ACC 控制方法相比,该法因对加速度限制过大,导致车距误差较大,易引入前车切入问题。这也说明,自适应巡航过程中,高跟踪性和低燃油消耗是相互矛盾的,提高单一目标的性能往往导致其他目标性能的下降。瑞典 Linkopings 大学的 Jonsson J 对相对车速和车辆油耗的协调控制问题进行了初步探讨^[24,25]。以燃油

消耗量和速度误差为自变量设计带 Mayer 函数的性能指标，权衡跟踪性能目标和燃油经济性目标。油门开度和挡位由最小化性能指标得到：

$$[u, i_g] = \left\{ u, i_g \mid \min_{u, i_g} \left\{ \phi(v_f) + \sum_{k=0}^N L[\Delta v(k), Q_e(k)] \right\} \right\} \quad (1-1)$$

式 (1-1) 中， u 为油门开度， i_g 为挡位， $\phi(\cdot)$ 为 Mayer 函数。同上述调整发动机工作点的控制方法一样，该法因采用的油门和挡位联合作动的策略，仍涉及发动机和自动变速器协调控制的问题，故难以实用化。而且，因为性能指标函数仅包括速度误差项，不能对跟车车距进行调整，无法解决因车距过大造成的前车切入或车距过小造成的追尾危险等问题。

总结已有文献，调整发动机工作点和降低车辆加速度水平是设计节油型 ACC 的两类主要措施。前者因发动机和变速器的协调机制过于复杂，其工程应用十分困难。后者中，已有方法存在以下问题：（1）降低车辆加速度水平，避免急加速和强制制动，虽然可以提高车辆的燃油经济性，但会降低跟踪性能，造成车距过大或车距过小的问题。这不仅会造成频繁的前车切入或追尾碰撞危险，导致驾驶员干预自适应巡航控制，而且极大影响驾驶员的乘坐感受，使系统失去辅助驾驶的意义；（2）跟车系统中，车辆的发动机为强非线性环节、变速器挡位离散、整车质量时变范围大且道路坡度干扰强烈，这不可避免造成较大的建模不确定性。已有方法均未考虑模型失配对控制性能的影响，会导致跟踪性能的严重下降。当模型失配严重时，不仅无法获得平缓的加减速过程，反而可能造成车辆急加速、强制制动，恶化车辆的燃油经济性。

1.2.2 考虑驾驶员感受问题的 ACC

目前，与 ACC 算法设计相关的驾驶员跟车特性主要包括三类，即驾驶员期望车距特性、纵向乘坐舒适性和驾驶员动态跟车特性。由于驾驶员跟车特性的研究早于 ACC 系统，对第一、二类特性的研究已经取得比较理想的结果，也广泛用于控制算法的设计过程^[26-28]。第三类特性又称跟驰特性，是指动态跟车工况中，驾驶员采用的加速度与车间状态、车辆状态的关系，反映了驾驶员调整自车运动轨迹的操作习惯。实际交通流中，尤其是城市交通流下，动态工况占跟车过程绝大部分时间，而且动态跟车特性表征车辆加速度、相对车速和车距误差的收敛模式，所以直接影响驾驶员主观感受，并在一定程度上反映第一、

二类特性。

动态跟车特性多利用驾驶员跟驰模型 (DCF, Driver Car-Following model) 描述。早在上个世纪 50 年代, Gipps D 和 Chandler R 等人通过研究驾驶心理机制, 以刺激-反应原理解释动态跟车过程, 建立了第一个跟驰模型^[29]:

$$\dot{v}_f(t+T) = \lambda \cdot \Delta v(t) \quad (1-2)$$

式 (1-2) 中, v_f 为自车速度, Δv 为相对车速, λ 为驾驶员控制增益, T 为驾驶员反应时间。利用实车实验数据, Gazis D 等人对刺激-反应模型 (1-2) 深入研究, 得出以下结论: (1) 对于不同的驾驶员, 驾驶员控制增益不是唯一的, 随驾驶个体的不同发生变化; (2) 对于同一驾驶员, 驾驶员控制增益也不是固定的, 随车距和车速的不同发生变化^[30]。与此同时, 为描述微观交通流特性, GM 公司的 Helly W 提出具有线性结构的跟驰模型^[31]:

$$a_f = K_V \cdot \Delta v + K_D \cdot \Delta d \quad (1-3)$$

式 (1-3) 中, K_V 和 K_D 为驾驶员控制增益, a_f 为自车加速度, Δv 为相对车速, Δd 为车距误差。此后, 众多学者的深入研究进一步揭示了驾驶员跟车过程的固有特性, 如: 加速工况和制动工况的不对称性^[30], 起停工况与高速工况的不一致性^[32], 拥堵交通流的特殊跟车特性^[33], 驾驶员操作的随机性^[34]等。为描述上述特性, 研究人员相继提出了多种跟驰模型, 如 GHR (Gazis-Herman-Rothery) 模型、Wiedermann 模型、OV (Optimal Velocity) 模型、AP (Action Point) 模型、模糊逻辑模型、神经网络模型等^[30,31]。这些模型结构复杂、参数众多、含非线性环节, 可较好模拟驾驶员的跟车特性, 在交通流分析等领域得到广泛应用^[35]。

为保证自适应巡航控制特性与驾驶员跟车特性一致, 目前多采用融合驾驶员特性模型设计 ACC 控制算法的方法。按照融合特性的不同, 将其分为三类: 第一类, 符合驾驶员期望车距特性, 保证自车按照驾驶员期望的车距跟随前车; 第二类, 满足纵向乘坐舒适性标准, 使自车具有良好的乘坐舒适性; 第三类, 融合驾驶员跟驰模型, 使自车的加减速过程与驾驶员动态跟车特性一致。

因为 ACC 的基本功能之一是车距保持, 故第一类特性是 ACC 控制算法的必要组成。其基本原理是利用驾驶员期望车距模型计算期望车距, 把它与实际

车距的误差作为状态变量，采用状态反馈措施使车距误差收敛为零，保证跟车车距与驾驶员特性一致。典型控制方法有：基于固定车距模型设计的滑模变结构控制律^[36]，基于二次车距模型设计的非线性解耦控制律^[12]以及自适应车间时距的 LQ 控制律^[27]等。为提高 ACC 车辆的纵向乘坐舒适性，第二类特性的融合多采用约束车辆加速度及其导数的措施。典型方法有基于约束滑动模的二阶滑模控制方法^[37]和车辆期望加速度的直接约束法^[28]。

为了在自适应巡航控制中体现驾驶员动态跟车特性，意大利 Plito 理工大学 Canale M 利用线性跟驰模型描述驾驶员特性，利用跟驰模型作为上位控制算法，增强自适应巡航控制特性和与驾驶员动态跟车特性的符合度^[38]。瑞典 Lund 大学 Persson M 等人采用“线性跟驰模型+PI 反馈”的控制结构，实现具有一定鲁棒特性的上位控制算法^[39]。Nissan 公司的研究人员则使用二阶惯性环节描述驾驶员动态跟车特性^[40,41]：

$$G_T(s) = \frac{\omega_{nT}^2}{s^2 + 2\zeta_T \omega_{nT} s + \omega_{nT}^2} \quad (1-4)$$

以式（1-4）为参考模型，结合模型匹配理论设计二自由度上位控制算法。该算法中，前馈补偿器和反馈补偿器共同作用，实现车距保持功能的同时，保证跟车状态的收敛轨迹与参考模型的输出一致，从而模拟驾驶员的动态跟车行为。

由上文的调研知，国内外在解决 ACC 的驾驶员感受问题时，主要考虑驾驶员期望车距特性、纵向乘坐舒适性和驾驶员动态跟车特性。对于前两类特性，多采用融合期望车距模型和限制车辆加速度的措施。对于第三类特性，多采用“线性控制方法+线性跟驰模型”的结构设计上位控制算法。实际应用中，现有方法主要存在以下问题：（1）驾驶员跟车特性是非线性的，存在控制增益时变等特点。目前，用于控制算法设计的线性跟驰模型难以充分反映上述特性，导致自适应巡航控制特性与驾驶员跟车特性仍存在较大差异。而用于交通流分析等领域的跟驰模型因结构过于复杂、可调参数众多且含强非线性环节，难以用于 ACC 控制算法的设计，也不利于用户根据自己的需求调节参数；（2）与 ACC 密切相关的三类驾驶员跟车特性，仍处于个别融于控制算法的设计阶段，尤其是第二、三类特性。因前者相当于车辆对象的状态约束，而后者相当于跟车系统的参考模型，现有的线性上位控制结构一方面不能处理约束问题，另一

方面,受跟车系统建模不确定性等影响,自适应巡航控制过程对参考模型的逼近程度仍难以保障。

综上所述,自适应巡航过程中,燃油经济性和驾驶员感受不是独立的,二者与跟踪性能互相影响、互相制约。跟车系统中,车辆发动机是强非线性环节、变速器挡位离散、整车质量时变范围大且道路坡度等外部干扰强烈,其模型不可避免存在较大误差,而且驾驶员跟车特性存在各类不等式约束,具有控制增益时变等非线性结构。而现有的 ACC 控制方法因具有下列缺陷,难以获得良好的控制品质:

- (1) 多以单一的低燃油消耗或符合驾驶员特性为控制目标;
- (2) 采用的线性反馈控制结构不具备多目标最优控制功能;
- (3) 未考虑车辆建模不确定性和驾驶员跟车特性的非线性对控制性能的影响。

因此,为同时满足新一代 ACC 系统的自动跟车行驶、低燃油消耗和符合驾驶员特性等功能要求,必须研究一种适用于非线性对象、可在线处理约束且对模型失配具有较好鲁棒性的多目标协调式自适应巡航控制方法。目前,应用于工业过程控制领域的模型预测控制方法,因具有下列优点^[43-47],是解决该问题的一个有力工具:

- (1) 适用于非线性对象,且对状态空间方程的形式和结构无特殊要求^[44,45];
- (2) 具有在线处理系统约束的能力,且对约束变量(如控制输入约束、系统状态约束和系统输出约束)、约束类型(线性不等式约束、椭圆不等式约束等)无限制^[46];
- (3) 具有最优或次优控制功能,可依据性能指标对被控对象进行最优或次优控制^[46];
- (4) 方法的扩展性强,可根据被控对象特点和控制性能要求,对算法本身进行改进,满足各种控制需求^[42,43]。

1.3 模型预测控制方法

预测控制的最初思想可追溯到 1963 年 Propoi 等人提出的滚动优化控制策略^[48]。经 50 多年的发展,已产生诸多分支,如模型算法控制(MAC, Model Algorithm Control)^[49]、动态矩阵控制(DMC, Dynamic Matrix Control)^[50]、广义预测控

制 (GPC, Generalized Predictive Control)^[51]、预测函数控制 (PFC, Predictive Function Control)^[52]等。模型预测控制 (MPC, Model Predictive Control)^[53], 又称滚动时域控制 (RHC, Receding Horizon Control)^[54], 也是预测控制的一个分支。与其他分支相比, MPC 以状态空间方程为对象模型, 适合采用现代控制理论分析其内部机理, 而且, 已有的 GPC 是它的一个特例, 因而对它的理论和应用研究更加广泛。

MPC 最早由 Mayne D Q 等人 (1988 年) 提出, 是 LQR 和 LQG 的一个推广方法。它的基本原理与一般预测控制方法相同, 即: 一个控制周期内, 利用被控对象模型对未来一段时间的状态或输出进行预测, 利用预测值构造预测优化问题; 采用数值优化方法求解预测优化问题, 利用最优解的局部元素构造控制输入量; 每个控制周期内重复上述过程, 不断构造新的控制输入量, 实现对被控对象的闭环控制。正是因为 MPC 特殊的控制原理, 它具有适用于非线性对象、可在线处理约束和最优/次优控制对象等优点, 是解决新一代 ACC 系统控制问题的有力措施。

然而, 拥有上述优点同时, 受 MPC 理论本身缺陷的限制, 它的工程应用存在三类实用化难点问题, 即对模型失配的低鲁棒性、最优控制量的非可解和在线优化的高计算复杂度。

第一类问题主要是由被控对象建模误差造成的^[49,51]。因被控对象建模过程中, 不可避免存在参数测量误差、未建模动态和外部干扰等不确定性, 所建立的数学模型与被控对象总存在一定失配。当模型失配严重时, 传统的 MPC 方法因无法补偿模型失配造成的预测误差, 会导致最优控制性能下降, 这在快变对象中尤为显著。

第二类问题与预测优化问题的可行域密切相关, 产生的原因有: (1) 受被控对象约束条件的限制, 系统状态的自由空间很小, 造成预测优化问题的可行域很小^[55]; (2) 外部扰动或模型失配过大时, 被控对象的机械惯性造成系统状态进入预测优化问题的可行域之外^[55]; (3) 为保证闭环系统稳定, 增加稳定性约束条件, 但缩小了预测优化问题的可行域^[56,57]。无论可行域缩小, 还是状态位于可行域之外, 它的一个直接结果是预测优化问题无解。当预测优化问题无解时, 最优控制量不存在, 造成控制进程中断。

第三类问题与预测优化问题的类型和规模、数值优化算法的效率和被控对象的实时性要求同时相关^[58]。MPC 的单个控制周期内, 它利用数值优化算法求

解预测优化问题，得到最优控制量。对于车辆等快变对象，控制周期多为秒级或毫秒级，它对控制律求解的实时性要求很高。当 MPC 的预测时域较长或系统状态、控制输入较多时，预测优化问题的规模通常较大，受数值优化算法效率的限制，其在线优化的计算复杂度很高，单个控制周期内完成数值求解是十分困难的。这一问题在预测优化问题为非线性时尤为严重。因此，即使预测优化问题各步均有可行解，若单个控制周期内无法求解最优控制量，控制进程也会中断。这是在线优化的高计算复杂度问题。

1.3.1 MPC 在车辆控制领域的应用现状

目前，预测控制方法在车辆控制领域的应用日渐普及，如柴油机增压控制^[59,60]、汽油机电喷控制^[61]、转向避撞控制^[62]、横摆稳定性控制^[63]、动态车速控制^[64]等。考虑本文的研究方向，本节以总结它在纵向运动控制领域的应用为主。该领域，预测控制方法多用于设计车速控制器和车距保持控制器。前者用于巡航控制系统，以满足特殊的功能需求，如执行器受限^[65]、低油耗^[13]、最短时间到达^[13]等。后者用于 ACC 系统，主要是进一步提高已有的系统功能，如降低跟踪误差、提高乘坐舒适性和跟车安全性等。

目前所知，利用预测思想设计车速控制算法始于 2004 年。DaimlerChrysler 公司以油耗最低为目标设计了预测巡航控制（PCC，Predictive Cruise Control）器^[13]。其基本思想是：对于给定的运输任务（起点、终点、行车路线已知），设计以燃油消耗为变量的全局代价函数，采用动态规划（DP，Dynamic Programming）算法求解最优车速轨迹，使行车过程的油耗最小。

瑞典 Linköping 大学 Hellstrom E 等人进一步改进 PCC，提出同时降低运输时间和燃油消耗的车速控制方法^[16]。其全局代价函数不仅包括燃油消耗量，而且含行车时间，该方法也采用 DP 算法求解最优控制律。类似，法国埃夫里大学 Nouveliere L 等人设计了一种行车时间固定、油耗最低的 PCC 控制器^[66]。

与已有的定速巡航控制系统相比，PCC 的车速是时变的，由控制算法根据车辆状态、道路坡度以及性能指标优化给出，故具有低油耗或短时间到达等优点。但是，应用 PCC 的一个基本前提是：行车路线是预先已知的，且交通流稀疏，满足车辆巡航行驶的要求。实际上，无论城际道路、还是城市道路，完全满足巡航行驶的交通流较少，这极大限制了它的实际应用。而具备跟车功能的 ACC 系统，因满足大部分城际、城市交通工况的要求，具有更广泛的应用前景。

针对 ACC 的控制模式切换问题,美国 Minnesota 大学 Bageshwar L 等人(2004 年)建立了一种基于 MPC 的模式切换控制方法。该法以车距误差和相对车速的 2 范数作为代价函数,以限制加速度量为约束条件,满足纵向乘坐舒适性要求的同时实现车速和车距控制模式的最优切换^[67]。荷兰 Delft 科技大学 Corona D 等人(2006 年~2008 年)利用分段仿射模型描述跟车系统,提出一种混合模型预测控制方法。其代价函数为车距误差和相对车速的 1 范数,约束条件可限制加速度量和最小车距,以保障纵向乘坐舒适性和跟车安全性^[68-72]。荷兰 Eindhoven 科技大学 Naus G 等人(2008 年)以三状态线性跟车模型为基础,建立跟踪误差的 2 范数性能指标,利用约束控制输入的措施,提高乘坐舒适性^[73]。瑞典 Linköpings 大学的 Jonsson J 建立了空间域的非线性车辆模型,以相对车速和燃油消耗量为自变量建立带 Mayer 函数的性能指标,实现跟踪性能和燃油经济性的初步协调控制^[24,25]。表 1.1 总结了现有基于 MPC 的 ACC 控制方法的主要特点。

表 1.1 基于 MPC 的 ACC 控制方法总结

文献来源	预测时域长度	代价函数	约束条件
Bageshwar L 等 ^[67]	--	跟踪误差最小	限制加速度
Corona D 等 ^[68-72]	2	跟踪误差最小	限制加速度 限制最小车距
Naus G 等 ^[73]	--	跟踪误差最小	限制加速度
Jonsson J 等 ^[24,25]	3	相对车速和燃油消耗最小	--

分析表明,现有方法虽然也采用 MPC 设计控制器,但因下列原因,仍不能满足新一代 ACC 系统的性能要求:(1)代价函数多以跟踪误差为自变量,约束条件仅限制车辆加速度和最小车距,存在控制目标单一的缺点;(2)预测时域较短,难以保障闭环系统的全局最优性。预测时域长度体现了 MPC 算法的最优性。预测时域越长,闭环控制结果越接近全局最优。短预测时域仅表明局部时间段内控制性能是较好的,不代表全局范围内系统的性能最优。

另外,鉴于 MPC 实用化问题对算法实车应用的重要性,已有文献也对低鲁棒性、非可解和高计算复杂度问题进行了初步探讨,如表 1.2 所示。

表 1.2 MPC 实用化问题的处理措施

文献来源	低鲁棒性	非可解	高计算复杂度
Bageshwar L 等 ^[67]	--	限制初始状态法	--
Corona D 等	Min-Max 法 ^[70]	--	多参数规划法 ^[68]
Naus G 等 ^[73]	--	--	多参数规划法
Jonsson J 等 ^[24,25]	--	--	--

对于低鲁棒性问题，文献[70]采用 Min-Max 法设计预测优化问题，并采用 Min-Max 优化算法求解控制律，保证闭环系统的控制性能不低于预定性能指标的下界。但该方法存在下列问题，难以实车应用：第一、Min-Max 法构造的预测优化问题具有较大保守性，会极大缩小最优解的可行域，增大非可解问题的概率；第二、与线性规划或二次规划相比，Min-Max 预测优化问题的计算复杂度更高，计算效率很低，不能满足车辆对象的实时性要求。故对该方法的验证仍处于仿真阶段。

对于非可解问题，文献[67]采用限制初始状态法保证模式切换过程中，系统状态总处于可行域之内。但该方法的有效性是以初始状态处于约束集之内为代价的，具有很大的局限性。当初始状态处于约束集之外，最优控制量的非可解问题仍可能存在。

对于高计算复杂度问题，文献[68]和[73]采用的多参数规划法虽然提高了计算效率，但同时也占用了大量在线内存。表 1.3 统计了该法对计算效率和在线内存的影响^[71,72]。比较法 2 与法 3（或法 4 与法 5）易知，多参数规划法虽然有效降低了在线计算时间，但大大增加了数值优化算法的代码量，占用大量在线内存。而且，由文献[74]知，算法的代码量与预测时域长度呈指数增长关系。当预测时域长度较短(如文献[71]和[72]，预测时域长度=2)时，它占用的在线内存量仍可以接受的。但对于以优化控制为目标的 MPC，预测时域通常较长，算法代码量急剧增加，远大于一般控制器的内存，是难以实车应用的。

表 1.3 文献[71]和[72]对不同 MPC 算法的比较

方法	1	2	3	4	5
跟车模型	非线性模型	分段线性模型	分段线性模型	Taylor 线性模型	Taylor 线性模型
模型状态	2	2	2	2	2
预测时域	2	2	2	2	2
求解算法	NMPC ^①	MILP ^②	mpMILP ^③	LP ^④	mpLP ^⑤
计算时间(ms)	520	52	7.4	36	4.8
在线内存(Mb)	0.33	0.46	16.6	0.22	4.1

① NMPC 为非线性规划算法；② MILP 为混合整型线性规划算法；④ LP 为线性规划算法；③、⑤中，前缀 mp 表示多参数规划法。

1.3.2 MPC 理论实用化技术的研究现状

目前，国内外在解决 MPC 的实用化问题，即对模型失配的低鲁棒性、最优控制量的非可解和在线优化的高计算复杂度时，已有一些研究成果。因被控对象、性能指标以及实际应用背景的不同，各处理方法具有自身的特点和相应的优缺点，现逐一总结。

（1）鲁棒性问题的研究现状

预测控制方法的鲁棒性问题已有较多研究，典型措施有 Min-Max 法、混合控制法、反馈校正法、线性矩阵不等式法等^[75,76]。本文主要介绍前三类方法。

早在 1978 年，Richalet J 等人针对脉冲响应模型，指出鲁棒预测控制问题可转化为 Min-Max 优化问题^[77]。基于该思想，1997 年 Lee J 等人针对不确定性对象，将无穷时域的预测优化问题转化为 Min-Max 优化问题^[78]。Min-Max 优化问题的数学形式为：

$$\min_{u_k} \max_{[\theta_k, \dots, \theta_{k+p-1}] \in [\Theta \times \dots \times \Theta]} \left\{ x_{k+p}^T Q_p x_{k+p} + \sum_{l=1}^{p-1} x_{k+l}^T Q x_{k+l} + \sum_{j=0}^{q-1} x_{k+j}^T R x_{k+j} \right\} \quad (1-5)$$

利用 Min-Max 优化算法求解上式，得到最优控制律。当模型误差有界时，该法可保证控制性能不低于性能指标（1-5）的下界。如上节所述，该法的主要

缺陷在于：第一、极大缩小了可行域范围；第二、算法的计算效率较低。该法的后续研究也主要针对这两点问题，如文献[79]、[80]和[81]。

混合控制思想最早由 Corradini M 等人提出^[82]，其基本原理是：被控对象的确定性部分采用 MPC 设计控制律，不确定性部分采用附加控制律（如滑模控制方法等）保证鲁棒收敛。周建锁等人提出一种 MPC 与滑模控制律相结合的非线性控制方案^[83,84]。针对公称模型设计 MPC 控制律 u_{mpc} ，针对不确定模型设计滑模控制律 u_{vsc} ，利用组合控制律 $u = u_{mpc} + u_{vsc}$ 镇定系统。姚琼荃等人进一步扩展了上述思想，提出一种基于预测型滑模面的 MPC 控制律^[85,86]。该法以被控对象的公称模型预测未来状态，利用状态预测值建立预测型滑模面 S_p 。最小化以 S_p 为自变量的性能指标，获得 MPC 控制律。仿真表明，当被控对象的不确定性有界时，闭环系统鲁棒镇定。混合控制的主要特点在于：附加控制律的引入虽然可以提高闭环控制的鲁棒性，但会极大削弱它的最优性，不适合以性能优化为目标的控制领域。

反馈校正法也是提高预测控制鲁棒性的一类措施，它的基本思想来源于 MAC 和 DMC。在 MAC 和 DMC 中，反馈校正项作为预测控制方法的基本构成而存在^[48]。其基本原理是：基于公称模型设计预测模型，利用预测值与测量值的偏差建立反馈校正项，利用反馈校正项修正预测模型，提高预测模型对不确定被控对象的预测精度。从原理上讲，反馈校正法可用于任何一类预测控制方法，但目前所知，它在 MPC 领域的应用还比较少。与混合控制法相比，反馈校正法虽然对控制鲁棒性的提升稍弱，但它基本不影响闭环控制的最优性，且方法简洁、原理清晰，具有较好的工程应用前景。

（2）非可解问题的研究现状

目前，解决非可解问题的常用措施有三类，即：可行解构造法、约束管理法和不变集法。

可行解构造法的基本思路是当预测优化问题无解时，利用人为构造的开环序列代替最优开环序列，保证预测控制不会中断。实施该法的关键在于构造满足约束条件的开环序列。一类典型的构造方法称“时域递减法”^[55]，即 $k-1$ 时刻的序列 $u(k+i|k-1)$ 向前移位一次，构成 k 时刻的开环序列 $U(k)$ ：

$$U(k) = [u(k+1|k-1) \quad \cdots \quad u(k+P-1|k-1)] \quad (1-6)$$

式（1-6）中， P 是预测时域长度。因为 $k-1$ 时刻的序列 $u(k+i|k-1)$ $i=1:P-1$ 均

是满足约束条件的可行解，则式 (1-6) 必为 k 时刻的一组可行解。利用 $U(k)$ 构造 k 时刻的控制量，可避免非可行解造成的控制中断问题。“时域递减法”一个主要缺陷是：与 $k-1$ 时刻的序列相比， k 时刻序列低一维，不利于算法编程的规范处理。为了避免序列维数的变化，另外一种构造方法称为“控制序列移位法”^[55]，即在式 (1-6) 基础上后补未知量 ψ 。令 ψ 服从被控对象的约束条件，则利用开环序列 $U(k)$ 进行反馈控制，也可避免非可解问题。可行解构造法虽然解决了因非可解造成的控制中断问题，但 k 时刻开环序列的可行性不代表最优性，即人为构造的可行序列不能对被控对象实施最优控制。因此当非可解问题频繁发生时，它难以保证闭环控制的最优性。

约束管理法的基本原理为：当控制输入或系统输出超出约束范围时，利用松弛因子扩大约束的上下界，消除约束条件的强制性^[87,88]。对于线性不等式约束：

$$Ex(k+i|k) + Fu(k+i|k) \leq G, i=1:P-1 \quad (1-7)$$

当上式左端大于右端项 G 时，利用松弛因子扩展其上界，转化为约束上界可松弛化的软约束：

$$Ex(k+i|k) + Fu(k+i|k) \leq G + V \cdot \varepsilon, i=1:P-1 \quad (1-8)$$

式 (1-8) 中， $V \in R^+$ 称为松弛系数， $\varepsilon \in R^+$ 为松弛因子。松弛约束条件边界的目的是扩大预测优化问题的可行域范围，保证可行解的存在。这虽然从根本上避免了非可解问题，但该法会对性能指标的代价函数进行修改，导致实际控制特性与原性能指标的要求不一致。一般来说，被控对象的约束条件有两类，第一类如执行器饱和限制等。因为它们与物理硬件相关，是不可违背的，所引起的非可解问题多采用可行解构造法解决。第二类是人为增加的约束条件，如最低经济效益限制等，因它们在容许的范围内是可以违反的，所引起的非可解问题多采用约束管理法处理。

与上述两种方法不同，不变集法主要解决稳定性约束造成的非可解问题。目前，为保证预测控制闭环稳定，多采用在原优化问题上附加稳定性约束的方法，如终端等式约束 (Terminal Equality Constraint)^[89,90]。但是，因终端等式约束要求预测状态收敛为零，该法极大缩小了最优解可行域的范围，常造成非可解问题。为此，文献[91]、[92]和[93]提出终端状态集合约束的措施，即以集合

约束 $x(k+P|k) \in \mathbf{X}_f$ 代替等式约束, 其中 \mathbf{X}_f 称为不变集合。已有文献中, 最常用的 \mathbf{X}_f 是椭圆不变集。因椭圆不变集对被控对象的状态构成不变空间, 而不变空间具有自闭特性, 即任意 k 时刻, 终端状态进入 \mathbf{X}_f 后, 后续时刻的终端状态仍属于 \mathbf{X}_f 。因此, 只要初始状态处于 \mathbf{X}_f 之内, 可保证后续状态均位于 \mathbf{X}_f , 使终端状态集合约束不会影响求解的可行性。很明显, 不变集 \mathbf{X}_f 的大小决定了最优解的可行域范围, 因而, 在保证闭环系统稳定的前提下, 如何扩大不变集的范围是一个关键问题。已有方法有双椭圆不变集^[94]、最优椭圆不变集^[95]等。

不变集法的基本前提是初始状态处于 \mathbf{X}_f 之内。工程应用中, 一个措施是: 强制初始状态处于 \mathbf{X}_f 之内, 即限制初始状态法^[67]。另外一个措施是: 当系统状态处于 \mathbf{X}_f 之外, 先利用一局部镇定的控制器 (如 LQ 控制器), 使状态收敛至 \mathbf{X}_f 之内, 再采用不变集法保证求解可行性^[58]。

(3) 计算复杂度问题的研究现状

模型预测控制方法中, 在线优化的计算复杂度是决定算法能否实用的关键, 这对快变对象尤为重要。围绕 MPC 的计算复杂度问题, 已有研究集中于三类方法: 被控对象线性化、高效数值优化算法和待优化变量减维法。

一般来说, 非线性对象的预测优化问题均可转化为一非线性规划 (NP, Nonlinear Programming) 问题, 利用 NP 算法可求解最优控制律。Zheng A 等人指出: NP 问题的规模随优化变量的维数呈指数增长, 这导致非线性 MPC 算法很难用于实时控制领域^[96]。表 1.3 中, 方法 1 属于 NP 问题, 它的计算时间较长也证明了这一点。被控对象线性化法的基本思想是以线性模型近似描述非线性对象, 利用计算效率更高的线性规划(LP, Linear Programming)代替 NP, 建立 MPC 控制律。按照线性化方法的不同, 有 Taylor 线性化法^[97]、基于微分几何的反馈线性化法^[98]、多模型线性化法^[99]等。线性化法虽有助于减小 NP 的计算复杂度, 但存在以下缺点: (1) Taylor 线性化方法误差较大, 难以实现被控对象的最优控制; (2) 反馈线性化法的使用条件苛刻, 难以广泛应用, 而且线性化状态的物理意义不明确; (3) 多模型线性化法不可避免存在控制器切换问题, 容易引起闭环系统的抖振。

高效数值优化算法的基本思想是通过提高 NP 的求解效率, 降低 MPC 的计算复杂度。目前, 多参数规划法 (multi-parametric Programming) 是一类比较有效的数值优化算法^[100,101]。Bemporad A 等人首次将多参数规划法用于求解预测控制律^[102]。它基本原理是将在线计算的预测优化问题转化为离线计算的多参数规

划问题，把最优控制量的数值求解转化为一显示函数的查表过程。从理论上讲，多参数规划法的求解时间等价于显式函数的查表时间，可有效提高最优控制量的求解效率^[103]。表 1.3 是多参数规划法优势的一个例证，对于同一 LP 或 MILP 问题，mpLP 的在线计算时间仅为普通 LP 算法的 1/7，mpMILP 仅为普通 MILP 算法的 1/8。然而，反映最优控制量与系统状态关系的显式函数是一个极其复杂的分区非线性函数，转化为控制器代码时，会占用大量在线内存。如表 1.3 所示，mpMILP 的在线内存是 MILP 的 36 倍，mpLP 的在线内存是 LP 的 18 倍。而这仅仅是预测时域长度为 2 的结果，考虑显式函数的复杂度与预测时域长度呈指数增长关系^[74]，当预测时域较长时，多参数规划法的在线内存会远大于一般控制器的内存。这是该法工程实用的最大问题。

降低在线优化计算复杂度的第三类方法是优化变量减维法，它包括低维参数化方法^[104]和直接减维法^[105]。与高效数值优化算法不同，待优化变量减维法专注于预测优化问题至 NP 的转化过程。低维参数化法的基本原理是利用一参数化函数描述系统状态与控制输入的关系，把参数化函数代入预测优化问题，将以控制序列为自变量的 NP 问题变为以函数参数为自变量的 NP 问题，从而减小在线优化的计算复杂度。应用低维参数化法的关键是参数化函数的选取，已有方法有阶梯型函数^[106]、多项式函数^[107,108]等。低维参数化法虽然可以有效提高在线优化的计算效率，但它的控制序列轨迹是受参数化函数的约束，对原性能指标不具有最优性。直接减维法由席裕庚等人首先提出，又称变量集结策略^[105]。其基本思想是：对控制序列进行低维线性变换，代入预测优化问题后，直接减小待优化变量的维数，从而降低在线优化的计算复杂度。文献[94]和[109]进一步拓展了该思想，针对无约束线性 MPC，提出不影响控制最优性的等效集结策略。变量集结策略的核心是控制序列的线性变换方法。因为该策略对线性变换方法无特定的要求，具有很好的扩展性，可覆盖已有的短控制时域法、粗控制细优化法、单值预测法、指数增长式控制法等。然而，该法的工程应用是比较困难的，一方面该方法中计算效率和闭环控制的最优性是相互矛盾的，这一问题还未得以充分研究。另一方面，线性变换方法多样，缺少相对规范的设计手段，仍依赖人工“试凑”得出。

1.4 本文研究内容

通过上文阐述,在解决新一代 ACC 系统的控制问题方面,已有方法多局限于跟踪性能目标、燃油经济性目标与驾驶员感受目标相分离的设计方案。自适应巡航过程中,这三类目标相互影响、相互制约,而且车辆对象建模不可避免存在误差,驾驶员特性存在控制增益时变等非线性,这导致现有 ACC 控制方法难以满足多目标协调控制的功能需求。模型预测控制理论具有适用于非线性对象、可在线处理约束和最优化性能指标等优点,为解决该问题提供了一条有效途径,但它在新一代 ACC 系统的应用研究基本空白。为此,本文开展了如下几方面的工作:

(1) 建立基于模型预测控制理论的车辆多目标协调式自适应巡航控制体系结构

针对新一代 ACC 系统,定义跟踪性能目标、燃油经济性目标和驾驶员感受目标的基本内容,研究基于模型预测控制理论(MPC, Model Predictive Control theory)的车辆多目标协调式自适应巡航控制(MOCACC, Multi-Target Coordinated Adaptive Cruise Control)体系结构。

(2) 以中国驾驶员道路实验数据为基础,建立适用于 ACC 系统设计的驾驶员跟车特性模型

以中国驾驶员道路实验数据为基础,设计符合中国交通流特征的跟车工况判断准则,选取有效跟车工况数据集。在此基础上,分析驾驶员期望车距特性、驾驶员动态跟车特性和驾驶员期望跟踪误差特性,研究满足控制算法设计需求的驾驶员跟车特性建模技术,并对模型的精度和适用度进行比较验证。

(3) 设计用于新一代 ACC 系统的车辆多目标协调式自适应巡航控制算法

以某国产乘用车为对象,采用逆模型法补偿车辆纵向非线性,结合车间纵向动力学特性设计跟车系统的离散状态空间方程。在车辆 MOCACC 体系结构下,研究跟踪性能目标、燃油经济性目标和驾驶员感受目标的数学量化方法,建立具有二次型代价函数和线性不等式约束的预测优化问题,综合新一代 ACC 系统的模型预测控制算法。

(4) 模型预测控制理论实车应用中实用化关键问题分析与处理

分析用于车辆 MOCACC 体系结构时, MPC 三类实用化问题的成因。针对对模型失配的低鲁棒性问题,采用反馈校正法设计鲁棒跟车预测模型,提高模型对跟车系统状态的预测精度;针对最优控制量的非可解问题,采用约束管理

法修正代价函数，松弛 I/O 硬约束，扩展预测优化问题的可行域；针对在线优化的高计算复杂度问题，综合变量集结策略和约束集压缩策略，提出规模缩减法的基本框架，设计相应的模型预测控制快速算法。通过仿真实验，对三类处理方法的有效性进行验证。

（5）车辆多目标协调式自适应巡航控制系统的实车实验研究

改进已有的实车实验平台，利用四种特定前车工况和两种前车循环工况，对本文提出的 MOCACC 方法进行实验验证，并与现有的 LQ 等方法进行对比。实验结果表明，本文方法可综合提升新一代 ACC 系统的跟踪性能和燃油经济性，且符合稳态驾驶员跟车、纵向乘坐舒适性和动态驾驶员跟车等特性。

（注：本论文中，新一代 ACC 系统因采用 MOCACC 体系结构设计，故又称为 MOCACC 系统。）

第2章 车辆新一代 ACC 系统的体系结构设计

对于新一代 ACC 系统, 现有控制方法存在功能目标单一, 且未充分考虑车辆对象建模失配和驾驶员特性非线性等问题, 无法满足多目标控制需求。为同时实现自动跟车行驶、低燃油消耗和符合驾驶员特性三类功能, 本章首先定义跟踪性能目标、燃油经济性目标和驾驶员感受目标的具体功能需求; 其次, 建立基于模型预测控制 (MPC, Model Predictive Control) 理论的车辆多目标协调式自适应巡航控制 (MOCACC, Multi-Objective Coordinated Adaptive Cruise Control) 方案; 最后, 阐述该方案设计过程和实车应用所需的关键技术, 以及各关键技术之间的联系。本论文中, 新一代 ACC 系统因采用 MOCACC 体系结构设计, 故又称为 MOCACC 系统。

2.1 新一代 ACC 系统的控制目标

前两代 ACC 系统多以良好的跟踪性能为控制目标^[10-12]。然而, 自适应巡航过程中, 过于精确的车速和车距跟踪多是不利的。当前车加速、制动或切入/切出时, 往往导致自车强加速或强制制动, 这不仅会恶化车辆的燃油经济性, 影响乘坐舒适性, 而且易放大前车加速度干扰, 使后向交通流不稳定。反之, 若放宽对跟踪性能的要求, 过于追求低油耗目标也是不合适的。燃油经济性的提高意味着自车加减速强度的降低。当前车加速时, 自车缓加速造成的过大车距, 会引起频繁的前车切入; 当前车制动时, 自车缓减速造成的过小车距, 使追尾碰撞的概率增大, 影响跟车安全性。另外, 若单纯采用驾驶员跟驰模型设计 ACC 控制算法, 因跟驰模型仅反映一般交通工况的驾驶员跟车特性, 它的跟踪能力较弱, 难以满足强加减速工况的自动跟车功能, 也无法保证行车过程的油耗最低。考虑上述因素, 定义新一代 ACC 系统的控制目标, 如下:

(1) 跟踪性能目标

同已有的 ACC 一样, 以自动跟车行驶为基本功能。前车稳态行车工况中, 车距误差和相对车速收敛为零。前车动态行车工况中, 车距误差和相对车速处于驾驶员期望跟踪误差范围, 以避免大车间距离带来的前车切入或小车间距离带来的驾驶员干涉。前车紧急制动工况中, 车间距离须大于零, 以避免追尾碰

撞事故的发生。

(2) 燃油经济性目标

自适应巡航过程中，尽量使自车缓加速、缓制动，发动机处于低油耗区，以降低车辆行驶过程的燃油消耗量。与前两代 ACC 相比，新一代 ACC 应使车辆具有更好燃油经济性。

(3) 驾驶员感受目标

自适应巡航过程应符合三类驾驶员跟车特性。第一、驾驶员期望车距特性，即：前车匀速行驶时，跟车车距与驾驶员期望的车间距离一致；第二、驾驶员纵向乘坐舒适性，即：自车的纵向运动舒缓，无冲击，符合纵向乘坐舒适性标准；第三、驾驶员动态跟车特性，即：前车加减速的动态跟车过程中，尽量减小自车运动轨迹与驾驶员期望轨迹的误差，保证自适应巡航控制特性与驾驶员的动态跟车特性相似。

2.2 多目标协调式自适应巡航控制方案

因为跟踪性能、燃油经济性和驾驶员感受三类目标互相矛盾，单一目标的强化往往导致其他目标的降低，所以，从本质上说，车辆多目标协调式自适应巡航控制是一个多目标优化控制问题。本文基于 MPC 理论，提出一种车辆多目标协调式自适应巡航控制方案，如图 2.1 所示。




图 2.1 基于 MPC 的车辆 MOCACC 方案

该方案包括 MOCACC 性能指标、跟车预测模型、驾驶员参考模型、滚动时

域优化计算以及被控对象本身，即跟车系统。图中， k 表示当前时刻， $(k+i|k)$ 表示以 k 时刻信息对 $k+i$ 时刻的预测， u 代表跟车系统的控制输入， y 代表跟车系统输出， v 代表跟车系统外部干扰， r 代表驾驶员参考轨迹。

MOCACC 性能指标包含代价函数和输入输出 (IO, Input and Output) 约束两个部分，它们与驾驶员参考模型共同界定 ACC 的基本性能，是控制器对三类目标进行协调控制的基础。代价函数利用矩阵 2 范数描述，以跟踪误差、燃油消耗量和驾驶员特性误差为变量。I/O 约束利用线性不等式描述，包含纵向乘坐舒适性标准、驾驶员期望跟踪误差范围和跟车安全性条件。

跟车预测模型基于跟车系统动力学模型建立，它根据跟车系统的输出 $y(k)$ 、前一时刻的控制输入量 $u(k-1)$ 以及外部干扰量 $v(k)$ ，估计预测时域内的系统输出 $y(k+i+1|k)$ 、控制输入 $u(k+i|k)$ 和控制增量 $\Delta u(k+i|k)$ 。

驾驶员参考模型利用驾驶员跟驰模型设计，用于体现驾驶员的动态跟车特性，其输入为 $y(k+i+1|k)$ ，输出为驾驶员参考轨迹 $r(k+i+1|k)$ 。

滚动时域优化计算则利用预测时域的控制输入 $u(k+i|k)$ 、控制增量 $\Delta u(k+i|k)$ 以及系统输出 $y(k+i+1|k)$ 与驾驶员参考轨迹 $r(k+i+1|k)$ 的差，结合 MOCACC 性能指标建立预测优化问题。每个控制周期内，利用数值优化算法求解该问题，以其开环最优序列的首元素构造控制输入量 $u(k)$ ，实现跟车系统的最优控制。

该控制方案中，驾驶员参考轨迹是驾驶员跟驰模型的输出，最小化它与预测时域系统输出的差，可保证自适应巡航控制特性与驾驶员动态跟车特性相符合。滚动时域优化计算中，利用 MOCACC 性能指标求解最优控制输入，在满足 I/O 约束的前提下，最小化代价函数，可实现跟踪性能目标、燃油经济性目标和驾驶员感受目标的协调控制。跟车预测模型的设计以跟车系统动力学模型为基础，它的介入有利于提高 ACC 系统对模型失配的鲁棒性。因此，与线性最优控制方法相比，该方案预计可取得理想的多目标协调式自适应巡航控制效果。

2.3 车辆 MOCACC 方案的关键技术

如图 2.2 所示，车辆 MOCACC 方案的关键技术分为四项，包括驾驶员跟车特性的分析与建模技术、跟车系统动力学特性建模技术、MOCACC 性能指标的设计技术和 MPC 实用化问题分析与处理技术。前三项与控制律的设计过程相关，主要围绕驾驶员参考模型、跟车预测模型和 MOCACC 性能指标展开。最后一项

与控制律的实车应用相关，主要与滚动时域优化计算环节相关。




图 2.2 车辆 MOCACC 控制系统的关键技术

新一代 ACC 系统的控制目标中，驾驶员期望车距特性、纵向乘坐舒适性、驾驶员动态跟车特性以及驾驶员期望跟踪误差范围均与驾驶员跟车特性相关。目前，现有的驾驶员跟车特性模型多用于微观交通流领域，存在结构复杂、参数众多、包含强非线性环节等缺点，很难在 ACC 控制算法设计中得以应用。因此，针对上述驾驶员跟车特性，建立模型结构简洁、参数物理含义明确且可准确描述驾驶员跟车行为的数学模型是本文的难点之一。

跟车预测模型的设计基础是跟车系统动力学模型。受 MPC 高计算复杂度的限制，车辆对象建模中，不易使用强非线性方程描述车辆纵向动力学特性。而且，车辆和车间纵向动力学特性相互耦合，二者分离的建模方案难以描述前车加减速干扰对跟车系统性能的影响。因此，兼顾计算的实时性和模型的准确性，设计跟车系统动力学模型也是本文的重点。

MOCACC 性能指标的设计须满足两条原则：一是准确量化跟踪性能目标、

燃油经济性目标和驾驶员感受目标，反映三者之间的制约关系；二是采用结构简洁的代价函数和 I/O 约束，兼顾 MPC 在线优化的计算效率问题。已有的 ACC 性能指标仅针对跟踪性能目标建立，且代价函数和 I/O 约束的类型多种多样、无统一标准。而新一代 ACC 的性能指标中，跟踪性能与车间纵向动力学系统相关，燃油消耗量是车辆驱动系的状态，驾驶员感受涉及驾驶员自身的特性和车辆的运动轨迹，三者之间呈现复杂的非线性关系，这增加了各控制目标数学量化的难度。因此，MOCACC 性能指标的设计技术也是本文的难点之一。

车辆 MOCACC 的实车应用中，受 MPC 本身特点的限制，其控制方案存在三类实用化问题，即对模型失配的低鲁棒性、最优控制量的非可解和在线优化的高计算复杂度。这三类实用化问题，不仅会降低闭环系统的最优性，影响多目标协调控制功能的实现，而且可能导致自适应巡航控制律的中断。现有文献提供的处理方法，如 Min-Max 法、限制初始状态法和多参数规划法，不适用于车辆新一代 ACC 系统。因此，研究三类实用化问题的处理方法，是车辆 MOCACC 控制算法实车应用的关键。

第3章 驾驶员跟车特性的分析与非线性建模

已有驾驶员跟车模型多用于微观交通流等领域,存在参数多、结构复杂、含强非线性项等缺点,难以用于 ACC 控制算法的设计过程。为此,本章以中国驾驶员自然实验数据为基础,首先建立符合中国交通流特征的跟车工况判别准则,选取跟车工况的数据集。其次,分析驾驶员的期望车距特性,建立二次型期望车距模型;为描述驾驶员控制增益的时变非线性,分析驾驶员对跟踪误差的敏感度,建立具有准线性结构且参数物理含义明确的驾驶员跟驰模型。然后,为消除驾驶随机性对跟驰模型验证的影响,提出基于假设检验理论的模型比较验证方法,评价所提出模型的精度和适用度。最后,分析驾驶员期望跟踪误差特性,利用统计方法建立它的一维分布模型和二维分布模型,为 MOCACC 性能指标的设计奠定基础。

3.1 驾驶员特性实验及其有效数据集选取

本节首先介绍驾驶员特性实验车和道路实验工况;其次针对实验平台传感器的特点,设计纵向加速度的离线平均滤波器,剔除加速度信号的中、高频噪声;然后针对中国道路交通流特征,提出一种跟车工况的判别准则,并据此选取跟车工况的数据集,为后续特性分析和建模工作奠定基础。

3.1.1 驾驶员特性道路实验介绍

本文使用的实验数据来源于清华—Nissan 驾驶员特性研究项目。所开发的驾驶员特性实验车装有激光雷达、GPS 接收机、加速度计、工控机以及附属的供电设备。其基本结构如图 3.1 所示。

该实验车中,激光雷达探测车辆前方的交通流信息,计算目标车与自车的车间距离和相对车速,并将该信息发送至 CAN 总线 A。加速度计测量自车纵向、横向和垂向加速度,由工控机的三路 A/D 采样、量化,转化为数字信号。除了车辆加速度外,驾驶员操作信息和车辆状态信息由原车传感器测量,经原车 CAN 总线 B 发送至工控机。GPS 接收机测量车辆的绝对运动信息,通过 RS232 串行通讯总线发送至工控机。工控机中,基于 Labview 和 Visual C++平台开发的数据

采集软件，分别接收 CAN 总线 A、CAN 总线 B、A/D 采样和 RS232 串行通讯的数据，经初步数据融合后，按照 $T_s=0.1\text{s}$ 的周期进行保存，即频率为 $f_s=10\text{Hz}$ 。




图 3.1 驾驶员特性实验平台车的基本结构

所保存的数据中，与驾驶员纵向特性相关的变量共 9 个，如表 3.1 所示。

表 3.1 与驾驶员纵向特性相关的变量

编号	变量	符号	单位	编号	变量	符号	单位
1	时间	t	s	6	制动压力	P_{brk}	MPa
2	车间距离	d	m	7	节气门开度	α_{thr}	%
3	相对车速	Δv	m/s	8	挡位	i_g	--
4	自车车速	v_f	m/s	9	发动机转速	ω_e	rpm
5	自车加速度	a_{fm}	m/s^2				

项目中，参与实验的中国驾驶员共 33 名，含男性 26 名，女性 7 名，皆为有经验的熟练驾驶员。实验道路包括城市普通路、城市快速路和高速公路三种类型。城市普通路包括北京市区的学院路和清华周边的道路，城市快速路包括北京市区的西四环路和南四环路，高速公路为京石高速公路。

实验过程中，要求驾驶员按照自己的驾驶习惯正常驾驶实验车。行车工况以跟随前方车辆为主，根据交通流的情况，可进行换道、超车、接近或自由驾驶等操作。

3.1.2 离线平均滤波器的设计

跟车特性分析与建模中，加速度计输出的纵向加速度是关键变量。道路实验中，受发动机和路面激励的影响，车身不可避免存在一定程度的纵向振动和俯仰运动。加速度计会如实记录纵向振动量和俯仰运动引起的重力分量，以中、高频噪声的形式存于测量信号。这对驾驶员跟车特性的建模，尤其模型参数的辨识，是非常不利的。故使用实验数据之前，应首先对纵向加速度信号进行滤波，剔除中、高频噪声。

数字滤波器的设计中，兼顾滤波器的复杂性和滤波效果，常选择一阶、二阶低通滤波器或在线平均滤波器等^[111]。这些滤波器的优点是可以在线实时滤波，缺点是具有较大的相位延迟。对加速度信号进行滤波时，相位延迟引入的相移会嵌入到驾驶员跟车特性中，使实验数据无法准确反映驾驶员的真实特性。然而，驾驶员特性的研究中，因所有数据皆提前记录，不必使用具有实时功能的在线滤波器。为此，设计一种无相位延迟的离线平均滤波器。滤波器的数学描述为：

$$a_f(i) = \frac{1}{2N_f + 1} \sum_{j=-N_f}^{N_f} a_{fm}(i+j) \quad (3-1)$$

式(3-1)中， a_f 为滤波后的纵向加速度， N_f 为离线平均滤波器的单边长度。同在线平均滤波器类似，离线平均滤波器属于低通滤波器，其主瓣单边带宽为 $2\pi f_s/(2N_f+1)$ ，噪声减少比(NNR, Noise Reduction Ratio)为 $1/(2N_f+1)$ ，不同之处在于在线平均滤波器的相位延迟为 $N_f \cdot T_s$ ，而离线平均滤波器的相位延迟为零。

一般来说，“人-车”构成的车辆纵向运动系统为低通系统，其截止频率低于1 Hz^[112]。为避免滤波器的阻带过低，衰减驾驶员的动态跟车特性，设置离线平均滤波器的主瓣单边带宽大于“人-车”系统带宽的3倍，即式(3-1)的单边长度 N_f 满足：

$$N_f < \left\lceil \frac{\pi}{3T_s} - 0.5 \right\rceil + 1 = 10 \quad (3-2)$$

以一阶低通滤波器为对照滤波器，验证离线平均滤波器对纵向加速度信号的滤波效果。二类滤波器的参数如表3.2所示，滤波效果如图3.2所示。

表 3.2 加速度信号滤波器的参数

一阶低通滤波器		离线平均滤波器	
时间常数	截止频率	N_f	主瓣单边带宽
1.2 s	5.2 Hz	6	4.8 Hz

图 3.2 中，灰线为纵向加速度原始信号，实线为离线平均滤波器的输出，虚线为一阶低通滤波器的输出。由图 3.2 知，两种滤波器均可有效剔除加速度信号的中、高频噪声。与一阶低通滤波器相比，离线平均滤波器几乎无相位延迟，所输出的信号可更加准确地反映驾驶员的真实跟车特性。




图 3.2 两类滤波器的效果验证

3.1.3 跟车工况的有效数据集选取

驾驶员特性道路实验中，受驾驶随机性、道路结构、交通控制等因素影响，行车工况非常复杂。所记录的实验数据不仅包括跟车过程，而且包含自由驾驶、接近、换道、超车、前车切入、前车切出等工况。然而，只有跟车工况的数据段对跟车特性的研究有用，因此，需要从庞杂的道路实验数据中抽取跟车工况数据段。美国 Southampton 大学的 Piao J 等人曾给出一种用于美国高速公路交通流的跟车工况判别准则^[116]：

- (1) 自车纵向加速度处于 $\pm 1 \text{ m/s}^2$ 范围之内；
- (2) 连续跟车过程的时间长度不短于 30 s；
- (3) 无起步或停车工况，即车速大于零；

本文实验数据来源于中国城市、城际道路的交通流。分析原始数据发现，

国内道路交通流存在以下特点：第一、车辆换道较频繁，切入切出工况较多，驾驶员难以保持长时间的跟车过程；第二、存在大量自由驾驶、接近和紧急制动的工况；第三、持续跟车工况的自车加速度多处于 $\pm 0.3 \text{ m/s}^2$ 之内。Piao J 等人的判别准则一是未对车间距离和相对车速的限制，难以区分自由驾驶、切入切出和跟车三类工况；二是自车加速度的阈值过大，易把接近或紧急制动工况误做跟车工况；三是连续跟车时间过长，因此，无法直接作为中国驾驶员跟车工况的判别准则。

为此，本文综合相对车速、车间距离、自车车速、自车加速度和跟车时间五种变量，制定符合中国道路交通流特征的跟车工况判别准则：

(1) 为排除自由驾驶工况，要求自车前方存在有效目标车，车间距离满足：

$$1.5 \leq d(i) \leq 5 v_f(i) + 10 \quad (3-3)$$

(2) 为排除前车切入切出工况，要求相邻采样时刻的车距满足：

$$|d(i) - d(i-1)| < 5 \quad (3-4)$$

(3) 为排除接近和紧急制动工况，要求相对车速满足：

$$-5 < \Delta v(i) < 5 \quad (3-5)$$

(4) 连续跟车过程中，大于 80% 的数据点满足：

$$|a_f(i)| < 0.3 \quad (3-6)$$

且所有数据点的自车加速度处于 $\pm 1 \text{ m/s}^2$ 之内；

(5) 连续跟车时间大于 10 秒，且无停车、起步过程，即自车车速大于零。

按照上述判别准则，对各驾驶员的实验数据进行处理，选取跟车工况的数据段。以编号为 1、2 和 3 的驾驶员为例，说明跟车工况数据段的选取结果，如表 3.3。下文将以这三名驾驶员为例说明特性分析和建模的结果。为保障驾驶员特性研究过程的客观性，将跟车工况数据段分为两组，称为 A 组数据集和 B 组数据集，分别用于驾驶员特性的建模和驾驶员模型的验证。对于每名驾驶员，从跟车工况数据段中，随机抽取 100 段组成 A 组数据集，剩余的数据段组成 B 组数据集。

表 3.3 驾驶员跟车工况的数据集

编号	段数	总长度(min)	平均长度(s)	平均车速(m/s)
1	179	98.2	32.9	15.2
2	169	79.7	28.3	15.9
3	182	106.7	35.2	16.2

为便于下文叙述，对于各名驾驶员，A 组数据集记为 \mathbf{D}^A ，段数记为 N_A ，第 n 段数据记为 \mathbf{D}_n^A ，第 n 段数据的长度为 φ_n^A 。同理，B 组数据集记为 \mathbf{D}^B ，段数记为 N_B ，第 n 段数据记为 \mathbf{D}_n^B ，第 n 段数据的长度为 φ_n^B 。

3.2 驾驶员跟车特性的建模和参数辨识

3.2.1 驾驶员期望车距特性的分析与建模

跟车过程中，驾驶员的期望车距特性采用期望车距模型描述。已有期望车距模型有固定车距模型^[113]、固定时距模型^[7]、线性期望车距（LDC, Linear Desired Clearance）模型^[114]及其非线性车距模型^[115]等。韩国 Hanyang 大学 Yi K 等人指出，驾驶员的期望车距与自车车速的关系不是线性的，而是近似于二次函数形式，并建立二次型期望车距模型（QDC, Quadratic Desired Clearance model）^[27]：

$$d_{des} = av_f^2 + bv_f + c \quad (3-7)$$

式（3-7）中， d_{des} 是期望车距， a, b, c 为模型系数。QDC 模型虽然对跟车特性的描述更加准确，但是其系数 a, b, c 缺乏明确的物理含义，基于该模型设计的 ACC 算法难以让用户根据自己的需求进行参数调整。为此，将式（3-7）的二次项在平均车速处 Taylor 展开，整理为各系数具有明确物理含义的 QDC 模型：

$$d_{des} = rv_f(v_f - v_{fmean}) + \tau_h v_f + d_0 \quad (3-8)$$

式（3-8）中， r 为二次项系数， τ_h 为车间时距， d_0 为停车距离， v_{fmean} 为跟车工况的平均车速。三者与原 QDC 模型系数的关系为：

$$\begin{aligned} r &= a \\ \tau_h &= b + av_{f\text{mean}} \\ d_0 &= c \end{aligned} \quad (3-9)$$

易知,当自车车速位于中速区域时,即 v_f 接近 $v_{f\text{mean}}$,则式(3-8)的二次项近似为零,QDC模型退化为LDC模型。这说明,QDC模型的参数 τ_h 和 d_0 与LDC模型的车间时距和停车距离具有近似的物理含义,即 d_0 反映了停车时的车间距离, τ_h 描述了期望车距与车速的关系,反映驾驶员跟车过程的保守程度。

以A组数据集 \mathbf{D}^A 为数据点,利用最小二乘法^[117]对QDC模型进行参数辨识,如表3.4所示。

表 3.4 QDC 模型的参数值

驾驶员	二次项系数	车间时距	停车距离
1	0.054	1.68	2.9
2	0.065	1.73	3.5
3	0.033	1.58	3.4
平均值	0.051	1.66	3.3

为比较QDC模型和LDC模型的优缺点,基于同一数据集,利用最小二乘法对LDC模型进行参数辨识。图3.3是三名驾驶员的辨识结果,实线为QDC模型,虚线为LDC模型,灰点为 \mathbf{D}^A 的数据点。

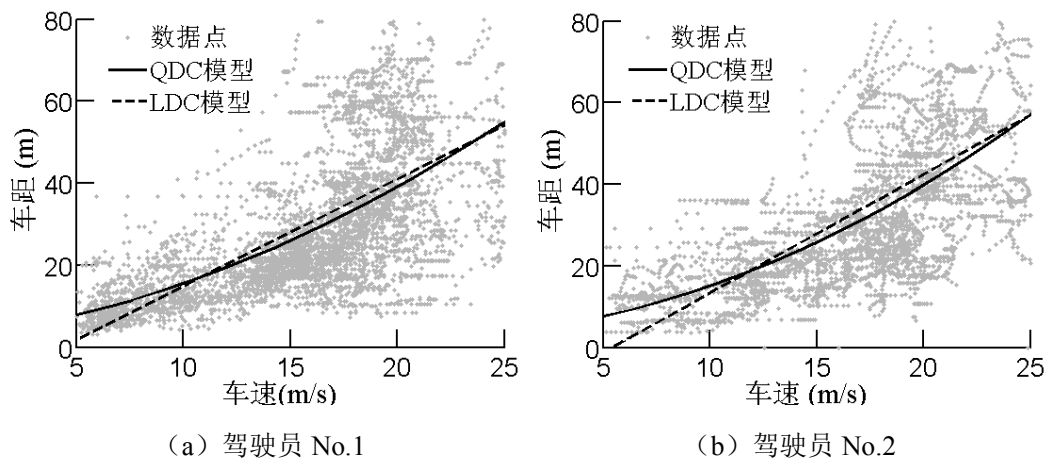



图 3.3 期望车距模型与实验数据的对比



(c) 驾驶员 No.3

图 3.3 期望车距模型与实验数据的对比 (续)

由图 3.3 知, 期望车距和实际车速不是标准的线性关系, 随着车速增加, 驾驶员的期望车距增加趋势变快。QDC 模型中, 系数为正值的二次项可使期望车距曲线的曲率为正值, 全速范围内, 与驾驶员实验数据更加吻合。限于二次项的缺失, LDC 模型不能准确反映这一特性。因此, 与 LDC 模型相比, QDC 模型与实验数据的接近程度更高, 可更好地描述驾驶员期望车距特性。

3.2.2 驾驶员对跟踪误差的敏感度分析

动态跟车特性的研究基础是跟驰模型。ACC 控制算法的设计中, 为便于融合驾驶员跟驰特性, 多采用线性跟驰模型 (LCF, Linear Car-Following model) 描述驾驶员动态跟车特性, 如式 (1-3) 所示。式 (1-3) 中, Δv 为相对车速, Δd 为车距误差, 定义为:

$$\begin{aligned}\Delta v &= v_p - v_f \\ \Delta d &= d - d_{des}\end{aligned}\quad (3-10)$$

式 (3-10) 中, v_p 为前车速度, d 为实际车距, d_{des} 为期望车距。已有研究表明, 驾驶员控制增益受驾驶员个体特征、道路状况以及交通流的影响, 是时变参数, 而非固定值^[30]。Gazis 等人指出刺激-反应模型的控制增益近似反比于车间距离^[30]。Edie 等人发现若假定控制增益正比于车速且反比于车距平方, 跟驰模型的精度更好^[30]。这表明, 驾驶员跟车过程中, 控制增益随车速或车距等

变量时变。乘用车驾驶员的跟车过程中，这一现象也非常明显。由于乘用车具有较低的驱动功率，高速工况下风阻损耗功率占整车功率的比重大，不同速度下车辆加速性能差异较大，因此车速的大小显著影响驾驶员对油门和制动的控制量。图 3.4 是 2 号驾驶员所有道路实验的车速—加速度分布图。其中，实点是实验数据点（每隔 10 秒选一点），实线是加速度的 3σ 上下界。由实线知，高速工况的加速度 3σ 值约为低速工况的一半，低速工况下驾驶员倾向于采用大的加速度，而高速工况下倾向于采用小的加速度。这说明：相同跟踪误差下，低速工况下驾驶员具有采取大控制增益的可能性，而高速工况下则有减小控制增益的可能性。




图 3.4 驾驶员的车速—加速度分布图

为定量描述驾驶员控制增益随车速时变的特性，引入驾驶员对跟踪误差敏感度的概念。对于相对车速和车距误差，分别定义驾驶员对车速误差敏感度（SVE, Sensitivity to Velocity Error）和驾驶员对车距误差敏感度（SDE, Sensitivity to Distance Error）：

$$\begin{aligned} SVE &\propto \frac{K_V(v_f)}{k_V} \\ SDE &\propto \frac{K_D(v_f)}{k_D} \end{aligned} \quad (3-11)$$

式 (3-11) 中，符合“ \propto ”代表“正比于”， SVE 表示驾驶员对速度误差的敏感度值， SDE 代表驾驶员对车距误差的敏感度值， $K_V(v_f)$ 、 $K_D(v_f)$ 表示车速为 v_f 时的控制增益， k_V 、 k_D 表示平均车速时的控制增益，即 $k_V = K_V(v_{fmean})$ ，

$k_D = K_D(v_{fmean})$ ，称为名义控制增益。为便于下文叙述，驾驶员对车速误差敏感度和驾驶员对车距误差敏感度统称为“驾驶敏感度”。由驾驶敏感度的定义式(3-11)知，驾驶敏感度反映了驾驶员控制增益随车速的变化趋势。

为利用道路实验数据量化驾驶敏感度，假设车距误差 Δd 和相对车速 Δv 是独立的，二者之间无影响。首先，利用道路实验数据量化驾驶员对相对车速的敏感度。为建立量化方法，分析 SVE 与 Δv 的关系。因 Δd 和 Δv 相互独立，忽略式(1-3)中 Δd 对自车加速度 a_f 的影响，令 Δd 恒为零。综合式(1-3)和式(3-11)，有 SVE 与 Δv 的关系式：

$$SVE^{-1} \propto k_v \cdot \frac{\Delta v}{a_f}, \text{ 当 } \Delta d = 0 \quad (3-12)$$

因为名义控制增益 k_v 为常数，当自车加速度 a_f 固定时，由上式知， SVE 的倒数近似正比于 Δv 。这表明，在同一加速度水平下， SVE 值与 Δv 直接关联。若利用实验数据统计在不同车速下 Δv 的变化趋势，则可直接反映 SVE 值随车速的变化趋势。注意：利用 Δv 的统计量反映 SVE 值的两个基本前提是：(1)所使用的数据点中， Δd 恒为零（或者 Δd 近似为零）；(2)所使用的数据点中，自车加速度 a_f 为某一固定值（或者 a_f 处于某一加速度水平上）。利用这一思想建立 SVE 的数学量化方法，步骤如下：

第一步：在A组数据集 \mathbf{D}^A 内，以下式为条件，选取用于量化 SVE 的数据点，记为集合 \mathbf{D}_{SVE}^A ：

$$\mathbf{D}_{SVE}^A \triangleq \left\{ i \mid a_{fmin} < |a_f(i)| < a_{fmax}, \Delta d_{min} < d(i) < \Delta d_{max}, i \in \mathbf{D}^A \right\} \quad (3-13)$$

式(3-13)中， $a_{fmin} = 0.15 \text{ m/s}^2$ 为加速度的下界， $a_{fmax} = 0.3 \text{ m/s}^2$ 为加速度的上界，用于选择同一加速度水平的数据点；式(3-13)中， $\Delta d_{min} = -1 \text{ m}$ 为车距误差下界， $\Delta d_{max} = 1 \text{ m}$ 为车距误差的上界，用于选择 Δd 接近零的数据点。

第二步：在车速范围 $[5\text{m/s}, 30\text{m/s}]$ 内，将车速等分为14个区间，记第 m 区间的车速下界为 v_{fmin}^m ，上界为 v_{fmax}^m ，中心车速为 v_{fmean}^m 。将集合 \mathbf{D}_{SVE}^A 的数据点，按照车速所在的区间进行分组，记第 m 组的数据点数为 ϕ_{SVE}^m ，数据点构成集合 $\mathbf{D}_{SVE}^{A,m}$ ：

$$\mathbf{D}_{SVE}^{A,m} \triangleq \{i | v_{f \min}^m < v_f(i) < v_{f \max}^m, i \in \mathbf{D}_{SVE}^A\} \quad (3-14)$$

第三步：在集合 $\mathbf{D}_{SVE}^{A,m}$ 内计算相对车速的有效值，作为第 m 区间中心车速处 SVE^{-1} 的量化值，即：

$$SVE^{-1}(v_{f \text{mean}}^m) = \sqrt{\frac{1}{\varphi_{SVE}^m} \sum \Delta v^2(i), i \in \mathbf{D}_{SVE}^{A,m}} \quad (3-15)$$

对于三名驾驶员， SVE^{-1} 的量化值如图 3.5 的柱状图所示。




图 3.5 驾驶员对 Δv 的敏感度

SDE 的量化方法中，除第一步的量化数据集选取条件外，其他与 SVE 的

化方法类似。以下式为条件，选取用于量化 SDE 的数据点，记为集合 \mathbf{D}_{SVE}^A ：

$$\mathbf{D}_{SDE}^A \triangleq \left\{ i \mid a_{f \min} < |a_f(i)| < a_{f \max}, \Delta v_{\min} < v(i) < \Delta v_{\max}, i \in \mathbf{D}^A \right\} \quad (3-16)$$

式 (3-16) 中， $\Delta v_{\min} = -0.2 \text{ m/s}$ 为相对车速下界， $\Delta v_{\max} = 0.2 \text{ m/s}$ 为相对车速的上界，用于选择相对车速接近零的数据点。对于三名驾驶员， SDE^{-1} 的量化值如图 3.6 的柱状图所示。




图 3.6 驾驶员对 Δd 的敏感度

跟车过程中， Δv 和 Δd 的均值为零，其有效值等价于标准差，而后者反映数据的离散程度。跟踪误差的分布越离散，说明驾驶员对误差的容许程度越大，即对误差的敏感性越小。这表明利用有效值反映驾驶敏感度是合理的。为简化

驾驶敏感度的表达形式，以线性模型描述 SVE^{-1} 、 SDE^{-1} 量化值与车速的关系，称为 SVE 和 SDE 模型。模型的数学形式如下式：

$$\begin{cases} SVE^{-1} = k_{SVE}v_f + d_{SVE} \\ SDE^{-1} = k_{SDE}v_f + d_{SDE} \end{cases} \quad (3-17)$$

式 (3-17) 中， k_{SVE} ， k_{SDE} 是一次项系数， d_{SVE} ， d_{SDE} 为常数项系数，由最小二乘法辨识得到。SVE 和 SDE 模型分别如图 3.5、图 3.6 的星实线所示。由图 3.5 的星实线知，乘用车驾驶员对相对车速的敏感度值近似水平，说明驾驶员对相对车速的敏感度与车速关系不大，即不同车速下 Δv 的控制增益基本一致。同理，由图 3.6 的星实线知，乘用车驾驶员对距离误差的敏感度值受车速影响较大，随着车速的增加而敏感度值降低。由驾驶敏感度的定义式知：驾驶员对 Δd 的控制增益在低速工况较大，随车速升高呈减小的趋势。这与上文的定性分析是一致的。由 (3-11) 知，驾驶敏感度用于描述驾驶员控制增益随车速的变化趋势，是相对量，其绝对值大小并无实际意义，故在平均车速下将 SVE 和 SDE 模型归一化。归一化的参数如表 3.5 所示。

表 3.5 SVE 和 SDE 模型的归一化参数

驾驶员	SVE		SDE	
	k_{SVE}	d_{SVE}	k_{SDE}	d_{SDE}
1	0.005	0.91	0.07	-0.28
2	0.012	0.79	0.07	-0.31
3	-0.002	1.03	0.05	0.22
平均值	0.005	0.91	0.06	-0.12

3.2.3 基于驾驶敏感度的跟驰模型结构

由上文知，驾驶敏感度反映驾驶员控制增益随车速的变化趋势。使用驾驶敏感度模型修正线性跟驰 (LCF) 模型，使模型系数随车速自适应变化，可改善 LCF 模型模拟不同车速下的驾驶员动态跟车特性的精度。为此，综合式 QDC 模型 (3-8)、SVE/SDE 的定义式 (3-11)、SVE/SDE 模型 (3-17) 和线性跟驰模型 (1-3)，有乘用车驾驶员的跟驰模型：

$$\begin{aligned}
 a_f &= SVE \cdot k_V \cdot (v_p - v_f) + SDE \cdot k_D \cdot (d - d_{des}) \\
 d_{des} &= r v_f (v_f - v_{fmean}) + \tau_h v_f + d_0 \\
 SVE^{-1} &= k_{SVE} v_f + d_{SVE} \\
 SDE^{-1} &= k_{SDE} v_f + d_{SDE}
 \end{aligned} \tag{3-18}$$

式 (3-18) 中, k_V 和 k_D 为名义控制增益。为区别已有的跟驰模型, 式 (3-18) 称为修正的线性跟驰模型 (MLCF, Modified Linear Car-Following model)。跟驰模型的输入为 Δv , d 和 v_f , 输出为自车加速度 a_f , w 代表驾驶员的不确定性。尽管 MLCF 模型属于非线性环节, 但 QDC 模型的二次项、 SVE 和 SDE 可分别看作车间时距、 k_V 和 k_D 的参数误差, 说明 MLCF 模型仍具有近似线性的结构, 适合融于自适应巡航控制算法的设计过程。而且, 模型的所有参数具有明确物理含义, 便于用户根据需求调节参数。图 3.7 是基于 MLCF 模型的跟车系统结构。




图 3.7 基于 MLCF 模型的跟车系统结构

图 3.7 所示的跟车系统, 输入为跟车工况数据集的前车车速 v_p , 输出为自车加速度, 自车车速和车间距离。为区别道路实验数据的同名变量, 记图 3.7 跟车系统输出的自车加速度、自车车速和车间距离为 a_{fCF} 、 v_{fCF} 和 d_{CF} 。若前车车速 v_p 属于 A 组数据集 \mathbf{D}^A , 跟车系统输出构成的集合记为 \mathbf{D}_{CF}^A 。若前车车速 v_p 属于 B 组数据集 \mathbf{D}^B , 跟车系统输出构成的集合记为 \mathbf{D}_{CF}^B 。

3.2.4 驾驶员跟驰模型的参数辨识

目前, 跟驰模型的参数多由驾驶员实验数据辨识得到, 常用方法有最小二乘法^[112]和最小化误差法^[27]。前者的基本思路是将跟车模型看作黑箱, 输入是 Δv

和 Δd ，输出是 a_{fCF} ；将道路实验的 Δv 和 Δd 输入跟驰模型，最小化模型输出 a_{fCF} 与实测 a_f 的误差，求解模型参数。后者的基本思路是将包含跟驰模型的跟车系统（如图 3.7）看作黑箱，输入是前车加速度 a_p ，输出是 a_{fCF} 、 v_{fCF} 和 d_{CF} ；将道路实验的 a_p 输入跟车系统，最小化跟车系统输出与实测 a_f 、 v_f 和 d 的误差，求解模型参数。两种方法的差别在于黑箱不同。如图 3.7 所示，跟车系统具有反馈回路，模型输出的 a_f 影响其输入 Δv 和 Δd （或者说 v_f 和 d 也可），即最小化 a_f 的误差不等于 Δv 和 Δd 最接近驾驶员实验数据，而 ACC 等系统以调整 $v_f \rightarrow v_p$ 和 $d \rightarrow d_{des}$ 为目标，对跟踪误差有要求，故应用于 ACC 控制算法的跟驰模型要求 v_f 、 d 与实车实验数据尽量吻合，适合采取最小化误差法辨识参数。

为综合量化跟车系统输出与道路实验测量值的误差，定义优化指标 E ：

$$E = \mathbf{W}^T \cdot \mathbf{e}_{CF} \quad (3-19)$$

式 (3-19) 中， $\mathbf{W} \in R^3$ 是权向量， $\mathbf{e}_{CF} \in R^3$ 称为跟驰模型与 A 组数据集 \mathbf{D}^A 的误差向量：

$$\begin{aligned} \mathbf{W} &= [w_1, w_2, w_3]^T \\ \mathbf{e}_{CF} &= \frac{1}{N_A} \sum_{n=1}^{N_A} \mathbf{e}_{CFn} \\ \mathbf{e}_{CFn} &= [f(a_f(i)), f(v_f(i)), f(d(i))]^T, i \in \mathbf{D}_n^A \end{aligned} \quad (3-20)$$

式 (3-20) 中， \mathbf{e}_{CFn} 称为跟驰模型与 A 组第 n 段数据的误差向量，其元素分别代表跟车系统输出 a_{fCF} 、 v_{fCF} 、 d_{CF} 与实测 a_f 、 v_f 、 d 的误差， \mathbf{W} 为相应的权矩阵，根据经验选取为 $w_1=0.9$ ， $w_2=0.09$ 和 $w_3=0.01$ 。 $f(x)$ 是以符号 x 为自变量的函数，定义为：

$$f(x) \triangleq \sqrt{\frac{1}{\varphi} \sum_{i=1}^{\varphi} [x_{CF}(i) - x(i)]^2}, x \in \{a_f, v_f, d\} \quad (3-21)$$

式 (3-21) 中， φ 为集合 \mathbf{D}_n^A 的数据点数。式 (3-20) 和 (3-21) 中，下标 CF 表示图 3.7 所示的跟车系统， x 的定义域为 a_f 、 v_f 和 d 。最小化性能指标 E ，得到名义控制增量 k_V 和 k_D ：

$$\begin{aligned} [k_V, k_D] &= \arg \min_{k_V, k_D} E \\ \text{subj. to: } &k_V > 0, k_D > 0 \end{aligned} \quad (3-22)$$

参照文献[118], 采用 Nelder-Mead 单纯形法对最优化问题 (3-22) 进行数值求解, 获得 MLCF 模型的名义控制增益 k_V^* 和 k_D^* 。三名驾驶员的名义控制增益如表 3.6 所示。

表 3.6 MLCF 模型的参数值

驾驶员	k_V^*	k_D^*
1	0.185	0.0164
2	0.147	0.0176
3	0.155	0.0268
平均值	0.162	0.0203

因为 MLCF 模型本身为非线性系统, 问题 (3-22) 可能存在局部极小值。为检验求解结果的全局最优性, 以名义控制增益为中心, 在区域 $k_V \in [0.1k_V^*, 10k_V^*]$, $k_D \in [0.03k_D^*, 30k_D^*]$ 内绘制优化指标 E 的等高线图, 如图 3.8。




图 3.8 性能指标 E 的等高线图 (仅 1、2 号驾驶员)

因三名驾驶员的等高线图类似, 图 3.8 仅展示 1 和 2 号驾驶员的结果。图中, 随着灰度值的增加, 总体误差 E 值增大, 星点为名义参数 k_V^* 和 k_D^* 的位置。易知, 在相当大范围内, (k_V^*, k_D^*) 均是 E 的极小值位置。工程应用中, (k_V^*, k_D^*) 可

近似全局最优解。

利用 B 组数据集验证 MLCF 模型的准确程度，图 3.9 是与 1 号驾驶员一数据段的对比图，图 3.10 是与 3 号驾驶员一数据段的对比图。图 3.9 和图 3.10 中，(a) (b) (c) 分别表示自车加速度、自车速度和车间距离。由图 3.9 和图 3.10 知，跟车系统输出的加速度、自车车速和车间距离接近实车测量结果，可反映驾驶员跟车过程的动态特性。由图 (b) 和 (c) 知，模型对自车车速的近似程度优于车间距离，这是因为实际驾驶中，驾驶员对速度误差的敏感度高于对距离误差的敏感度。与车距相比，驾驶员对车速的控制更加规范，易于使用准确模型描述，而驾驶员对车距控制的随意性较大，难以使用准确模型描述，故 MLCF 模型对车距的近似程度较差。




图 3.9 MLCF 模型与 1 号驾驶员实验数据的对比

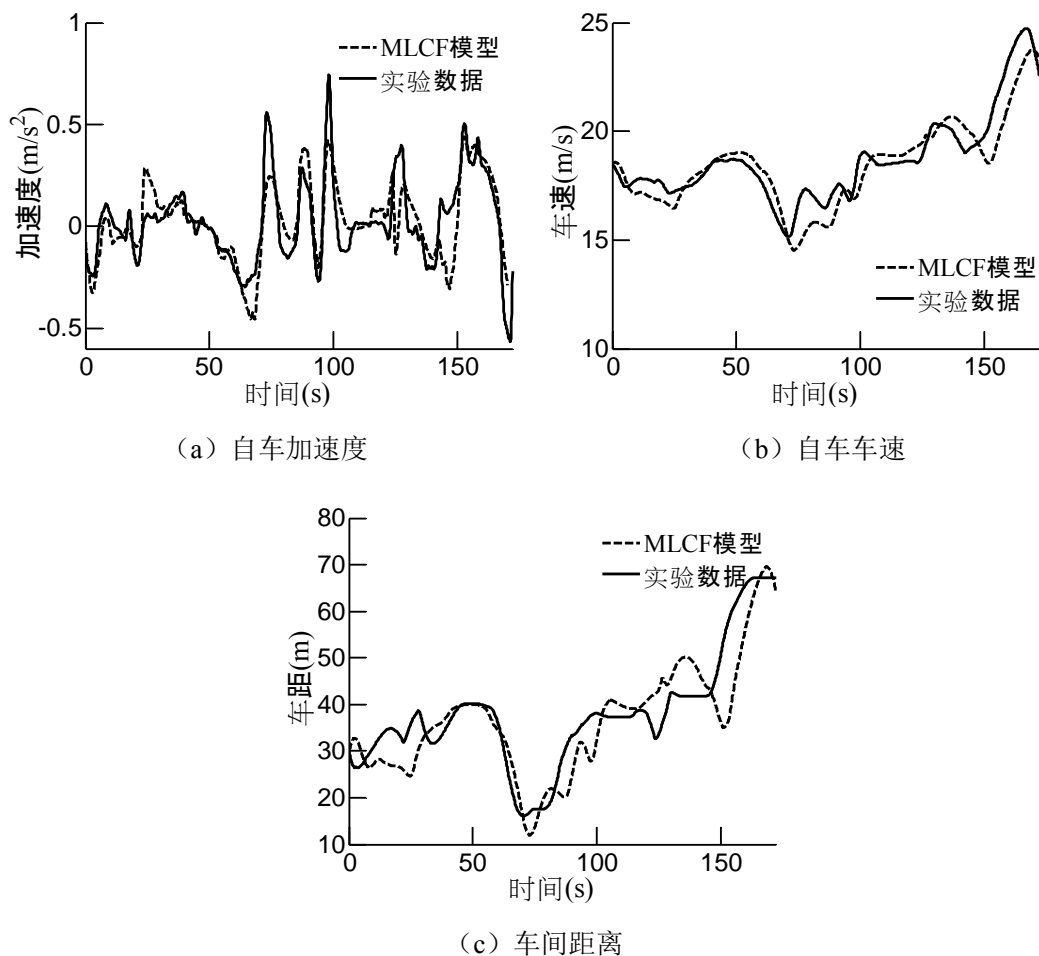


图 3.10 MLCF 模型与 3 号驾驶员实验数据的对比

3.3 基于假设检验理论的跟驰模型比较验证

由节 3.1.3 知, 用于评价跟驰模型性能的数据集由多段跟车工况数据组成。受道路差异和交通流变化多样等因素的影响, 驾驶员的操作具有相当大的随意性, 不同数据段所包含的驾驶员跟车特性是不同的。因此, 描述驾驶员平均特性的跟驰模型与各数据段的误差是不一致的, 且误差呈现一定的随机分布性, 这极大影响跟驰模型性能的定量评价。

为减小驾驶随机性对模型性能评价的影响, 判断跟驰模型优劣时, 必须考虑模型误差的分布特性。模型误差的均值和方差是评价跟驰模型优劣的两个重

要变量。前者反映了跟驰模型与驾驶员跟车特性的接近程度，后者反映了跟驰模型对不同工况数据段的适应度。

然而，单纯使用均值和方差的大小判断模型的优劣，属于主观评价，易受个人经验影响。若以一个已有跟驰模型为参考模型，利用相同的实验数据对两种模型进行对比性检验，可获得相对客观的评价。为此，借鉴概率统计思想，本文提出一种基于假设检验理论的跟驰模型比较检验方法，通过比较模型误差的总体均值和总体方差，评价两种模型的相对优劣。

3.3.1 模型误差的均值与方差分析

以 ACC 设计中常用的 LCF 模型为参考模型。参考模型的参数辨识方法同 MLCF 模型，结果如表 3.7。

表 3.7 LCF 模型的参数值

驾驶员	K_V^*	K_D^*
1	0.164	0.0130
2	0.144	0.0127
3	0.180	0.0324

为应用假设检验理论，定义两个随机变量为 e_M 和 e_L ，其样本为 e_{Mn} 和 e_{Ln} ，分别为 MLCF 和 LCF 模型与 B 组第 n 数据段的加权误差：

$$\begin{aligned} e_{Mn} &= \mathbf{W}^T \cdot \mathbf{e}_{MLCFn} \\ e_{Ln} &= \mathbf{W}^T \cdot \mathbf{e}_{LCFn} \end{aligned} \quad (3-23)$$

式 (3-23) 中， \mathbf{e}_{MLCFn} 和 \mathbf{e}_{LCFn} 分别表示 MLCF 和 LCF 模型与 B 组第 n 数据段的误差向量，定义式同式 (3-20) 的变量 \mathbf{e}_{CFn} 。1 号、2 号和 3 号驾驶员中， e_M 和 e_L 的样本均值和样本方差，如表 3.8 所示。由表 3.8 知，三名驾驶员中， e_M 的样本均值皆小于 e_L 的样本均值。由于 B 组数据集的数据段数有限，样本均值的优势也可能是驾驶随机性造成的，故 e_M 样本均值小于 e_L 不能代表其总体均值也小于 e_L ，而总体均值的大小才是评价模型优劣的判断依据。这说明：直接利用样本均值差异说明模型精度的优劣过于武断。

表 3.8 随机变量 e_M 和 e_L 的统计量

驾驶员	B 组 段数	e_M		e_L	
		样本均值	样本方差	样本均值	样本方差
1	79	0.348	0.0152	0.369	0.0174
2	69	0.403	0.0198	0.428	0.0230
3	82	0.588	0.0573	0.616	0.0663

为进一步说明这一结论，绘制 1 号驾驶员，变量 e_M 和 e_L 的 20 个样本点，如图 3.11。图中，横坐标为数据段号，星点表示 e_M 的样本点，圈点表示 e_L 的样本点。

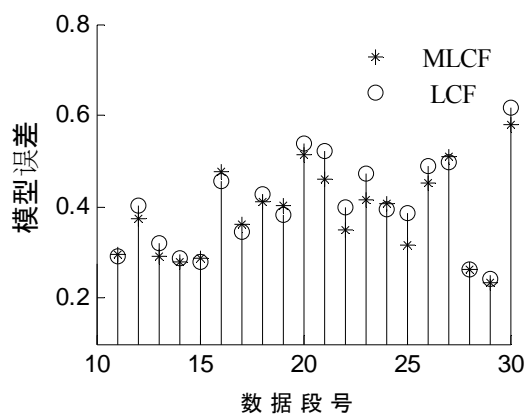


图 3.11 模型误差的样本点

由图 3.11 知，尽管 e_M 的样本均值皆小于 e_L 的样本均值，但是部分数据段处，MLCF 模型误差大于 LCF 模型误差，这也证明了上文的分析结论。同理，直接利用样本方差说明模型适用度也是不合理的。

3.3.2 基于 F-P 法的模型误差分布特性分析

由节 3.3.1 知，跟驰模型与实验数据的近似程度受驾驶随机性影响。本文拟采用 t 检验法和 F 检验法评价跟驰模型的性能，以消除驾驶随机性的影响。由文献[119]知，两种检验法的基本前提是被检验变量服从正态分布。为此，假设检验之前，首先分析随机变量 e_M 和 e_L 的分布特性。

一般来说，误差 e_M 和 e_L 分布特性是不规则的，而其对数值近似服从正态分

布。为证明这一论断，定义误差 e_M 和 e_L 的对数值为随机变量：

$$\begin{aligned} X_M &= \log(e_M) \\ X_L &= \log(e_L) \end{aligned} \quad (3-24)$$

式 (3-24) 中，因 $\log(\cdot)$ 为单调递增函数，所以， X_M 、 X_L 的比较关系与 e_M 、 e_L 的比较关系一致，对 X_M 、 X_L 的对比检验也可反映 MLCF 模型和 LCF 模型的相对优劣。表 3.9 是随机变量 X_M 与 X_L 的统计量。表中， X_M 与 X_L 的样本均值分别记为 \bar{X}_M 和 \bar{X}_L ，二者的样本方差分别记为 S_M^2 和 S_L^2 。

表 3.9 随机变量 X_M 和 X_L 的统计量

驾驶员	X_M		X_L	
	样本均值	样本方差	样本均值	样本方差
1	-1.11	0.118	-1.05	0.120
2	-0.965	0.122	-0.912	0.124
3	-0.593	0.118	-0.553	0.128

正态分布的非参数假设检验中，Fisher-Pearson (F-P) 法的应用最广泛。它的检验原理为：第一步，利用随机变量的统计量建立正态分布函数，假定随机变量服从该正态分布，构造零假设；第二步，计算随机变量的经验频数和理论频数，构造 χ^2 检验量；第三步，利用 χ^2 分布的特性，确定零假设的置信区间；第四步，利用 χ^2 检验量与置信区间的关系，判断随机变量是否服从正态分布。

基于该原理，假定 X_m 和 X_L 服从正态分布，构造零假设 H_0 ：

$$\begin{aligned} H_0 : X_M &\sim N(\bar{X}_M, S_M^2) \\ X_L &\sim N(\bar{X}_L, S_L^2) \end{aligned} \quad (3-25)$$

式 (3-25) 中， $N(\bar{X}_M, S_M^2)$ 表示以 \bar{X}_M 、 S_M^2 为参数的正态分布函数， $N(\bar{X}_L, S_L^2)$ 表示以 \bar{X}_L 、 S_L^2 为参数的正态分布函数，参数值如表 3.9 所示。

对于各驾驶员，统计 X_m 和 X_L 的频数分布特性。以 1 号驾驶员为例，图示 X_m 、 X_L 的频数分布特性，如图 3.12。




图 3.12 随机变量的频数分布图 (1 号驾驶员)

以图 3.12 (a) 为例, 说明 χ^2 检验量的构造方法。 X_M 频数直方图的区间数记为 m ; 第 i 区间的高度记为 n_i , 称为经验频数; 第 i 区间的中心处, 理论概率 p_i 由式 (3-25) 的正态分布函数计算得到, 而理论频数等于理论概率 p_i 与样本总数 N_B (N_B 也是 B 组数据集的数据段数) 的乘积, 记为 p_i , 如图 3.12 (a) 的实线。对于随机变量 X_M , 为定量判断经验频数与理论频数的接近程度, 构造 χ^2 检验量:

$$\chi^2 = \sum_{i=1}^m \frac{(n_i - N_B p_i)^2}{N_B p_i} \sim \chi^2(m - r - 1) \quad (3-26)$$

式 (3-26) 中, $r=2$ 为正态分布函数的参数个数。由 Fisher-Pearson 定理知^[120], χ^2 检验量服从自由度为 $m-r-1$ 的 χ^2 分布。F-P 法中, 置信度水平反映了零假设 H_0 成立的概率, 置信度水平越高, H_0 成立的概率越大。驾驶员跟驰模型的验证中, 因为 X_m 、 X_L 的分布特性仅是 t 检验和 F 检验的前提条件, 不影响总体均值和总体方差的检验过程, 因此, 对 H_0 成立的置信度不必过于苛刻。设定置信度水平 β 为 0.90, 据此确定零假设的置信区间:

$$\chi^2 \in (0, \chi_{\beta}^2(m - r - 1)] \quad (3-27)$$

式 (3-27) 中, 置信区间的上界为 $\chi_{\beta}^2(m-r-1)$, 置信区间的下界为 0。对三名驾驶员, 利用式 (3-26) 计算随机变量 X_M 和 X_L 的 χ^2 检验量, 利用 χ^2 分布表确定置信区间的上界 $\chi_{\beta}^2(m-r-1)$, 如表 3.10 和表 3.11 所示。

表 3.10 X_M 分布特性的检验结果

驾驶员	χ^2 检验量	β	自由度	$\chi^2_{\beta(m-r-1)}$
1	9.00	0.90	$m-r-1=16$	9.31
2	8.71	0.90	$m-r-1=16$	9.31
3	8.03	0.90	$m-r-1=16$	9.31

表 3.11 X_L 分布特性的检验结果

驾驶员	χ^2 检验量	β	自由度	$\chi^2_{\beta(m-r-1)}$
1	4.86	0.90	$m-r-1=16$	9.31
2	6.86	0.90	$m-r-1=16$	9.31
3	5.43	0.90	$m-r-1=16$	9.31

由表 3.10 知, 对于三名驾驶员, 随机变量 X_M 的 χ^2 检验量均小于置信区间的上界 $\chi^2_{\beta(m-r-1)}$, 即 χ^2 检验量处于 H_0 的置信区间之内, 这说明对于三名驾驶员, 接受 X_M 服从正态分布的假设。类似, 由表 3.11 知, 对于三名驾驶员样本, X_L 的 χ^2 检验量处于 H_0 的置信区间之内, 故也接受 X_L 服从正态分布的假设。

3.3.3 基于 t 检验法的模型误差均值比较

MLCF 模型和 LCF 模型的对比验证中, 计算模型误差的数据段来源于同一数据集, 所以对于每一名驾驶员来说, X_M 、 X_L 样本点的总数相同。由文献[120]知, 对 X_M 和 X_L 总体均值的检验属于配对问题。配对问题中, 因随机变量 X_M 和 X_L 近似服从正态分布, 且二者总体方差未知, 可使用 t 检验法对两随机变量的总体均值进行比较。

t 检验法的基本原理是: 首先, 以 X_M 、 X_L 的差定义随机变量 X , 利用 X 的样本均值和样本方差构造 t 检验量; 其次, 根据 X_M 、 X_L 之间待确定的关系建立零假设; 然后, 利用 t 分布的特性, 结合给定的显著性水平 α , 确定零假设的拒绝域; 最后, 根据 t 检验量是否满足拒绝域, 通过拒绝或接收零假设的方法, 判断 X_M 、 X_L 总体均值之间的关系。

按照上述原理, 首先定义随机变量 X 为 X_M 与 X_L 之差:

$$X = X_M - X_L \quad (3-28)$$

随机变量 X 的样本均值记为 \bar{X} ，样本方差记为 S^2 。由样本均值的定义易知：

$$\bar{X} = \bar{X}_M - \bar{X}_L \quad (3-29)$$

由文献[120]知，配对问题的 t 检验量由 X 的样本均值和样本方差构成。为直观反映 X_M 与 X_L 均值的关系，将式 (3-29) 代入 t 检验量的定义式，整理为式 (3-30)。当 X_M 、 X_L 皆服从正态分布时， t 检验量服从于自由度为 N_B-1 的 t 分布^[120]，即：

$$t = \frac{\bar{X}_M - \bar{X}_L}{\sqrt{S^2 / N_B}} \sim t(N_B - 1) \quad (3-30)$$

式 (3-30) 中， N_B 为样本点数，也就是 B 组数据集的数据段数。本节待证明的结论是 MLCF 的模型精度优于 LCF 模型，即 X_M 的总体均值小于 X_L 的总体均值。由上文所述， X_M 的样本均值小于 X_L 的样本均值，这是样本的支持信息。由于 t 检验属于显著性检验的范畴，主要控制第 I 类错误，即“弃真”错误。因有待证明的结论与样本支持的信息是一致的，为了加强结论成立的信服力，应以这一论断的否定作为零假设，以充分利用显著性检验的特点控制“弃真”错误发生的概率。为此，给定零假设 H_0 和备选假设 H_1 ：

$$\begin{aligned} H_0 : \mu_M &\geq \mu_L \\ H_1 : \mu_M &< \mu_L \end{aligned} \quad (3-31)$$

式 (3-31) 中， μ_M 为 X_M 的总体均值， μ_L 为 X_L 的总体均值。选择 t 检验法的显著性水平 α 为 0.005。由 t 检验法知，零假设 H_0 的拒绝域为：

$$t \in (-\infty, -t_\alpha(N_B - 1)] \quad (3-32)$$

式 (3-32) 中， $-t_\alpha(N_B-1)$ 为零假设拒绝域的临界点。对于三名驾驶员，利用式 (3-30) 计算 t 检验量，利用 t 分布表确定拒绝域的临界点 $-t_\alpha(N_B-1)$ ，如表 3.12。由表 3.12 知， t 检验量小于拒绝域临界点 $-t_\alpha(N_B-1)$ ，故处于零假设 H_0 的拒绝域之内，即显著性水平为 0.005 时，认为 H_0 不成立的。由文献[119]知， t 检验属于显

显著性检验的范畴，其显著性水平反映了“弃真”错误所犯的概率。对于 X_M 、 X_L 总体均值的检验来说，“真”是原假设 $\mu_M \geq \mu_L$ ，“弃真”错误的概率为 $\alpha=0.005$ 说明：尽管 t 检验拒绝承认 H_0 成立，但实际上 H_0 可能成立，且这一事件的发生概率小于 0.5%。在驾驶员模型的评价领域中，0.5% 属于小概率事件，“弃真”错误几乎不会出现。这表明，对于三名驾驶员， X_M 总体均值小于 X_L 的总体均值这一论断是成立的，即 MLCF 模型的精度优于 LCF 模型。

表 3.12 X_M 和 X_L 总体均值的 t 检验结果

驾驶员	t 检验量	α	t 自由度	$-t_{\alpha}(N_B-1)$
1	-5.48	0.005	$n-1=78$	-2.68
2	-5.41	0.005	$n-1=68$	-2.68
3	-4.14	0.005	$n-1=81$	-2.68

3.3.4 基于 F 检验法的模型误差方差比较

同总体均值的 t 检验类似，本节将 X_M 和 X_L 的分布特性引入到总体方差的检验中，以避免驾驶随机性对模型适用度验证的影响。因变随机量 X_M 、 X_L 服从正态分布，且其总体均值未知，由文献[120]知，两变量总体方差可由 F 检验法进行比较。

F 检验法的基本原理是：首先利用 X_M 、 X_L 样本方差的商构造 F 检验量；其次，根据随机变量方差之间待确定的关系建立零假设；然后利用 F 分布的特性，结合给定的显著性水平 α ，确定零假设的拒绝域；最后根据 F 检验量是否满足拒绝域，通过拒绝或接收零假设的方式，判断 X_M 、 X_L 总体方差之间的关系。

按照上述原理，首先，利用 X_M 、 X_L 样本方差的商构造构造 F 检验量，如式 (3-33)。由 F 检验法知，当 X_M 、 X_L 皆服从正态分布时，F 检验量服从自由度为 N_B-1 的 F 分布^[120]。

$$F = \frac{S_M^2}{S_L^2} \sim F(N_B - 1, N_B - 1) \quad (3-33)$$

式 (3-33) 中， N_B 为样本点数，也是 B 组数据集的段数。同 t 检验法类似，F 检验法也属于显著性检验的范畴，主要控制“弃真”错误。由表 3.9 易知， X_M 样本方差小于 X_L 的样本方差，这是样本支持的信息。但实际上，二变量样本方

差的差别并不悬殊,这说明与 LCF 模型相比,MLCF 模型的适用度可能没有明显改进。本节选择该论断作为待证明的结论。与总体均值的检验不同,本节待证明结论弱于样本的支持信息,因此,没有必要加强结论成立的信服力。以二变量总体方差一致为结论构造零假设和备选假设:

$$\begin{aligned} H_0: \sigma_M &= \sigma_L \\ H_1: \sigma_M &\neq \sigma_L \end{aligned} \quad (3-34)$$

式(3-34)中, σ_M , σ_L 分别为 X_M 、 X_L 的总体方差。参照文献[120],选择 F 检验法的显著性水平 α 为 0.01。因式(3-34)零假设属于双边假设检验,其单边显著性水平为 0.5α ,即 0.005。由 F 检验法知,零假设 H_0 的拒绝域为:

$$F \in (0, F_{1-0.5\alpha}(N_B-1, N_B-1)] \cup [F_{0.5\alpha}(N_B-1, N_B-1), +\infty) \quad (3-35)$$

式(3-35)中, $F_{0.5\alpha}(N_B-1, N_B-1)$ 和 $F_{1-0.5\alpha}(N_B-1, N_B-1)$ 为拒绝域的临界点。对于三名驾驶员,利用式(3-33)计算 F 检验量,利用 F 分布表确定拒绝域的临界点,结果如表 3.13 所示。

表 3.13 X_M 和 X_L 总体方差的 F 检验结果

驾驶员	F 检验量	α	F 自由度	$F_{1-0.5\alpha}$	$F_{0.5\alpha}$
1	0.98	0.01	$N_B-1=78$	0.63	1.60
2	0.99	0.01	$N_B-1=68$	0.61	1.64
3	0.92	0.01	$N_B-1=81$	0.63	1.59

由表 3.13 知,三名驾驶员的 F 检验量处于零假设的拒绝域之外,即不能拒绝零假设,应承认 $\sigma_M = \sigma_L$ 成立。同 t 检验一致, F 检验的显著性水平也反映了“弃真”错误所犯的概率。与总体均值的检验不同,因总体方差检验的零假设与待证明的结论是相同的,故被弃掉的“真”是备选假设 H_1 。这说明,尽管 F 检验承认 H_0 成立,但实际上备选假设 H_1 也可能成立,且这一事件发生的概率小于 1%。这表明,对于三名驾驶员, X_M 总体方差与 X_L 的总体方差没有明显差别,对各类交通流和道路工况而言,MLCF 和 LCF 模型的适用度是基本一致的。

3.4 驾驶员期望跟踪误差特性的分析与建模

自适应巡航过程中，因 ACC 系统的感知、决策和执行过程需要一定时间，且车辆驱动制动系存在延迟，自车运动特性总滞后于前车。当前车制动时，自车速度会高于前车速度，相对车速向负方向增大，车间距离变短。当前车加速时，自车速度会低于前车，相对车速向正方向增大，车间距离变长。而，过短的车间距离会增加跟车危险性，引发用户对跟车安全性的担忧和焦虑；过长的车间距离则会引入旁侧车辆的切入，导致自车频繁制动，恶化燃油经济性，这都是 ACC 系统应该避免的问题。

本质上讲，人类的跟车驾驶是一种更先进、更高级的自适应巡航控制过程。跟车过程中，驾驶员会根据车况、路况、交通流状态以及个体特点，对跟踪误差确定一个虚拟的范围。当车间状态处于或者靠近该范围之内，驾驶员对油门和制动的操作通常比较舒缓，车辆加减速缓慢，油耗小，乘坐舒适性好。当车间状态远离该范围时，驾驶员会增加油门或制动踏板的操作量，使车辆快速地加速或制动，使车间状态进入虚拟范围之内。本文称这一特性为驾驶员期望跟踪误差特性。跟车过程中，该特性对跟踪性能的保障是十分必要的，可有效减少前车切入和追尾碰撞的几率。

本节以跟车工况的驾驶员实验数据为基础，利用概率统计方法分析驾驶员期望跟踪误差特性，建立它的一维分布模型和二维分布模型。

3.4.1 期望跟踪误差特性的一维分布模型

跟车过程中，跟踪误差多以相对车速 Δv 和车距误差 Δd 描述。为建立驾驶员跟踪误差特性的数学模型，假定：（1） Δv 和 Δd 是随机变量；（2）跟车工况数据段的样本点足够长， Δv 和 Δd 的样本分布特性与其总体特性一致；（3）跟车过程中， Δv 和 Δd 是相互独立的。


建模之前，先对相对车速和车距误差进行预处理。由节 3.2.3 知，不同车速下，驾驶员对相对车速和车距误差的敏感度是不同的。以车距误差为例，低速时驾驶员对 Δd 的敏感度高， Δd 的离散程度小；高速时，驾驶员对 Δd 的敏感度低， Δd 的离散程度大。所以，不同车速下，驾驶员期望车距误差的范围是不相同的。若直接以实车测量的 Δd 值统计其分布规律，因高速工况 Δd 的离散程度大，它的分布特性极易掩盖低速工况分布特性。为此，先利用驾驶敏感度模型处理实验直接测量的相对车速和车距误差，建立具有等敏感度的相对车速量和车距

误差量。处理方法如下：

$$\begin{aligned}\Delta v_s(i) &= \Delta v(i) \cdot SVE(v_f(i)) \\ \Delta d_s(i) &= \Delta d(i) \cdot SDE(v_f(i))\end{aligned} \quad i \in \mathbf{D}^A \quad (3-36)$$


式 (3-36) 中, Δv 、 v_f 、 Δd 来源于 A 组数据集, Δv_s 为 SVE 模型修正的相对车速, Δd_s 为 SDE 模型修正的车距误差。

以 $\Delta v_s(i)$ 为样本点, 统计相对车速的一维累积概率分布曲线, 如图 3.13 所示; 以 $\Delta d_s(i)$ 为样本点, 统计车距误差的一维累积概率曲线, 如图 3.14 所示。图中, 星点是累积概率值。



(a) 驾驶员 No.1

(b) 驾驶员 No.2



(c) 驾驶员 No.3

图 3.13 相对车速的一维累积概率分布




图 3.14 车距误差的一维累积概率分布

由图 3.13 的星点线知, 相对车速的累积概率曲线呈斜 S 形, 近似中心对称。由图 3.14 的星点线知, 车距误差的累积概率曲线也呈 S 形, 也近似中心对称。因为累积概率曲线的斜率直接反映随机变量分布的集中程度, 由两图易知, 以零点为中心的邻域是 Δv_s 和 Δd_s 的集中区域, 这也是驾驶员期望跟踪误差的所在范围。

为建立该范围的数学模型, 以置信度水平为 β , 建立累积概率区间为 $[0.5\beta, 1-0.5\beta]$, 如图 3.13 和图 3.14 的水平实线所示。利用累积概率区间分别确定 Δv_s 和 Δd_s 的置信区间, 以置信上限和置信下限作为驾驶员期望跟踪误差范围的上下界。图 3.13 中, Δv_s 置信区间的下界是累积概率为 0.5β 的水平线与星点线交

点对应的相对车速值，它的置信区间下界是累积概率为 $1-0.5\beta$ 的水平线与星点线交点对应的相对车速值。图 3.14 中， Δd_s 置信区间的下界是累积概率为 0.5β 的水平线与星点线交点对应的相对车速值，它的置信区间下界是累积概率为 $1-0.5\beta$ 的水平线与星点线交点对应的相对车速值。从数学角度描述 Δv_s 和 Δd_s 的置信区间的求取方法为：

$$\begin{aligned}\Delta v_{\min} &= \min \{ \Delta v_s | 0.5\beta < F_{\Delta v}(\Delta v_s) < 1-0.5\beta \} \\ \Delta v_{\max} &= \max \{ \Delta v_s | 0.5\beta < F_{\Delta v}(\Delta v_s) < 1-0.5\beta \}\end{aligned}\quad (3-37)$$

$$\begin{aligned}\Delta d_{\min} &= \min \{ \Delta d_s | 0.5\beta < F_{\Delta d}(\Delta d_s) < 1-0.5\beta \} \\ \Delta d_{\max} &= \max \{ \Delta d_s | 0.5\beta < F_{\Delta d}(\Delta d_s) < 1-0.5\beta \}\end{aligned}\quad (3-38)$$

式 (3-37) 中， $F_{\Delta v}()$ 是随机变量 Δv_s 的一维累积概率函数，如图 3.13 的星线， Δv_{\min} 和 Δv_{\max} 是相对车速 Δv_s 的上下界。式 (3-38) 中， $F_{\Delta d}()$ 是随机变量 Δd_s 的一维累积概率函数，如图 3.14 的星线， Δd_{\min} 和 Δd_{\max} 是车间距离 Δd_s 的上下界。由辨识方法知，置信度水平 β 决定了驾驶员期望跟踪误差范围的大小。本文选择 $\beta=0.5$ ，即：假定驾驶员在 50% 的概率下，认为跟踪误差处于期望的范围之内，对油门和制动的操作比较舒缓；在 50% 的概率下，认为跟踪误差处于期望范围之外，会增加油门或制动踏板的操作量。在 $\beta=0.5$ 下，有 Δv_s 和 Δd_s 上下界的辨识结果，如表 3.14。

表 3.14 跟踪误差上下界的辨识结果

驾驶员	Δv_{\min}	Δv_{\max}	Δd_{\min}	Δd_{\max}
1	-0.7	0.7	-6.5	6.0
2	-1.0	1.0	-7.5	8
3	-0.7	0.8	-6.0	7.5
平均值	-0.8	0.8	-6.7	7.2

因为 Δv_s 和 Δd_s 是等敏感度的相对车速量和车距误差量，相当于平均车速处，相对车速和车距误差的上下界。将预处理式 (3-36) 代入 Δv_s 和 Δd_s ，并结合表 3.14 中上下界辨识结果，建立全速范围内驾驶员期望跟踪误差模型为：

$$\begin{aligned}\Delta v_{\min} \cdot SVE^{-1} &\leq \Delta v \leq \Delta v_{\max} \cdot SVE^{-1} \\ \Delta d_{\min} \cdot SDE^{-1} &\leq \Delta d \leq \Delta d_{\max} \cdot SDE^{-1}\end{aligned}\quad (3-39)$$

因式(3-39)的模型由相对车速和车距误差的一维累积概率函数得到的,称为驾驶员期望跟踪误差的一维分布模型。实际上,跟车过程不存在一个绝对的跟踪误差边界,边界两侧的驾驶员特性完全不同。期望跟踪误差特性中,驾驶员增强操作强度是随跟踪误差增大而逐渐增大的,或者说存在一个相当大的过渡边界,让驾驶员的特性发生变化。而且不同驾驶员对边界大小的期望值是不同的,即使同一驾驶员,不同时间段、不同交通工况下对边界大小的期望值也是不一致的。因此,辨识一维分布模型时,置信度水平设置为0.5也不是绝对固定的。该模型的应用中,应由驾驶员调整置信度水平,改变跟踪误差的上下界,以满足驾驶员个体的需求。

3.4.2 期望跟踪误差特性的二维分布模型

一维分布模型的基本前提是相对车速和车距误差是相互独立。跟车系统中,相对车速是车距的微分量,车距误差是车距与期望车距的差,而期望车距是车速的非线性函数,车速又与相对车速和前车车速相关,这说明相对车速和车距误差不是完全独立的。为反映二者之间的相关性,除了节3.4.1的假设(1)(2)外,本节假定:(4)相对车速的均值为零,分布特性是对称的;(5)车距误差的均值为零,分布特性是对称的。由对称性假设知, $\Delta v_s, \Delta d_s$ 的二维概率密度函数应以 $\Delta d_s = 0$ 为轴上下对称,以 $\Delta v_s = 0$ 为轴左右对称。

为建立可反映 Δv 和 Δd 相关性的二维分布模型,首先统计随机变量 Δv_s 和 Δd_s 的二维累积概率分布图。方法如下:

- (1) 以 $(\Delta v_s, \Delta d_s)$ 为坐标系,将 $\Delta v_s, \Delta d_s$ 的常在范围划分为二维等间距栅格区间;
- (2) 以式(3-36)修正后的A组数据集为样本,统计样本点位于各栅格区间的概率;
- (3) 在 $(\Delta v_s, \Delta d_s)$ 坐标系内,分别计算第I、II、III和IV象限内的二维累积概率;
- (4) 考虑到 $\Delta v_s, \Delta d_s$ 的二维概率密度函数是上下、左右对称的,将第I、II和IV象限按照对称关系,叠加到第III象限上,得到单象限的二维累积概率。

第三象限的二维累积概率分布如图 3.15 所示。




图 3.15 中，细实线表示等累积概率线。各子图中，同一细实线上，二维累积概率相同。越接近右上角，累积概率越大，右上角点（即平面原点）的累积概率值最大，为 1；越接近左下角，累积概率越小，至左下无穷远处，累积概率为零。辨识二维分布模型的基本原理是：给定置信度水平 β ，在第三象限内确定累积概率接近置信度水平的点（称为累积概率点），利用直线拟合累积概率点，即为驾驶员期望跟踪误差范围在第三象限的边界；根据对称性假设，将第三象限的直线边界扩展到第 I、II 和 IV 象限，所有象限内，边界直线围成的区域就是驾驶员期望跟踪误差范围。

下面具体介绍辨识的详细过程。给定置信度水平 $\beta=0.5$ ，记第三象限中的置信概率点组成的集合为 T_b 。点集 T_b 定义为：

$$T_b \triangleq \{ \Delta v_s, \Delta d_s \mid \beta - \Delta\beta \leq F_{vd}(\Delta v_s, \Delta d_s) \leq \beta + \Delta\beta \} \quad (3-40)$$

式(3-40)中， T_b 称为置信概率点集， $F_{vd}()$ 表示第III象限的累积概率函数， β 是置信度水平， $\Delta\beta$ 是置信度偏差。辨识过程中， $F_{vd}()$ 是以 $\Delta v_s, \Delta d_s$ 为自变量二维查表函数，如图3.15的等累积概率线所示。因为二维累积概率分布图是基于栅格区间统计得到的，故 $F_{vd}()$ 函数的自变量是不连续的。式(3-40)中，若强制要求 $F_{vd}(\Delta v_s, \Delta d_s) = \alpha$ ，则点集 T_b 极易为空集。为避免该问题，本文选择 $\Delta\alpha = 0.05$ ，利用式(3-40)求解得到的 T_b 点集，如图3.15的实点所示。

为了使用数学模型描述驾驶员期望跟踪误差特性的边界，利用直线模型拟合 T_b 点集，有：

$$\Delta v_s + \frac{\Delta d_s}{K_{TE}} = -C_{TE} \quad (3-41)$$

式(3-41)中， K_{TE} 、 C_{TE} 为模型系数，结果如表3.15所示。

表 3.15 期望跟踪误差的边界模型参数

驾驶员	K_{TE}	C_{TE}
1	9.08	0.96
2	7.84	1.22
3	8.33	1.01
平均值	8.42	1.06

式(3-41)的边界模型和表3.15的参数仅是第III象限的辨识结果。利用相对车速和车距误差的对称性假设，将单象限的边界模型扩展到第I、II和IV象限。另外，同一维分布模型一致，利用驾驶敏感度模型对式(3-41)进行修正，以体现不同车速下驾驶员期望跟踪误差范围的差别。所建立的驾驶员期望跟踪误差范围的二维分布模型为：

$$\left| \Delta v \cdot SVE \right| + \left| \frac{\Delta d \cdot SDE}{K_{TE}} \right| \leq C_{TE} \quad (3-42)$$

式 (3-42) 中, 三名驾驶员的 K_{TE} 、 C_{TE} 参数以及平均值如表 3.15 所示。

3.4.3 两类分布模型的对比

为比较一维分布模型和二维分布模型的特点, 以 $\Delta v_s, \Delta d_s$ 为变量统计四个象限的累积概率值, 如图 3.16 所示。图中, 等高线表示相同的累积概率值, 实线矩形是一维分布模型的边界, 虚线菱形是二维分布模型的边界。




图 3.16 跟踪误差的二维累积概率分布

由图 3.16 的等高线知, 同一累积概率下, 相对车速和车距误差是相互关联的。各象限内, 相对车速的变化趋势与车距误差的趋势是相反的。相对车速的绝对值增大, 则车距误差的绝对值减小, 反之则增加。驾驶员期望跟踪误差的二维分布模型近似菱形, 其边界更贴近这一特性, 能够反映相对车速边界和车距误差边界的相关性。这方面, 二维分布模型优于一维分布模型。

另外, 由图 3.16 的累积概率知, 相对车速和车距误差的分布特性并非完全对称的。以 1 号驾驶员为例, 其累积概率峰值点明显偏下, 小于零点。一维分布模型中, 车距误差的上界和下界是独立计算的, 可描述驾驶员期望跟踪误差范围的不对称性。而二维分布模型的基本假设是跟踪误差的分布特性对称, 无法反映不对称性。这方面, 一维分布模型要优于二维分布模型。

3.5 本章小结

本章以中国驾驶员道路实验数据为基础，依次分析驾驶员的期望车距特性，动态跟车特性和期望跟踪误差特性，并建立相应的数学模型。分析、建模和验证过程的结论如下：

（1）所制定的驾驶员跟车工况判别准则符合中国道路交通流特征，基于该准则选取的数据集可有效避免其他工况对驾驶员跟车特性分析、建模和验证的影响。

（2）跟车过程中，驾驶员对跟踪误差的敏感度模型可有效描述控制增益随车速变化的趋势。随着车速的增加，驾驶员对车距误差的敏感度降低，与车距误差相关的控制增益减小，而驾驶员对相对车速的敏感度近似水平，与相对车速相关的控制增益基本恒定。

（3）基于驾驶敏感度的跟驰模型具有准线性的结构，且参数具有明确的物理含义，适合融于自适应巡航控制算法的设计过程。基于假设检验理论的模型比较验证方法消除了驾驶随机性对跟驰模型性能评价的影响，证明了本章提出的跟驰模型的精度优于线性跟驰模型，两种模型的适用度基本一致。

（4）驾驶员期望跟踪误差特性的一维分布模型近似矩形，可描述驾驶员期望跟踪误差范围的不对称性；它的二维分布模型近似菱形，可反映相对车速和车距误差的边界相关性。

第4章 基于 MPC 的 MOCACC 控制算法设计

跟车系统中，车辆为快变对象，且驱制动系包含各类强非线性环节。然而，MPC 的实时性要求对象模型具有准线性结构，避免使用强非线性方程。为解决二者之间的矛盾，本章利用逆模型法补偿车辆纵向非线性，建立具有线性结构的广义车辆纵向动力学模型，然后结合车间纵向动力学特性，建立跟车系统的离散状态空间方程。

新一代 ACC 的控制目标中，跟踪误差与车间状态相关，燃油消耗是发动机的输出量，驾驶员特性涉及车辆本身的运动轨迹，这三者互相制约。针对该问题，本章进一步以二次型代价函数和线性不等式约束为框架，设计跟踪性能目标、燃油经济性目标和驾驶员感受目标的数学量化方法，建立相应的预测优化问题，并推导出车辆 MOCACC 控制算法，为跟踪性能、燃油经济性和驾驶员感受的协调控制奠定基础。

4.1 乘用车纵向动力学系统的分析与建模

跟车系统建模之前，首先要建立车辆的纵向动力学模型。一方面，ACC 系统的设计必须依托精确的车辆模型，另一方面，它也是 ACC 性能仿真评价的基础。本节以国产某型自动挡轿车为对象，分析该车纵向动力学系统的基本结构，兼顾准确性和复杂性建立驱动系、制动系的动力学方程以及发动机油耗模型，并进行实车实验验证。

4.1.1 车辆纵向动力学系统的基本结构

图 4.1 为国产某型自动挡轿车的纵向动力学结构，输入为节气门开度 α_{thr} 和制动压力 P_{brk} ，输出为发动机瞬时油耗 Q_s ，发动机转速 ω_e ，变速器挡位 i_g ，纵向车速 v_f 和纵向加速度 a_f 。该车的发动机为 2.0L 四缸四冲程电喷汽油机，其输出经液力变矩器、行星齿轮变速器、主减速器等总成变速增矩后，作用于左右前轮，驱动车辆前进。制动系为双管路液压结构，作用于车辆四轮。




图 4.1 乘用车的纵向动力学结构

考虑 ACC 系统的应用环境，兼顾建模的复杂性和精确性，对车辆纵向动力学特性作如下假设和简化：（1）忽略横向和垂向运动，仅考虑汽车纵向运动；（2）针对良好路面和常规驾驶条件，忽略轮胎的滑移和传动轴的变形；（3）汽车左右完全对称，忽略前后轴载荷转移；（4）发动机中，简化进气歧管动态特性、发动机燃烧迟滞为一阶惯性环节，采用发动机速度特性数据描述发动机的转矩输出；（5）假定传动系的机械效率固定，简化自动变速器的换挡逻辑为节气门开度和车速的非线性函数；（6）简化制动压力到制动力矩的关系为固定制动增益，因制动器间隙和压力传输过程造成的动态特性由一阶惯性延迟环节描述。

4.1.2 车辆纵向动力学模型及其参数

基于上述假设和简化，参考[121]、[122]、[123]和[124]，建立乘用车纵向动力学模型：

$$T_{es} = \text{MAP}(\omega_e, \alpha_{thr}), T_e = \frac{1}{\tau_e s + 1} T_{es} \quad (4-1)$$

$$T_e - T_p = J_e \dot{\omega}_e$$

$$T_p = C_{TC} \omega_e^2, T_t = K_{TC} T_p$$

$$T_d = \eta_T i_g i_0 T_t, \omega_t = i_g i_0 \omega_w, \omega_w = \frac{v_f}{r_w} \quad (4-2)$$

$$\begin{aligned}
 M\dot{v}_f &= \frac{T_d}{r_w} - \frac{T_b}{r_w} - F_i - F_a - F_f \\
 T_b &= \frac{K_b e^{-\tau_d s}}{\tau_b s + 1} P_{brk} \\
 F_i &= Mg \cdot \sin(\theta), F_a = \frac{1}{2} C_D A_c \rho v_f^2, F_f = Mg \cdot \cos(\theta) f
 \end{aligned} \tag{4-3}$$

式 (4-1) 中, ω_e 为发动机转速, T_{es} 为发动机静态转矩, T_e 为发动机动态转矩, τ_e 为进气歧管气体动态和发动机燃烧迟滞的时间常数, $\text{MAP}()$ 用于描述发动机速度特性, 是节气门开度 α_{thr} 和发动机转速 ω_e 的非线性函数, J_e 为发动机飞轮和液力变矩器泵轮的转动惯量。式 (4-2) 中, T_p 为泵轮的输入转矩, T_l 为涡轮的输出转矩, C_{TC} 和 K_{TC} 分别为液力变矩器的容量特性系数和变矩比, 均是液力变矩器速比的非线性函数, i_g 是自动变速器传动比, i_0 是主减速器传动比, η_r 为传动系的效率, T_d 为前轴的驱动力矩, ω_l 是涡轮转速, ω_w 是前轮轮速, r_w 是车轮滚动半径。式 (4-3) 中, M 是等效整车质量, T_b 是前后轴的制动总力矩, F_i 为坡道阻力, F_a 为空气阻力, F_f 为滚动阻力, K_b 是制动系增益, τ_b 为制动系的时间常数, τ_d 为因制动压力传递延迟造成的时滞常数, g 是重力常数, θ 是道路坡度, C_{DA} 是空气阻力系数, A_c 是迎风面积, f 是轮胎滚阻系数。

为便于控制算法的设计, 并评价车辆油耗特性, 应建立发动机油耗模型。汽油机建模中, 平均值模型可详细描述进气歧管、曲轴旋转、燃油混合和流动等动态特性, 在发动机控制领域已经广泛应用^[125,126]。该模型的精度虽高, 但结构复杂, 参数较多。在 ACC 中, 因无需精确控制发动机的内部状态, 如进气歧管的压力、混合气的空燃比等, 故不必使用过于复杂的发动机模型。参考文献[127]和[128], 利用发动机稳态油耗特性数据, 结合动态油耗的经验补偿方法, 建立发动机的半经验油耗模型:

$$\begin{aligned}
 Q_s &= P_e b_s + k_q \xi \\
 \xi &= \begin{cases} \dot{\omega}_e & \dot{\omega}_e \geq 0 \\ 0 & \dot{\omega}_e < 0 \end{cases} \\
 b_s &= \text{Fuel}(\omega_e, \alpha_{thr}) \\
 P_e &= \omega_e T_e
 \end{aligned} \tag{4-4}$$

式(4-4)中, Q_s 为发动机瞬时油耗量, b_s 为发动机的稳态燃油消耗率, P_e 为发动机的净功率, k_q 为动态油耗的经验补偿系数, ξ 是与发动机转速变化率相关的变量, $\text{Fuel}()$ 表示发动机稳态油耗特性, 是发动机转速和节气门开度的非线性函数, 由发动机台架实验得到。实践表明, 发动机大部分时间工作在非稳态工况下, 动态工况占总工作过程的 60% 以上^[128]。当汽油机加速时, 因混合气形成异常、油料燃烧不充分等原因, 发动机动态转矩会低于稳态工况。为补偿加速过程的转矩降低, 电控发动机中, 其 ECU 会根据发动机加速状态增加喷油量, 调整混合气的浓度, 提高发动机动态转矩。一般来说, 汽油机加速过程中, 补偿的喷油量与发动机转速的变化率相关, 约为正常喷油量的 4~5%^[128]。

由于实验车在原车基础上增加了电子节气门和电子真空助力装置, 为能准确描述实验车的动力学特性, 需建立执行器的数学模型。根据执行器的阶跃响应曲线, 利用面积法^[117]得到二者的传递函数模型:

$$\begin{aligned}\alpha_{thr} &= \frac{1}{0.15s+1} \alpha_{thrdes} \\ P_{brk} &= \frac{1}{0.2s+1} P_{brkdes}\end{aligned}\quad (4-5)$$

式(4-5)中, α_{thrdes} 为期望节气门开度, P_{brkdes} 为期望制动压力。

本文考虑到 ACC 系统多用于常规交通流和良好天气状况。根据国家标准^[129]: 道路最大坡度不超过 5%; 风速不超过 4 级 (<8m/s); 良好沥青或混凝土路面, 滚动阻力系数在 0.01~0.02 之间, 进行实车实验, 并结合汽车本身技术参数, 确定车辆纵向动力学模型的公称参数值, 如表 4.1 和表 4.2 所示。图 4.2 是发动机稳态油耗特性, 图 4.3 是发动机速度特性图, 图 4.4 是液力变矩器的容量特性和变矩比, 图 4.5 是自动变速器的换挡逻辑。

表 4.1 自动变速器的传动比

挡位	1	2	3	4	5
传动比	3.620	1.925	1.285	0.936	0.667

表 4.2 车辆纵向动力学模型的公称参数

参数	物理意义	单位	公称值
τ_e	发动机时间常数	s	0.3
J_e	曲轴和泵轮转动惯量	$\text{kg} \cdot \text{m}^2$	0.28
η_T	传动系机械效率	-	0.92
i_0	主减速器传动比	-	3.863
M	等效整车质量	kg	1645
r_w	轮胎滚动半径	m	0.301
C_D	空气阻力系数	--	0.37
A_c	迎风面积	m^2	2.2
g	重力加速度	m/s^2	9.81
f	滚动阻力系数	--	0.018
K_b	制动系统增益	$\text{N} \cdot \text{m/MPa}$	596.5
τ_b	制动系时间常数	s	0.2
τ_d	制动系时间迟滞	s	0.1
k_q	动态油耗补偿系数	$\text{g} \cdot \text{s}$	0.03




图 4.2 发动机稳态油耗特性




图 4.3 发动机速度特性




图 4.4 液力变矩器特性




图 4.5 自动变速器换挡规律

4.1.3 车辆纵向动力学模型的实验验证

为验证车辆模型的精度，进行表 4.3 所述的实车实验。实验路面为良好的沥青路面，长度大于 1000m，最大坡度为 2%，最小弯道半径>500m，风速小于 8m/s。考虑驾驶员、实验人员以及加装的设备，实验车相当于整备质量。

表 4.3 验证车辆模型的实验工况

时间段	工况描述	装载质量	坡道
6-17 秒	发动机怠速行车	满载	<2%
17-58 秒	小油门开度加速	满载	<2%
58-88 秒	中油门开度加速	满载	<2%
88-115 秒	制动减速	满载	<2%

实验过程中，记录下实验车的输入信号和响应信号。仿真时，将记录的实车输入信号作为模型的输入，如图 4.6。仿真模型中，整车质量为满载质量，坡度、风速为零。






图 4.6 实验过程的车辆输入信号

通过对比实验结果与仿真结果来验证车辆模型的准确性，如图 4.7 所示。由图 4.7 知，怠速工况、小油门开度、中油门开度和制动工况下，车辆纵向动力学模型输出的车速、加速度、发动机转速和瞬时油耗均能较好吻合实验结果。而且，各工况切换过程，模型输出与实验结果也基本一致。这说明，所建立的车

辆模型可准确反映汽车纵向动力学系统的稳态特性和动态特性。



(a) 车速和加速度



(b) 发动机转速和瞬时油耗

图 4.7 实车实验和模型仿真的输出信号

4.2 自适应巡航控制对象建模

节 4.1 建立的乘用车纵向动力学模型虽具有结构简洁、准确性好的特点，但不能直接用于 ACC 算法的设计。一是车辆驱制动总成多为快变对象，且包含各

类强非线性环节，不满足高实时 MPC 对被控对象线性或准线性的要求；二是缺少车间动力学特性的数学描述，无法反映车间和车辆特性之间的耦合关系。为此，本节首先采用逆模型法补偿车辆纵向非线性，建立具有线性结构的广义车辆纵向动力学系统；其次，利用正弦激励法辨识其输入输出特性，结合车间纵向动力学特性，建立集成式跟车系统动力学模型；最后，结合 T-S 模糊化法，将连续方程离散化，建立跟车系统的离散状态空间方程。

4.2.1 车辆纵向非线性的逆模型补偿

设计自适应巡航控制算法的难点之一是车辆纵向动力学系统的强非线性问题。驱动系中，非线性特性主要包括发动机强静态非线性、液力变矩器非线性、AT 的离散挡位和二次型空气阻力；制动系中，主要是制动系时滞特性等。针对驱动系，已有文献给出两类处理方法。第一类采用非线性建模方案，利用滑模变结构控制等非线性方法设计控制算法^[12,113]。第二类利用线性化方法将非线性对象转化为线性或准线性模型，如 Taylor 展开法^[130]、基于微分几何的输入输出线性化^[131]以及逆模型法^[28,133,134]，利用线性方法设计控制算法。对于制动系，目前多采用 SMITH 预估器^[131]或时滞环节 Taylor 线性化法^[135]，消除时滞造成的抖振问题。

为解决跟踪性能、燃油经济性和驾驶员感受的协调问题，本文采用具有在线优化功能的 MPC 理论设计控制算法。自适应巡航控制对象中，发动机、电子节气门和制动执行器等总成属于快变对象，为保证良好的控制性能，控制周期不应大于 100ms^[134]。而 MPC 的优化功能是以大规模在线计算为代价的，其求解过程不仅复杂，而且极其耗时。因此，利用 MPC 实时控制快变对象时，不适合采用计算量大、难以求解的非线性模型。线性化建模方案中，对于发动机等强非线性对象，Taylor 展开法不可避免存在较大的线性化误差，而且，离散挡位属于非连续函数，理论上无法使用 Taylor 展开。基于微分几何的输入输出线性化方法虽然理论上无线性化误差，但使用条件相对苛刻，而且线性化模型无明确的物理意义，不便于后续控制算法设计。逆模型方法无苛刻的应用条件，不要求被控对象光滑连续，且易于工程实现，是解决车辆纵向非线性问题的有效措施。对于制动系的时滞非线性，因乘用车的制动系统采用液压结构，制动延迟很小，对纵向控制性能基本无影响，故可不必处理。

综上分析，本文采用逆模型法补偿车辆纵向非线性，并结合油门制动切换

逻辑和加速度校正器，建立具有线性输入输出特性的被控系统，如图 4.8 所示。该系统包括车辆逆纵向动力学模型、油门制动切换逻辑和车辆对象本身，输入为期望加速度，输出为实车加速度。为区别已有的车辆对象，称图 4.8 为广义车辆纵向动力学（GVLD，Gneralized Vehicular Longitudinal Dynamics）系统。




图 4.8 广义车辆纵向动力学系统

设计车辆逆纵向动力学模型时，假设：（1）忽略发动机及其电子节气门的动态特性；（2）自动变速器的换挡过程可瞬间完成；（3）正常的行车工况，液力变矩器锁止；（4）忽略制动系和电控制动执行器的动态特性；（5）道路坡度为零。




图 4.9 车辆逆纵向动力学模型

车辆逆纵向动力学模型的结构如图 4.9 所示，输入为校正期望加速度 \bar{a}_{fdes} 、发动机转速 ω_e 、挡位 i_g 和车速 v_f ，输出为期望节气门开度 α_{thrdes} 和期望制动压力 P_{brkdes} 。驱动工况的逆纵向动力学模型为：

$$\begin{aligned}
 F_{ddes} &= 0.5C_{DA}\rho v_f^2 + Mgf + Mg\bar{a}_{fdes} \\
 T_{edes} &= \frac{F_{ddes}}{\eta_T i_g i_0 r_w} \\
 \alpha_{thrdes} &= \text{MAP}^{-1}(\omega_e, T_{edes})
 \end{aligned} \tag{4-6}$$

式 (4-6) 中, \bar{a}_{fdes} 为校正期望加速度, F_{ddes} 为前轮期望驱动力, T_{edes} 为期望发动机转矩, $\text{MAP}^{-1}()$ 为发动机逆 MAP 图, 如图 4.10 所示。




图 4.10 发动机逆 MAP 图

汽车行驶过程中, 为减少不必要的燃油损耗, 制动时首先利用发动机、风阻和道路阻力等进行制动, 当上述阻力不足以提供必要减速度时, 才需要制动器进行制动。根据这一原则, 建立制动工况的逆纵向动力学模型:

$$P_{brkdes} = \frac{1}{K_b r_w} (F_{ddes} - f_{eng}(\omega_e, i_g)) \tag{4-7}$$

式 (4-7) 中, $f_{eng}()$ 是车轮上因发动机倒拖产生的阻力, 是发动机转速 ω_e 和挡位 i_g 的非线性函数, 定义为:

$$f_{eng}(\omega_e, i_g) = \frac{1}{\eta_T} i_g i_0 r_w \cdot \text{MAP}(\omega_e, \alpha_{idle}) \tag{4-8}$$

式 (4-8) 中, α_{idle} 为发动机怠速油门开度, 为 15.5%, $\text{MAP}()$ 是发动机速度特性函数, 见图 4.3。另外注意, 发动机倒拖时, 功率流为逆向, 从车轮传递

到发动机，因此其传动系机械效率与功率正向传递过程不同，故，在式（4-8）中，传动系机械效率 η_r 处于分母中。

汽车行驶过程中，为保护汽车驱/制动系各总成，要避免既增加节气门开度又进行制动的情况。所以，不能利用电子节气门和电控制动装置同时控制车辆，需要根据一定的规则进行驱动工况和制动工况的切换。驱动工况时，期望制动压力为零。制动工况时，期望节气门开度为怠速油门开度。根据上述原则，以车辆怠速带挡滑行的实验数据为基础，统计汽车加速度与车速的关系作为油门制动切换逻辑的基准曲线。另外，从驾驶舒适性方面考虑，应当避免驱动/制动控制的频繁切换，因此根据经验将该曲线分别向上、向下偏置 0.03m/s^2 ，构成的制动控制的上界和驱动控制下界，如图 4.11 所示。以车速为横坐标，当期望加速度大于制动控制上界时，切换至驱动工况；当期望加速度小于驱动控制下界时，切换至制动工况。




图 4.11 油门制动切换逻辑

若本节假设（1）~（5）成立，车辆对象与逆模型准确逆向相反，则逆模型补偿后的车辆纵向动力学系统完全线性化，输入输出增益为 1。然而，逆模型建模过程忽略了两类不确定性：一是发动机、轮胎等部件的动态，二是车辆参数误差和道路坡度。当前者存在时，逆模型补偿后，车辆纵向动力学系统存在动态过程。当后者存在时，逆模型补偿后，车辆纵向动力学系统的输入输出增益不为 1。为减小两类不确定性的影响，利用实际加速度与期望加速度的误差对逆纵向动力学模型的输入进行 PI 校正，有：

$$\bar{a}_{fdes} = a_{fdes} + k_{acce}e + I_{acce} \int_{E_{low}}^{E_{upp}} e(t) dt \quad (4-9)$$

$$e \triangleq a_{fdes} - a_f$$

式 (4-9) 中, e 是加速度误差, k_{acce} 是常数项, I_{acce} 是积分项。与一般 PI 方法的积分器不同, 式 (4-9) 的积分器带上下界 E_{upp} 和 E_{low} 。当误差积分量大于上界时, 积分器的输出保持为 E_{upp} , 当误差积分量小于下界式, 积分器的输出保持 E_{low} 。与一般 PID 控制器的积分环节相比, 它可以避免过大积分量引起的控制超调问题。表 4.4 是加速度校正器的参数。

表 4.4 加速度校正器的参数

参数	物理意义	参数值	参数	物理意义	参数值
k_{acce}	常数项系数	0.5	E_{upp}	积分项上界	0.2
I_{acce}	积分项系数	0.2	E_{low}	积分项下界	-0.2

由表 4.4 知, PI 校正器的参数较小, 这虽然降低了加速度反馈校正的强度, 但有利于减少加速度测量噪声的反馈量, 避免中低频测量噪声造成的加速度控制抖振问题。GVLD 系统中, 因加速度反馈强度较低, 当跟车系统不确定性较大时, 加速度跟踪不可避免存在一定的瞬态或稳态误差。这导致下一节(节 4.2.2)辨识得到的 GVLD 模型不能准确描述实际系统的输入输出特性, 进而造成跟车系统建模失配, 降低了 ACC 系统的鲁棒性。因跟车系统模型失配带来的弱鲁棒性问题, 将在第 5 章中进一步解决。

4.2.2 广义车辆纵向动力学系统的特性辨识

目前, 用于车辆纵向动力学特性辨识的方法主要有两类: 阶跃响应法^[136]和频率响应法^[137]。前者以加速度阶跃信号为激励源, 会导致汽车车速发生变化, 引起车辆工作点的转移, 进而改变 GVLD 系统的传递特性。模型预测控制算法的设计中, 因被控对象的模型是单一的, 不能同文献[136]一样, 利用多线性模型消除工作点转移造成的特性辨识误差。因此, 本文采用第二类方法, 辨识 GVLD 系统的传递函数模型。

因为单频激励法仅可估计单一工作点处的系统特性, 为覆盖 GVLD 系统的主要工作区, 选择车速范围为 10m/s 到 25m/s, 每隔 5m/s 为一个工作点。每个

工作点处，又分整车质量为公称质量、110%的公称质量、120%公称质量、130%公称质量和 140%公称质量。为激励 GVLD 系统的固有特性，以 0.15rad/s 到 10rad/s 为频率范围，不等间距选择 24 个激励频率。以车辆模型代替实车对象，利用计算机仿真完成 GVLD 系统的激励实验。各车速工作点、各整车质量、各激励频率下，依次仿真，记录 GVLD 系统的输入输出信号，利用傅立叶变换估计输入输出信号的幅值比和相位差，作为 GVLD 系统的输入输出特性。辨识结果如图 4.12 所示。图中，星灰线是辨识点，点实线是拟合后的一阶传递函数模型。




图 4.12 GVLD 系统的特性辨识结果

由图 4.12 星灰线知，GVLD 系统的输入输出特性近似低通滤波器，其-3dB 截止频率约为 0.6Hz，相位差约为-50deg。利用一阶惯性传递函数描述 GVLD 系统的输入输出特性：

$$a_f = \frac{K_G}{T_G s + 1} a_{fdes} \quad (4-10)$$

式(4-10)中， K_G 和 T_G 分别为传递函数模型的系统增益和时间常数。以 GVLD 系统的幅值比和相位差为数据点，利用 Levy 法求解传递函数模型的系统增益和时间常数，有 $K_G=1.05$ 和 $T_G=0.393$ 。

为验证传递函数模型精度，分别在不同车速工作点处，以变化范围 $-0.2\text{m/s}^2 \sim 0.4\text{m/s}^2$ ，周期为 5 秒的方波信号为期望加速度输入，仿真比较 GVLD 系统和传递函数模型的输出，如图 4.13 所示。图 4.13 中，A 表示期望加速度输

入信号, B 是 GVLD 系统的输出, C 是传递函数模型的输出。由图 4.13 知, 各车速工作点处, 传递函数模型的输出均能较好吻合 GVLD 系统的输出。这说明, 在 ACC 常用工作范围内, 一阶惯性传递函数模型可很好地描述 GVLD 系统的输入输出特性。




图 4.13 GVLD 系统和传递函数模型的对比

4.2.3 跟车系统动力学特性的集成式建模

常规的 ACC 控制器设计多采用车辆和车间纵向动力学系统分离建模的方案。这虽然简化了系统模型的结构, 但难以反映目标车加、减速干扰对自车纵向动力学特性的影响。MOCACC 中, 跟踪误差与车间状态相关, 燃油消耗是发动机的输出量, 驾驶员特性涉及车辆本身的运动轨迹, 这三者的协调控制需要

综合考虑车辆和车间纵向动力学特性的耦合关系。因此，参照文献[131]提出集成建模思想，建立跟车系统的连续动力学模型。

图 4.14 是跟车系统的基本结构，含广义车辆纵向动力学（GVLD）系统和车间纵向动力学系统。




图 4.14 跟车系统的基本结构

为描述车间纵向动力学特性，定义车间状态变量：

$$\begin{aligned}\Delta d &= d - d_{des} \\ \Delta v &= v_p - v_f\end{aligned}\quad (4-11)$$

式 (4-11) 中， Δd 为车距误差， Δv 为相对车速， d 为车间距离， d_{des} 为期望车距， v_p 为前车车速， v_f 为自车车速。利用 Newton 第二运动定律建立 Δd 和 Δv 的关系，并代入 QDC 模型 (3-8)，有车间纵向动力学模型：

$$\begin{aligned}\Delta \dot{d} &= \Delta v - \left[\tau_h + r(2v_f - v_{fmean}) \right] a_f \\ \Delta \dot{v} &= a_p - a_f\end{aligned}\quad (4-12)$$

式 (4-12) 中， a_p 为前车加速度， a_f 为自车加速度。综合 GVLD 模型 (4-10) 和车间纵向动力学模型 (4-12)，建立跟车系统的连续动力学模型：

$$\dot{\mathbf{x}} = \begin{bmatrix} 0 & 1 & -\tau_h - r(2v_f - v_{fmean}) \\ 0 & 0 & -1 \\ 0 & 0 & -1/T_G \end{bmatrix} \mathbf{x} + \begin{bmatrix} 0 \\ 0 \\ K_G/T_G \end{bmatrix} u + \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} v \quad (4-13)$$

$$\mathbf{x} \triangleq [\Delta d \quad \Delta v \quad a_f]^T, u \triangleq a_{fdes}, v \triangleq a_p$$

式 (4-13) 中, 控制输入 $u \in R^1$ 为期望加速度, 可测干扰 $v \in R^1$ 为前车加速度, 系统状态 $\mathbf{x} \in R^3$ 是由车距误差、相对车速和自车加速度组成的向量。对于典型 ACC 系统, 除车速等原车传感器外, 装有雷达和加速度计, 状态 Δd 、 Δv 和 a_f 皆可直接测量。因此, 其输出方程为:

$$\mathbf{y} = \mathbf{C}\mathbf{x} + \mathbf{w} \quad (4-14)$$

式 (4-14) 中, \mathbf{C} 为 3×3 维单位矩阵, $\mathbf{w} \in R^3$ 代表传感器测量噪声, $\mathbf{y} \in R^3$ 为系统状态的测量值。为便于后文的叙述, 定义控制输入的维数为 m , 系统状态的维数为 l , 系统输出的维数为 n , 可测干扰的维数为 q , 有 $m=1, l=3, n=3, q=1$ 。

4.2.4 跟车系统动力学模型的离散化

因 QDC 模型二次项的存在, 跟车系统连续动力学模型是非线性的。由文献 [138] 知, 连续状态空间方程的离散化须求解一矩阵多项式的积分, 对于非线性对象, 其理论解的计算是十分困难的。目前, 一类常用的解决方法是采用多个线性模型描述非线性对象, 并分别离散化, 建立离散状态空间方程的集合^[139-142]。该方法的主要缺点是: 基于多模型集设计的控制器中, 控制量通常不连续, 切换瞬间易造成系统抖振^[142]。为避免该问题, 本节以多模型离散化思想为基础, 结合 T-S (Takagi-Sugeno) 模糊化法, 建立具有准线性结构且方程唯一的离散状态空间方程。

首先, 以城市道路工况和高速公路工况的典型车速为工作点, 对跟车系统连续动力学方程 (4-13) 进行 Taylor 线性化, 有分段线性的连续方程:

$$\dot{\mathbf{x}} = \boldsymbol{\Phi}_{High} \mathbf{x} + \boldsymbol{\Pi} u + \boldsymbol{\Gamma} v$$

$$\boldsymbol{\Phi}_{High} \triangleq \begin{bmatrix} 0 & 1 & -\tau_h - r(2v_{fHigh} - v_{fmean}) \\ 0 & 0 & -1 \\ 0 & 0 & -1/T_G \end{bmatrix}, \boldsymbol{\Pi} \triangleq \begin{bmatrix} 0 \\ 0 \\ K_G/T_G \end{bmatrix}, \boldsymbol{\Gamma} \triangleq \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad (4-15)$$

$$\dot{\mathbf{x}} = \Phi_{Low} \mathbf{x} + \Pi u + \Gamma v$$

$$\Phi_{Low} \triangleq \begin{bmatrix} 0 & 1 & -\tau_h - r(2v_{fLow} - v_{fmean}) \\ 0 & 0 & -1 \\ 0 & 0 & -1/T_G \end{bmatrix}, \Pi \triangleq \begin{bmatrix} 0 \\ 0 \\ K_G/T_G \end{bmatrix}, \Gamma \triangleq \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad (4-16)$$

式 (4-15) 和 (4-16) 中, $v_{fHigh}=25\text{m/s}$ 、 $v_{fLow}=10\text{m/s}$ 分别为高速公路工况和城市道路工况的车速工作点, Φ_{High} 、 Φ_{Low} 、 Π 和 Γ 为连续系统矩阵。因为 (4-15) 和 (4-16) 均为线性时不变方程, 利用零阶保持控制输入法对两线性方程分别离散化, 得到两线性离散状态空间方程:

$$\mathbf{x}(k+1) = \mathbf{A}_{High} \mathbf{x}(k) + \mathbf{B}_{High} u(k) + \mathbf{G}_{High} v(k) \quad (4-17)$$

$$\mathbf{x}(k+1) = \mathbf{A}_{Low} \mathbf{x}(k) + \mathbf{B}_{Low} u(k) + \mathbf{G}_{Low} v(k) \quad (4-18)$$

式 (4-17) 和 (4-18) 中, \mathbf{A}_{High} 、 \mathbf{B}_{High} 、 \mathbf{G}_{High} 、 \mathbf{A}_{Low} 、 \mathbf{B}_{Low} 和 \mathbf{G}_{Low} 是离散系统矩阵。它们与连续系统矩阵的关系为:

$$\begin{aligned} \mathbf{A}_{High} &= \sum_{k=0}^{\infty} \frac{\Phi_{High}^k T_s^k}{k!}, \quad \mathbf{B}_{High} = \sum_{k=0}^{\infty} \frac{\Phi_{High}^{k-1} T_s^k}{k!} \Pi, \quad \mathbf{G}_{High} = \sum_{k=0}^{\infty} \frac{\Phi_{High}^{k-1} T_s^k}{k!} \Gamma \\ \mathbf{A}_{Low} &= \sum_{k=0}^{\infty} \frac{\Phi_{Low}^k T_s^k}{k!}, \quad \mathbf{B}_{Low} = \sum_{k=0}^{\infty} \frac{\Phi_{Low}^{k-1} T_s^k}{k!} \Pi, \quad \mathbf{G}_{Low} = \sum_{k=0}^{\infty} \frac{\Phi_{Low}^{k-1} T_s^k}{k!} \Gamma \end{aligned} \quad (4-19)$$

式 (4-19) 中, T_s 为控制周期。参照 T-S 模糊化思想^[143], 将分段线性的离散状态空间方程组合为单一模型, 建立跟车系统的离散状态空间方程。定义模糊因子 λ 为:

$$\lambda = \begin{cases} 0 & v_f < v_{fLow} \\ (v_f - v_{fLow})(v_{fHigh} - v_{fLow})^{-1}, & v_{fLow} \leq v_f \leq v_{fHigh} \\ 1 & v_f > v_{fHigh} \end{cases} \quad (4-20)$$

利用模糊因子 λ 将式 (4-17) 和 (4-18) 组合为单一离散状态空间方程, 有:

$$\begin{aligned} \mathbf{x}(k+1) &= \mathbf{A}\mathbf{x}(k) + \mathbf{B}\mathbf{u}(k) + \mathbf{G}\mathbf{v}(k) \\ \mathbf{y}(k) &= \mathbf{C}\mathbf{x}(k) + \mathbf{w} \end{aligned} \quad (4-21)$$

式 (4-21) 中, \mathbf{A} 、 \mathbf{B} 和 \mathbf{G} 为离散状态空间方程的系数矩阵:

$$\begin{aligned} \mathbf{A} &= \lambda \mathbf{A}_{High} + (1-\lambda) \mathbf{A}_{Low} \\ \mathbf{B} &= \lambda \mathbf{B}_{High} + (1-\lambda) \mathbf{B}_{Low} \\ \mathbf{G} &= \lambda \mathbf{G}_{High} + (1-\lambda) \mathbf{G}_{Low} \end{aligned} \quad (4-22)$$

式 (4-21) 以及与之相关的 (4-19)、(4-20) 和 (4-22) 共同组成跟车系统的离散状态空间方程。

本质上讲, 该离散方程也是非线性的, 受模糊因子的作用, 系数矩阵随车速时变, 但它不影响滚动时域优化环节的计算效率。这是因为基于式 (4-21) 设计的模型预测控制器, 单个控制周期内可令模糊因子 λ 恒定, 使 MPC 算法保持线性形式, 满足在线优化的高实时性要求。不同控制周期内, 令模糊因子 λ 随车速自适应变化, 使式 (4-21) 能够准确反映跟车系统的特性, 保证自适应巡航控制性能。而且, ACC 系统中, 单个控制周期的预测时域不大于 5 秒。该时间段内, 车速变化范围有限, 模糊因子近似恒定是合理的, 因此, 跟车系统的离散状态空间方程 (4-21) 是近似线性的。

4.3 车辆 MOCACC 的性能指标设计

性能指标是联系控制目标和控制算法的纽带。一方面, 它体现跟踪性能目标、燃油经济性目标和驾驶员感受目标, 是三者协调控制的基础; 另一方面, 其代价函数和 I/O 约束构成了预测优化问题的主体, 是求解 MPC 控制算法的关键。因此, 它的设计必须兼顾两条原则: 一是准确量化跟踪性能目标、燃油经济性目标和驾驶员感受目标, 体现三者之间的制约关系; 二是代价函数和 I/O 约束应具有简洁的结构, 以保证控制算法求解的实时性。

本节以二次型代价函数和线性不等式约束为框架, 提出跟踪性能、燃油经济性和驾驶员感受各子目标的数学量化方法, 建立可表征跟踪误差、燃油消耗量和驾驶员特性误差的代价函数和包含纵向乘坐舒适性标准、驾驶员期望跟踪误差范围和跟车安全性条件的约束条件, 完成车辆 MOCACC 性能指标的设计。

4.3.1 跟踪性能目标的性能指标

ACC 的跟踪性能一般以车距误差和相对车速为评价标准。如第 2 章的节 2.1 所述,跟踪性能目标分为三个子目标:(1)前车稳态行车工况中,车距误差和相对车速收敛为零,记为 TC1;(2)前车动态行车工况中,车距误差和相对车速处于驾驶员期望跟踪误差范围,以避免远距跟车带来的频繁前车切入或近距跟车的潜在行车危险,记为 TC2;(3)前车紧急制动工况中,车间距离须大于零,以避免追尾碰撞事故的发生,记为 TC3。

子目标 TC1 适合作为 MOCACC 性能指标的代价函数。为定量描述自车跟随前车的能力,文献[68]、[69]将 Δv 和 Δd 的一范数作为代价函数,对不同级别的误差给予同等重视。文[67]将两误差的 2 范数作为代价函数,倾向于重视大的跟车误差。实际跟车过程中,驾驶员对不同级别误差的重视程度是不同的^[144]。一般来说,驾驶员仅响应稍大的跟踪误差,对较小跟踪误差不敏感,甚至不对油门和制动进行任何操作^[31]。从该角度言,倾向于重视大误差的 2 范数比 1 范数更为合理。而且从省油角度来说,也希望忽略小跟踪误差,避免油门或制动的频繁调整。故本文以相对车速和车距误差的 2 范数量化跟踪性能子目标 TC1,有指标 L_{TE} :

$$L_{TE} = w_{y\Delta v} \Delta v^2 + w_{y\Delta d} \Delta d^2 \quad (4-23)$$

式(4-23)中, $w_{y\Delta v}$ 和 $w_{y\Delta d}$ 为相应的权系数。ACC 跟车过程中,虽然指标 L_{TE} 用于惩罚车距误差和相对车速,保证跟踪误差收敛。以低油耗作为目标的 ACC 中,通常选择较小的跟踪误差权系数,使车辆缓加速、轻制动。这种做法带来一个明显的问题是:当前车加速时,自车因加速能力不足,车距过大,易引入频繁的旁侧车辆切入;当前车制动减速时,因自车制动能力不足,车距过小,会增加追尾碰撞的几率,影响驾驶员的安全感。为避免该问题,本节利用驾驶员期望跟踪误差的一维分布模型量化跟踪性能子目标 TC2:

$$\begin{aligned} \Delta d_{\min} \cdot SDE^{-1} &\leq \Delta d \leq \Delta d_{\max} \cdot SDE^{-1} \\ \Delta v_{\min} \cdot SVE^{-1} &\leq \Delta v \leq \Delta v_{\max} \cdot SVE^{-1} \end{aligned} \quad (4-24)$$

式(4-24)中, Δd_{\min} 为车距误差下界, Δd_{\max} 为车距误差上界, Δv_{\min} 为相对车速下界和 Δv_{\max} 为相对车速上界, SDE 和 SVE 为驾驶员对跟踪误差的敏感度,是

车速的函数。

跟车过程中，安全性的首要任务是避免追尾碰撞，保证跟车距离大于安全车距。基于这一原则，Corona 等人采用固定安全车距策略约束车间距离，保障 ACC 系统的跟车安全性^[68]。实际上，固定安全车距策略仅适合稳态跟车工况。动态跟车工况中，安全车距不是固定值，与前后车速相关。一个典型的例子是，当自车速度远大于前车时，即使较长的车间距离也存在一定的危险性。文献[145]采用 TTC (Time-To-Collision) 策略描述安全车距与相对车速的关系，用于车辆前向报警系统和主动避撞系统的设计。TTC 策略适合描述制动过程的跟车安全性，但并不适用于稳态跟车过程。例如，前后车等速行驶时，TTC 策略输出的安全车距为零，显然是不合理的。为此，本节综合 TTC 策略和固定安全车距策略，建立跟车安全性条件，作为跟踪性能子目标 TC3 的数学量化：

$$\begin{aligned} d &\geq d_{safe} \\ d_{safe} &= \max \{TTC \cdot \Delta v, d_{s0}\} \end{aligned} \quad (4-25)$$

式 (4-25) 中， TTC 为碰撞时间， d_{s0} 为最小安全车距， d_{safe} 为跟车安全车距。

4.3.2 燃油经济性目标的性能指标

车辆 MOCACC 中，燃油经济性目标是最小化行车过程的车辆油耗。车辆纵向动力学特性中，尽管瞬时油耗量与燃油消耗直接相关，但它是发动机转速、车速、挡位和节气门开度的非线性函数。若把它直接融于性能指标，则燃油经济性目标的代价函数将是车辆状态的非线性函数。滚动时域优化环节中，其预测优化问题会转化为一高计算复杂度的非线性规划问题。对于周期小于 100ms 的 ACC 而言，该问题的实时求解几乎是不可能的。文[17]指出，跟车过程中，燃油消耗与纵向加速度密切相关，降低加速度水平可有效提高车辆的燃油经济性。因为纵向加速度是跟车系统动力学方程的状态之一，利用它量化燃油经济性目标，不仅可以表征车辆的燃油消耗量，而且可避免引入非线性规划问题。

为利用加速度量化燃油经济性目标，本节首先定性分析车辆加减速过程的油耗特点。参照文献[129]，行车过程中，发动机油耗量 Q_{fuel} 的计算式为：

$$Q_{fuel} = \int_0^T P_e b_e dt \quad (4-26)$$

式 (4-26) 中， b_e 为燃油消耗率， P_e 为发动机净功率， T 为行车时间。由式

(4-26) 知, 除行车时间外, 发动机油耗量依赖于两个因素: 燃油消耗率 b_e 和发动机净功率 P_e 。一般来说, b_e 取决于发动机工作点, 以最佳燃油经济性曲线附近为经济区。驱动时, P_e 主要转化为因轮胎弹性迟滞、空气阻力产生的热能和车辆加速获得的动能。制动时, 车辆动能会逐渐降低, 主要由制动器以热能的形式耗散。与匀速行驶相比, 车辆加减速行驶过程中, 油耗增加的主要因素包括:

(1) 发动机工作在非经济区的几率增加, 导致燃油消耗率 b_e 升高。自动变速器多为两参数换挡规律, 无法根据加速度信息进行挡位切换, 因此车辆加减速时, 发动机工作点常偏离经济区, 导致 b_e 上升。

(2) 发动机加速过程, 混合气形成异常, 导致燃油消耗率 b_e 升高。非匀速行车工况中, 发动机会频繁加减速。发动机加速过程中, 因混合气形成异常, 发动机转矩下降。因此, 相同功率输出条件下, 发动机的 b_e 升高。

(3) 减速过程, 制动器耗散能量, 导致发动机的燃油消耗增加。制动器耗散的能量来源于车身动能, 而车身动能是在车辆加速过程积累的。因此, 制动器耗散的能量仍来源于发动机, 故频繁制动会增加车辆油耗。

为定量分析燃油消耗量与加速度水平的关系, 基于 PID 控制方法, 结合车辆逆纵向动力学模型和油门制动切换逻辑, 设计一车速控制系统。车速控制系统仿真模型的基本结构如图 4.15 所示。




图 4.15 车速控制系统仿真模型的基本结构

仿真模型中, 输入为期望车速 V_{des} , 输出为发动机瞬时油耗量 Q_s 、车速 v_f 和加速度 a_f 。车辆模型、油门制动切换逻辑和逆纵向动力学模型的参数见节 4.1 和 4.2。为使车速和加速度精确跟踪期望值, 以便于定量分析加速度水平与油耗的关系, 取偏大的 PID 控制器系数, 比例项为 2.5, 积分项为 0.15, 微分项为 1.5。

为了分析全速范围内加速度水平与油耗的关系, 设置车速均值恒定的动态

行车工况为：期望车速 V_{des} 的平均速度恒定，以频率 $0.1Hz$ 的正弦加速度 A_{des} 行驶。从 $[0, 0.1, 0.2, 0.3, 0.4, 0.5]m/s^2$ 中，依次选一值作为 A_{des} 的幅值。从 $30km/h$ 到 $90km/h$ 范围内，每隔 $10km/h$ 取一点作为 V_{des} 的平均车速。每个幅值和每个车速点处，利用车速控制系统进行仿真，记录仿真过程的燃油消耗量和平均百公里油耗。仿真时间为 150 秒。图 4.16 是平均车速为 $30km/h$ 时，期望车速和它的加速度曲线。图例代表正弦加速度的幅值。




图 4.16 车速均值恒定的期望行车工况

图 4.17 是平均车速为 $30km/h$ ， A_{des} 幅值为 $0.4m/s^2$ 时，车速及其加速度的跟踪效果。图 (a) 为加速度跟踪曲线，图 (b) 为车速曲线。由图易知，所选 PID 控制器可保证精确的车速跟踪和加速度跟踪，即：车辆的实际行车工况基本等于对 V_{des} 设置的期望行车工况。




图 4.17 车速跟踪和加速度跟踪效果

图 4.18 是油耗和加速度关系的仿真结果，图例代表 V_{des} 的平均车速。图（a）是燃油消耗量与正弦加速度幅值的关系，图（b）是平均百公里油耗与正弦加速度幅值的关系。




图 4.18 油耗与加速度的关系

由图 4.18（a）知，车速均值恒定的正弦加减速行车工况中，燃油消耗量随加速度幅值的增加而增加，符合文献[17]的论述。由图 4.18（b）知，平均百公里油耗与加速度幅值近似线性，利用线性函数量化二者的关系，有：

$$Q_e = k_{QA} \cdot A_{acce} + c_{QA} \quad (4-27)$$

式（4-27）中， Q_e 为平均百公里油耗， A_{acce} 为正弦加速度幅值， k_{QA} 和 c_{QA} 为拟合系数，经最小二乘拟合为 $k_{QA}=7.03$ ， $c_{QA}=6.38$ 。这表明，车速均值恒定的正弦加减速行车工况中，加速度幅值每增加 0.1m/s^2 ，车辆平均百公里油耗上升 0.7L 。因为 GVLD 系统中，实际加速度跟踪期望加速度，对二者进行限制均可有效降低车辆的加速度水平。故本节利用期望加速度和期望加速度导数的 2 范数量化燃油经济性目标，有指标 L_{FC} ：

$$L_{FC} = w_u a_{fdes}^2 + w_{du} \dot{a}_{fdes}^2 \quad (4-28)$$

式（4-28）中， w_u 为期望加速度的权系数， w_{du} 为期望加速度导数的权系数。该代价函数不仅包括期望加速度量，而且含有期望加速度导数量。对于前者，由 2 范数的性质知，控制过程中最小化 L_{FC} 可降低车辆的加速度水平，从而提高车辆的燃油经济性。对于后者，它一方面通过降低加速度变化率，限制发动机

频繁加减速,有助于进一步提高燃油经济性,另一方面低加速度变化率也可减少纵向冲击,提高驾驶员的纵向乘坐舒适性。

4.3.3 驾驶员感受目标的性能指标

为满足良好驾驶员感受,新一代 ACC 的控制特性应符合三类驾驶员感受子目标:(1)符合驾驶员期望车距特性,记为 DB1;(2)满足驾驶员纵向乘坐舒适性要求,记为 DB2;(3)符合驾驶员动态跟车特性,记为 DB3。

第一类特性已经融于跟车系统的建模过程。由节 4.2 的车间纵向动力学模型知,车距误差等于实际车距与期望车距的差。因跟踪性能子目标 TC1 的存在,前车匀速的稳态跟车过程中,车距误差会收敛为零,即实际车距与期望车距相同,驾驶员感受子目标 DB1 自然成立。

目前,国内外学者对第二类特性已有较多研究。针对驾驶员纵向乘坐舒适性问题,美国 PATH 项目提出两条原则:(1)车辆纵向加速度在驾驶员容许的上下界之间;(2)纵向加速度导数的绝对值较小,也在驾驶员容许的上下界之间^[37]。基于该思想,本文利用约束期望加速度和实际加速度的措施建立纵向乘坐舒适性标准,量化驾驶员感受子目标 DB2:

$$\begin{aligned} a_{f \min} &< a_{fdes} < a_{f \max} \\ j_{f \min} &< \dot{a}_{fdes} < j_{f \max} \\ a_{f \min} &< a_f < a_{f \max} \end{aligned} \quad (4-29)$$

式(4-29)中, $a_{f \min}$ 为加速度下界, $a_{f \max}$ 为加速度上界, $j_{f \min}$ 为加速度导数的下界, $j_{f \max}$ 为加速度导数的上界。另外,式(4-29)对期望加速度导数的限制不仅提高了乘坐舒适性,而且可避免紧急加速和紧急制动过程,有利于降低车辆油耗。

驾驶员感受子目标 DB3 与动态跟车过程相关。跟车过程中,虽然最终目标是使 Δv 和 Δd 收敛至零,但前车切入/切出或者加减速工况中,跟踪误差不为零,驾驶员会按照自己期望的参考轨迹,操纵油门和制动踏板,使跟踪误差收敛。该参考轨迹的具体形式与驾驶员习惯相关,属于驾驶员动态跟车特性,由驾驶员跟驰模型描述。如第2章所述,MOCACC 体现驾驶员动态跟车特性的能力由驾驶员参考模型和性能指标共同决定。前者用于计算驾驶员期望的动态跟车轨迹,即参考轨迹 r 。后者通过最小化参考轨迹 r 与跟车系统输出 y 的差,使跟车

系统的状态轨迹逼近驾驶员期望的动态参考轨迹，以达到体现驾驶员动态跟车特性的目的。因此，本节以参考轨迹 r 与跟车系统输出 y 的差作为驾驶员特性误差，利用驾驶员特性误差的 2 范数量化驾驶员感受子目标 DB3，有指标 L_{DC} ：

$$L_{DC} = w_{R\Delta d} (\Delta d_R - \Delta d)^2 + w_{R\Delta v} (\Delta v_R - \Delta v)^2 + w_{Ra} (a_{fR} - a_f)^2 \quad (4-30)$$

式 (4-30) 中， Δd_R 为参考车距误差， Δv_R 为参考相对车速， a_{fR} 为参考加速度，三者共同组成参考轨迹向量， $w_{R\Delta d}$ 、 $w_{R\Delta v}$ 和 w_{Ra} 为相应的权系数。令参考车距误差等于实际车距误差，参考相对车速等于实际相对车速，参考加速度等于 MLCF 模型的输出，建立驾驶员参考模型为：

$$\begin{aligned} \Delta d_R &= \Delta d \\ \Delta v_R &= \Delta v \\ a_{fR} &= SVE \cdot k_v \cdot \Delta v + SDE \cdot k_d \cdot \Delta d \end{aligned} \quad (4-31)$$

式 (4-31) 中， Δd_R 和 Δv_R 直接等于跟车系统的状态，而未利用 a_{fR} 结合车辆纵向动力学模型递推得到。这是因为：MPC 预测优化问题是在预测时域内建立的，需要将本节的代价函数转化为预测形式。若以 a_{fR} 为输入，结合车辆纵向动力学模型递推得到 Δd_R 和 Δv_R ，代价函数 (4-30) 的预测形式将十分复杂，再加上第 5 章跟车预测模型的介入，会大大增加滚动时域优化环节的设计复杂性。而以式 (4-31) 作为参考轨迹时，可将式 (4-30) 简化为式 (4-32)，有利于降低控制算法设计的复杂性。

$$L_{DC} = w_{Ra} (a_{fR} - a_f)^2 \quad (4-32)$$

本质上讲，跟驰模型是从 Δv 、 Δd 到 a_{fR} 的反馈控制算法。当 ACC 特性与驾驶员动态跟车特性不一致时，跟驰模型输出的 a_{fR} 必然与实车加速度 a_f 存在误差，此时，最小化代价函数 (4-32) 可使控制算法调整实际加速度 a_f ，进而调整 Δv 和 Δd 直至与驾驶员期望的动态跟车轨迹一致。因此，只要选择较大的 w_{Ra} 权系数，则可增强 Δv 、 Δd 逼近驾驶员期望跟车轨迹的程度，不影响车辆 ACC 系统体现驾驶员动态跟车特性的能力。

4.3.4 性能指标的代价函数和约束条件设计

控制目标的量化结果中，以跟踪误差为变量的量化指标 L_{TE} 、表征燃油消耗

的量化指标 L_{FC} 和以驾驶员特性误差为变量的量化指标 L_{DC} 具有 2 范数形式，适合作为性能指标的代价函数。驾驶员期望跟踪误差范围、跟车安全性条件和乘坐舒适性标准因具有线性不等式形式，适合作为性能指标的约束条件。

新一代 ACC 系统中， L_{TE} 、 L_{FC} 和 L_{DC} 是相互制约、相互影响的，三者独立的形式不能体现目标之间的协调性。故利用加权平均法将 L_{TE} 、 L_{FC} 和 L_{DC} 整合为单一代价函数 L_{index} ：

$$\begin{aligned} L_{index} &= L_{TE} + L_{FC} + L_{DC} \\ &= (w_{y\Delta v} \Delta v^2 + w_{y\Delta d} \Delta d^2) + (w_u a_{fdes}^2 + w_{du} \Delta \dot{a}_{fdes}^2) + w_{Ra} (a_{fR} - a_f)^2 \end{aligned} \quad (4-33)$$

式 (4-33) 中，不对 L_{TE} 、 L_{FC} 和 L_{DC} 设置权系数，这是因为三者内部的权系数是互相独立，对内部权系数的设置也可反映控制器对 L_{TE} 、 L_{FC} 和 L_{DC} 的偏重。由驾驶员参考模型 (4-31) 知，参考加速度与跟车系统输出满足：

$$a_{fR} = \begin{bmatrix} SDE \cdot k_D & SVE \cdot k_V & 0 \end{bmatrix} \cdot \begin{bmatrix} \Delta d \\ \Delta v \\ a_f \end{bmatrix} \quad (4-34)$$

将式 (4-34) 代入式 (4-33) 后，且利用控制输入 u 代换期望加速度 a_{fdes} ，利用系统输出 y 代换 $[\Delta d, \Delta v, a_f]^T$ ，整理为单一代价函数 L_{index} ：

$$L_{index} = (\omega_{CF} y)^T w_y (\omega_{CF} y) + w_u u^2 + w_{du} \dot{u}^2 \quad (4-35)$$

式 (4-35) 中， ω_{CF} 称驾驶员跟驰特性矩阵， w_y 为输出向量权矩阵，为：

$$\omega_{CF} = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ SDE \cdot k_D & SVE \cdot k_V & -1 \end{bmatrix}, \quad w_y = \begin{bmatrix} w_{y\Delta d} & 0 & 0 \\ 0 & w_{y\Delta v} & 0 \\ 0 & 0 & w_{Ra} \end{bmatrix} \quad (4-36)$$

驾驶员期望跟踪误差范围和纵向乘坐舒适性标准中，受约束变量都是跟车系统动力学模型的控制输入或者系统输出，可直接成为约束条件。对于纵向乘坐舒适性标准，以控制输入 u 代换期望加速度 a_{fdes} ，有跟车系统输入的约束：

$$\begin{aligned} a_{f \min} &\leq u \leq a_{f \max} \\ a_{f \min} &\leq \dot{u} \leq a_{f \max} \end{aligned} \quad (4-37)$$

对于驾驶员期望跟踪误差范围，结合纵向乘坐舒适性标准对加速度的限制，并以系统输出 \mathbf{y} 代换 $[\Delta d, \Delta v, a_f]^T$ ，有跟车系统输出的约束：

$$\begin{bmatrix} \Delta d_{\min} \cdot SDE^{-1} \\ \Delta v_{\min} \cdot SVE^{-1} \\ a_{f \min} \end{bmatrix} \leq \mathbf{y} \leq \begin{bmatrix} \Delta d_{\max} \cdot SDE^{-1} \\ \Delta v_{\max} \cdot SVE^{-1} \\ a_{f \max} \end{bmatrix} \quad (4-38)$$

因为跟车安全性条件的受约束变量与系统输入输出无直接关系，故本节对其进行变换，转化为系统输出 \mathbf{y} 的补充约束。首先，将车距误差的定义式 (4-11) 代入跟车安全性条件 (4-25)，有：

$$\begin{aligned} \Delta d + d_{des} &\geq TTC \cdot \Delta v \\ \Delta d + d_{des} &\geq d_{s0} \end{aligned} \quad (4-39)$$

其次，将二次型期望车距模型 (3-8) 代入上式，有：

$$\begin{aligned} \Delta d &\geq TTC \cdot \Delta v - \left(r(v_f - v_{fmean}) + \tau_h \right) v_f - d_0 \\ \Delta d &\geq d_{s0} - \left(r(v_f - v_{fmean}) + \tau_h \right) v_f - d_0 \end{aligned} \quad (4-40)$$

然后，将相对车速的定义式 (4-11) 代入上式，整理有与跟车安全性条件相关的补充约束：

$$\begin{bmatrix} 1 & -TTC - r(v_f - v_{fmean}) - \tau_h \\ 1 & -r(v_f - v_{fmean}) - \tau_h \end{bmatrix} \begin{bmatrix} \Delta d \\ \Delta v \end{bmatrix} \geq \begin{bmatrix} -\tau_h v_f - d_0 \\ -\tau_h v_f + d_{s0} - d_0 \end{bmatrix} \quad (4-41)$$

式 (4-41) 中，尽管系数矩阵是与车速相关的时变矩阵，但因为 QDC 模型的二次项系数较小，预测时域内车速变化也不大，故在一个控制周期内 $r(v_f - v_{fmean})$ 的变化量可忽略，即认为系数矩阵是近似定常的。

4.4 MOCACC 预测优化问题的推导

节 4.3 中，代价函数和约束条件是以当前时刻的系统输入 \mathbf{u} 和系统输出 \mathbf{y} 为自变量的。为建立车辆 MOCACC 控制算法，本节首先将 MOCACC 性能指标进行预测型转化，建立预测时域的代价函数和约束条件；其次，推导出相应的 MOCACC 预测优化问题，并对问题参数进行设计。

4.4.1 代价函数的预测型转化

假定当前时刻为 k ，车辆 MOCACC 系统的预测时域为 $[k:k+P-1]$ ，预测长度为 P 。

代价函数预测型转化的步骤是：（1）在预测时域 $i \in [k:k+P-1]$ 内，保持代价函数的函数类型和权系数不变，以第 i 点的预测输入和预测输出为自变量，建立第 i 点的代价函数；（2）将各点的代价函数线性加权，得到预测时域的代价函数。依据上述步骤，将代价函数（4-35）转化为预测型，有：

$$\begin{aligned} L(y, u, \Delta u) \triangleq & \sum_{i=1}^P \left\| \omega_{CF} y(k+i+1|k) \right\|_{w_y}^2 \\ & + \sum_{i=1}^P \left\| u(k+i|k) \right\|_{w_u}^2 \\ & + \sum_{i=1}^P \left\| \Delta u(k+i|k) \right\|_{w_{\Delta u}}^2 \end{aligned} \quad (4-42)$$

式（4-42）中， $L(y, u, \Delta u)$ 为预测时域的代价函数， $(k+i|k)$ 表示基于 k 时刻信息对 $k+i$ 时刻的预测， $\|\cdot\|^2$ 为矩阵 2 范数， Δu 为控制增量，定义为：

$$\Delta u(k+i|k) = u(k+i|k) - u(k+i-1|k) \quad (4-43)$$

易知，控制输入 u 的离散差分 Δu 与其导数 \dot{u} 是不同的，二者满足：

$$\dot{u} = \frac{\Delta u}{T_s} \quad (4-44)$$

所以，式（4-42）中 Δu 的权系数 $w_{\Delta u}$ 与式（4-35）中 \dot{u} 的权系数 $w_{\dot{u}}$ 不相同，二者满足：

$$w_{\Delta u} = \frac{w_{\dot{u}}}{T_s^2} \quad (4-45)$$

4.4.2 约束条件的预测型转化

约束条件预测型转化的原理是：保持约束条件的不等式类型和上下界不变，将约束条件扩展到整个预测时域 $[k:k+P-1]$ 内，即约束每个预测点。首先，将跟车

系统输入的约束条件转化为预测型：

$$\begin{aligned} u_{\min} &\leq u(k+i|k) \leq u_{\max} \\ \Delta u_{\min} &\leq \Delta u(k+i|k) \leq \Delta u_{\max} \\ i &= 0:P-1 \end{aligned} \quad (4-46)$$

式 (4-46) 中, $u_{\min}=a_{f\min}$ 为控制输入下界, $u_{\max}=a_{f\max}$ 为控制输入上界, $\Delta u_{\min}=j_{f\min} \cdot T_s$ 为控制增量下界, $\Delta u_{\max}=j_{f\max} \cdot T_s$ 为控制增量上界。其次, 将跟车系统输出的约束条件转化为预测型：

$$\begin{aligned} y_{\min} &\leq y(k+i+1|k) \leq y_{\max} \\ i &= 0:P-1 \end{aligned} \quad (4-47)$$

式 (4-47) 中, y_{\max} 为系统输出 y 的上界, y_{\min} 为系统输出 y 的下界, 定义为：

$$y_{\min} = \begin{bmatrix} \Delta d_{\min} \cdot SDE^{-1} \\ \Delta v_{\min} \cdot SVE^{-1} \\ a_{f\min} \end{bmatrix}, y_{\max} = \begin{bmatrix} \Delta d_{\max} \cdot SDE^{-1} \\ \Delta v_{\max} \cdot SVE^{-1} \\ a_{f\max} \end{bmatrix} \quad (4-48)$$

最后, 与跟车安全性条件相关的补充约束转化为预测型：

$$\begin{aligned} a_{safe} \cdot y(k+i+1|k) &\geq d_{safe} + \tau_{safe} v(k+i+1|k), \\ i &= 0:P-1 \end{aligned} \quad (4-49)$$

式 (4-49) 中, v 是前车加速度干扰, $v(k+i+1|k)$ 表示干扰 v 的预测值。预测时域内, 前车加速度干扰的预测方法将在第 5 章 5.2 节中进一步叙述。式 (4-49) 中, $a_{safe} \in R^{n \times n}$, $d_{safe} \in R^n$ 和 $\tau_{safe} \in R^n$ 为系数矩阵, 定义为：

$$a_{safe} = \begin{bmatrix} 1 & -TTC - r(v_f - v_{fmean}) - \tau_h & 0 \\ 1 & -r(v_f - v_{fmean}) - \tau_h & 0 \\ 0 & 0 & 0 \end{bmatrix}, d_{safe} = \begin{bmatrix} -d_0 \\ d_{s0} - d_0 \\ 0 \end{bmatrix}, \tau_{safe} = \begin{bmatrix} -\tau_h \\ -\tau_h \\ 0 \end{bmatrix} \quad (4-50)$$

综上所述, 系统输入约束 (4-46)、系统输出约束 (4-47) 和补充约束 (4-49) 是 MOCACC 性能指标的预测型约束。

4.4.3 预测优化问题设计及其参数选取

综合节 4.4.1 和节 4.4.2，车辆 MOCACC 的预测优化问题是以式 (4-42) 为代价函数，以系统输入约束 (4-46)、系统输出约束 (4-47) 和补充约束 (4-49) 为约束条件，且符合跟车系统离散状态空间方程 (4-21) 的最优化问题，即：

$$\min_{\Delta u(k+i|k), i=0:P-1} L(y, u, \Delta u)$$

Subj.to.:

- (1) 跟车系统离散状态空间方程：(4-21)
- (2) 跟车系统的 I/O 约束：(4-46)、(4-47)
- (3) 系统输出的补充约束：(4-49)

(4-51)

式 (4-51) 所示的预测优化问题，其参数可分为三部分：(1) 跟车系统离散状态空间方程的参数；(2) 代价函数的参数；(3) 约束条件的参数。

跟车系统离散状态空间方程的参数有 QDC 模型的系数、GVLD 传递函数模型的参数以及采样时间。QDC 模型的系数来源于三名样本驾驶员的平均值，见第 3 章。GVLD 传递函数模型的参数来源于节 4.2.2 对 GVLD 系统的特性辨识，采样时间为 100ms，如表 4.5 所示。

表 4.5 跟车系统离散状态空间方程的参数

参数类别	物理含义	符号	参数值	单位
GVLD 模型	系统增益	K_G	1.05	--
	时间常数	T_G	0.393	s
采样时间		T_s	0.1	s

除了采样时间之外，代价函数的参数有代价函数的权系数、驾驶员跟驰模型的系数、SVE/SDE 模型的系数以及预测时域长度 P 。代价函数的权系数由设计人员根据燃油经济性目标、跟踪性能目标和驾驶员感受目标的偏重进行设置。本文设置代价函数的权系数如表 4.6 所示。驾驶员跟驰模型、SVE/SDE 模型的系数是三名样本驾驶员的平均值，见第 3 章。预测时域长度的设置与 MPC 计算效率和控制最优性相关。当预测时域较长时，MPC 控制性能更接近整个时间域的全局最优，但计算复杂度很大，控制的实时性难以保障。反之，则计算复杂

度降低，但闭环控制的最优性变差。本文以多目标协调控制为目的，最优性是第一位的，故选择较长的预测长度 $P=50$ 。由此带来的高计算复杂度问题将在第5章解决。

表 4.6 代价函数的参数

参数类别	物理含义	符号	参数值	单位
代价函数权系数	Δd 权系数	$w_{y\Delta d}$	0.02	--
	Δv 权系数	$w_{y\Delta v}$	0.025	--
	a_f 权系数	$w_{y\alpha}$	0.5	--
	a_{fdes} 权系数	w_u	5	--
	a_{fdes} 导数的权系数	w_{du}	0.001	--
预测时域长度		P	50	--

除了采样时间 T_s 、预测时域长度 P 和 SVE/SDE 模型参数外，约束条件的参数有纵向乘坐舒适性标准的参数、驾驶员期望跟踪误差范围的参数以及跟车安全性条件的参数。本文设置纵向乘坐舒适性标准的参数值，如表 4.7 所示。驾驶员期望跟踪误差范围的参数来源于第 3 章节 3.4，为三名样本驾驶员的平均值。跟车安全性的参数 TTC 和 d_{s0} 属于前向碰撞报警系统的研究领域，目前已有成熟的研究结果^[68,145]。设置 TTC 和 d_{s0} 的参数值如表 4.7 所示。

表 4.7 约束条件的参数

参数类别	物理含义	符号	参数值	单位
纵向乘坐舒适性标准	加速度下界	a_{fmin}	-1.5	m/s^2
	加速度上界	a_{fmax}	0.5	m/s^2
	加速度导数下界	j_{fmin}	-1	m/s^3
	加速度导数上界	j_{fmax}	1	m/s^3
跟车安全性条件	碰撞时间	TTC	-2.5	s
	固定安全车距	d_{s0}	5	m

4.5 基于 MPC 的车辆 MOCACC 控制算法

MPC 框架下, 车辆 MOCACC 的基本原理是: 通过最小化代价函数 $L(y, u, \Delta u)$, 求解最优控制增量 $\Delta u^*(k+i|k)$, 且满足跟车系统的约束条件和跟车系统离散状态空间方程; 利用 $\Delta u^*(k+i|k)$ 的首元素进行反馈, 实现车辆 MOCACC 系统的闭环控制。

基于 MPC 的车辆 MOCACC 控制算法为:

$$u^*(k) = u(k-1) + \Delta u^*(k+0|k) \quad (4-52)$$

式 (4-52) 中, $u^*(k)$ 是第 k 步的最优控制输入, $u(k-1)$ 为第 $k-1$ 步的控制输入, $\Delta u^*(k+0|k)$ 为最优控制增量的首元素。最优控制增量 $\Delta u^*(k+i|k)$ 是预测优化问题的最优解:

$$\Delta u^*(k+i|k) = \arg \min_{\Delta u(k+i|k), i=0:P-1} L(y, u, \Delta u)$$

Subj. to:

- (1) 跟车系统离散状态空间方程: (4-21)
- (2) 跟车系统的 I/O 约束: (4-46)、(4-47)
- (3) 系统输出的补充约束: (4-49)

该控制算法通过最小化代价函数 $L(y, u, \Delta u)$ 实现跟踪误差、发动机油耗和驾驶员特性误差的优化控制, 通过约束不等式限制跟车系统的控制输入和系统输出, 满足驾驶员纵向乘坐舒适性要求, 驾驶员期望跟踪误差特性和跟车安全性, 达到多目标协调控制的目的。控制算法 (4-52) 中, 控制输入是期望加速度。在 GVLD 系统中, 第 k 步的最优控制输入 $u^*(k)$ 可转化为最优节气门开度 α_{thrdes}^* 和最优制动压力 P_{brkdes}^* 。自适应巡航过程中, α_{thrdes}^* 和 P_{brkdes}^* 是电子节气门和电子真空助力装置的期望控制量。

至此, 基于 MPC 的 MOCACC 控制算法设计完毕。

4.6 本章小结

本章兼顾建模准确性和求解实时性, 建立跟车系统的离散状态空间方程, 对跟踪性能目标、燃油经济性目标和驾驶员感受目标进行数学量化, 建立相应

的预测优化问题，推导出车辆 MOCACC 控制算法。结论如下：

(1) 逆模型法可有效补偿发动机强非线性、变速器挡位离散和空气阻力二次项等非线性环节，使广义车辆纵向动力学系统具有线性输入输出结构。跟车系统建模中，T-S 模糊化法的采用不仅避免了多模型离散化法带来的控制器切换问题，而且建立的离散状态空间方程近似线性，同时满足计算实时性和建模准确性的要求。

(2) 跟踪性能目标的数学量化中，最小化相对车速和车距误差的 2 范数，可保证稳态跟车过程中跟踪误差收敛。驾驶员期望跟踪误差特性的一维分布模型是线性不等式约束，具有限制过大跟踪误差的能力，可避免过长车距引起的频繁前车切入和过短车距造成的跟车安全隐患。基于 TTC 策略和固定安全车距策略设计的跟车安全性条件同时适用于稳态和动态跟车工况，能够有效避免追尾碰撞事故。燃油经济性目标的数学量化中，以车辆加速度水平表征燃油消耗量，不仅可反映跟车过程的车辆燃油经济性，而且避免了使用瞬时油耗量作为代价函数带来的非线性规划问题。驾驶员感受目标的数学量化中，驾驶员期望车距特性由嵌入至车间纵向动力学模型的二次期望车距模型反映。纵向乘坐舒适性标准是加速度及其导数的线性不等式约束，可提高驾驶员纵向乘坐舒适性。以驾驶员特性误差为变量建立 2 范数型代价函数，可最小化跟车系统输出与驾驶员期望轨迹的误差，使自适应巡航控制特性接近驾驶员的动态跟车特性。

第5章 模型预测控制算法实用化问题分析与处理

实车应用中，基于 MPC 的 MOCACC 算法存在三点实用化问题：对模型失配的低鲁棒性、最优控制的非可解和在线优化的高计算复杂度。本章首先分析跟车模型失配的原因，设计基于反馈校正法的鲁棒跟车预测模型，改善车辆 MOCACC 系统的鲁棒性。其次，探讨 I/O 硬约束与求解可行性的关系，采用约束管理法修正预测优化问题，扩展最优控制量的求解可行域。然后，分析优化问题规模与计算复杂度的关系，提出用于提高在线优化计算效率的规模缩减法，并推导出相应的 MPC 快速算法。最后，综合三种实用化处理措施，利用 Dantzig-wolfe 有效集法实现最优控制量的数值求解。以车辆 MOCACC 系统为对象，仿真验证各实用化处理方法的有效性。

5.1 用于 ACC 的 MPC 算法实用化问题分析

第4章基于 MPC 设计了车辆 MOCACC 控制算法。该控制算法的实车应用中，受跟车系统和 MPC 本身特点的限制，存在三点实用化问题，即对模型失配的低鲁棒性、最优控制的非可解和在线优化的高计算复杂度。

第一点实用化问题与跟车预测模型相关。实际车辆对象中，因车辆参数测量误差（如整车质量）或参数时变（如变速器挡位）、未建模动态（如发动机燃烧迟滞、飞轮旋转动态、轮胎滑移和制动系时滞等）和外部干扰（如外界风和道路坡度），跟车系统动力学模型不可避免存在模型不确定性。文献[146]指出，无约束线性 MPC 的鲁棒性等价于线性最优控制方法，因此，MPC 本身对模型失配不具备良好的鲁棒性。当模型不确定性较大时，跟车预测模型存在较大的预测误差，不能准确反映跟车系统的实际特性。此时，车辆 MOCACC 系统的控制误差增大，不仅会削弱跟踪性能，而且可能恶化燃油经济性，甚至使系统丧失多目标协调控制功能。

第二点实用化问题与跟车系统的 I/O 约束相关。第4章设计的 MOCACC 性能指标中，跟车系统的 I/O 约束均属于硬约束，其上下界不能被超越。这与最优解的可行性通常是矛盾的。新一代 ACC 系统中，因燃油经济性目标的存在，其加速和制动能力相对弱化。当前车紧急加速或者制动时，跟踪误差容易到达系

统输出约束的上下界。此时，因系统输出的硬约束不能超越，滚动时域优化的唯一结果是加大控制输入量，增强驱动力或制动力，使车辆紧急加速或制动，以减小跟踪误差。但是，这与控制输入约束是矛盾的。实际的情况是，前车急加速时，期望加速度多处于控制输入约束的上界，无法继续增大驱动力。前车急制动时，期望加速度多处于控制输入约束的下界，也无法继续提高制动力。这时，因为跟车系统惯性的存在，跟踪误差轨迹会沿原方向继续运行一段时间，超过输出约束的边界。当跟车状态处于约束之外时，因硬约束条件不能满足，预测优化问题必然无解，导致自适应巡航控制中止。

第三点实用化问题与 MPC 的在线优化相关。目前，预测控制多用于动态过程缓慢、采样周期较长的工业过程。与一般工业过程相比，跟车系统中，发动机、节气门执行器、制动执行器等总成属于快变对象^[134]，为保证离散控制的性能，控制周期应小于 100ms，这要求 MPC 算法必须具有较高的在线计算效率。MOCACC 控制算法中，因被控对象准线性、代价函数为二次型和约束为线性不等式，其预测优化问题可转化为 QP 问题。与 NP 相比，QP 虽然计算复杂度小，但本文中它的预测长度较长 $P=50$ 。此时，该 QP 问题的待优化变量维数为 50 维，约束集的不等式为 650 个，它的实时求解也是十分困难的。当计算时间超过控制周期时，因优化问题的求解未完成，也会导致自适应巡航控制中断。

5.2 基于反馈校正法的系统鲁棒性增强

本节在比较已有鲁棒 MPC 方法优缺点的基础上，采用反馈校正法设计鲁棒跟车预测模型，提高车辆 MOCACC 系统对模型误差和外部干扰的鲁棒性。

5.2.1 鲁棒跟车预测模型的设计

如第 1 章所述，提升 MPC 鲁棒性的常用方法有三类，即 Min-Max 法、混合控制法和反馈校正法。第一类方法中，因 Min-Max 优化算法的计算量大，求解速度慢，难以用于车辆等快变对象的实时控制。第二类方法虽然不影响计算效率，但附加控制律会影响最优控制功能的实现，对于以多目标协调为控制目标的 ACC 系统来说，也是不适合的。第三类方法，虽然对鲁棒性的提升弱于前两种方法，但它对计算效率和最优功能均无影响。故本节将基于反馈校正法建立鲁棒跟车预测模型，提高它对跟车状态的预测精度。

跟车预测模型的设计基础是跟车系统离散状态空间方程。受车辆参数误差、未建模动态和外部干扰的影响，跟车模型与跟车系统不可避免存在一定失配，其预测输出偏离跟车系统的实际输出。为描述这一差别，定义 k 时刻跟车系统实际状态与跟车模型预测状态之间的误差 $e(k)$ ：

$$e(k) = x(k) - x(k|k-1) \quad (5-1)$$

式 (5-1) 中， $x(k)$ 为 k 时刻的跟车系统状态， $x(k|k-1)$ 为 $k-1$ 时刻对 k 时刻状态的预测量，定义为：

$$x(k|k-1) = Ax(k-1) + Bu(k-1) + Gv(k-1) \quad (5-2)$$

式 (5-2) 中， $x(k-1)$ 为 $k-1$ 时刻的状态，它等于 $k-1$ 时刻跟车输出的测量值， $u(k-1)$ 为 $k-1$ 时刻的控制输入， $v(k-1)$ 为 $k-1$ 时刻的外部干扰。 k 时刻，为提高离散跟车模型的预测精度，利用误差 $e(k)$ 校正状态预测量 $x(k+1|k)$ ：

$$x(k+1|k) = Ax(k) + Bu(k-1) + B\Delta u(k+0|k) + Gv(k) + He(k) \quad (5-3)$$

式 (5-3) 中， $\Delta u(k+0|k)$ 为 $(k+0|k)$ 时刻的控制增量， H 为校正矩阵：

$$H = \begin{bmatrix} h_1 & & 0 \\ & \ddots & \\ 0 & & h_n \end{bmatrix}, \quad 0 < h_i < 1, \quad i = 1:n \quad (5-4)$$

由式 (5-1) 和 (5-2) 知， $e(k)$ 描述了 k 时刻跟车模型与跟车系统的误差信息。在 $k+1$ 时刻利用 $e(k)$ 修正预测状态，可补偿模型失配造成的预测误差，提高其预测精度。类似，将 $k+1$ 时刻的预测量 $x(k+1|k)$ 代入跟车模型，有 $k+2$ 时刻的状态预测量：

$$\begin{aligned} x(k+2|k) &= A^2x(k) + AHe(k) \\ &+ (B + AB)u(k-1) + (AB + B)\Delta u(k+0|k) + B\Delta u(k+1|k) \\ &+ AGv(k) + Gv(k+1|k) \end{aligned} \quad (5-5)$$

预测时域内，依次类推，得到 $k+i$ 时刻的状态预测量 $x(k+i|k)$ 。将 $x(k+i|k)$ 代入跟车系统的输出方程，有鲁棒跟车预测模型：

$$\begin{aligned}
 y(k+i|k) &= CA^i x(k) + CA^{i-1} He(k) \\
 &\quad + C \sum_{m=0}^{i-1} A^{i-1-m} \left(Bu(k-1) + B \sum_{j=0}^m \Delta u(k+j|k) \right) \\
 &\quad + C \sum_{m=0}^{i-1} A^{i-1-m} \left(\sum_{j=0}^m Gv(k+m|k) \right) \\
 i &= 1:P
 \end{aligned} \tag{5-6}$$

式 (5-5) 和 (5-6) 中, $\Delta u(k+i|k)$ 为 $k+i$ 时刻的控制增量, $y(k+i|k)$ 为 $k+i$ 时刻的系统输出, $v(k+i|k)$ 为 $k+i$ 时刻外部干扰。MPC 算法中, 因反馈校正项补偿了模型失配造成的预测误差, 更好地反映跟车系统的实际特性, 能够增强车辆 MOCACC 系统对模型失配的鲁棒性。

5.2.2 前车加速度的预测器设计

式 (5-6) 中, $\Delta u(k+i|k)$ 属于待优化变量。为求解待优化变量, 鲁棒跟车预测模型中, 除 $\Delta u(k+i|k)$ 之外的其他变量必须是可知的 (“可知” 表示 “可直接测量” 或 “可间接推导”)。跟车状态 $x(k)$, 状态误差 $e(k)$ 、控制输入 $u(k-1)$ 均为已知量, 只有预测时域的外部干扰 $v(k+i|k)_{i=1:P}$ 是未知的, 需要对其进行预测。

按照预测模式的不同, 外部干扰预测器有两类。第一类称为 Look Ahead 模式^[147]。若未来时刻的干扰可测量, $v(k+i|k)_{i=1:P}$ 可直接使用测量值代替预测值。例如, 对于道路坡度干扰, 当车辆装有 GPS 和 GIS 时, 利用二者可预先计算前方道路的坡度, 作为干扰的预测值。第二类称为递推模式^[147]。若未来时刻的干扰无法测量, $v(k+i|k)$ 则只能由以前时刻的干扰量递推得到。ACC 系统中, 外部干扰是前车加速度, 它在预测时域内是不可测量的。故, 采用零阶保持 (FOH, First Order Hold) 法递推预测时域的前车加速度:

$$\begin{aligned}
 v(k+1|k) &= \hat{v}(k) \\
 v(k+i+1|k) &= v(k+i|k), \quad i=1:P
 \end{aligned} \tag{5-7}$$

式 (5-7) 中, $\hat{v}(k)$ 为 k 时刻 $v(k)$ 的估计值:

$$\hat{v}(k) = a_f(k) + \Delta \hat{a}(k) \tag{5-8}$$

式 (5-8) 中, $\Delta \hat{a}$ 为相对加速度的估计值。目前, 车载雷达的输出信号只有

车间距离和相对车速，缺少相对加速度量。本文借鉴文[137]提出的四阶 Kalman 滤波器，设计相对加速度的估计器。以车间距离 d ，相对车速 Δv 、相对加速度 Δa 和相对加速度导数 Δj 为状态变量，建立雷达系统的离散状态空间方程：

$$\begin{aligned}\xi(k+1) &= F_r \cdot \xi(k) + G_r \cdot v(k) \\ \varsigma(k) &= H_r \cdot \xi(k) + w(k)\end{aligned}$$

$$F_r = \begin{bmatrix} 1 & T_s & T_s^2/2 & T_s^3/6 \\ 0 & 1 & T_s & T_s^2/2 \\ 0 & 0 & 1 & T_s \\ 0 & 0 & 0 & 1 \end{bmatrix}, G_r = \begin{bmatrix} T_s^4/24 \\ T_s^3/6 \\ T_s^2/2 \\ T_s \end{bmatrix}, H_r = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \quad (5-9)$$

式 (5-9) 中， $\xi = [d \ \Delta v \ \Delta a \ \Delta j]^T$ 是系统状态， ς 是系统输出的观测值，为雷达输出的车间距离和相对车速， F_r, G_r, H_r 为系统矩阵， $v \in R^1$ 是系统噪声， $w = [w_d, w_{\Delta v}]^T \in R^2$ 是测量噪声（ w_d 为车间距离的测量噪声， $w_{\Delta v}$ 为相对车速的测量噪声）， $T_s=0.1s$ 为采样频率。对于雷达系统 (5-9)，它的离散 Kalman 估计器为：

$$\begin{aligned}\hat{\xi}(k+1|k) &= (F_r - L \cdot H_r) \hat{\xi}(k|k-1) + L \cdot \varsigma(k) \\ \hat{\xi}(k) &= (I - M \cdot H_r) \hat{\xi}(k|k-1) + M \cdot \varsigma(k)\end{aligned} \quad (5-10)$$

式 (5-10) 中， $L \in R^{4 \times 2}$ 为增益矩阵， $M \in R^{4 \times 2}$ 为新息矩阵， $\hat{\xi}$ 是状态估计值， I 是 4×4 维的单位阵。

为求解增益矩阵和新息矩阵，需知测量噪声 w 的方差 δ_w^2 、系统噪声 v 的方差 δ_v^2 以及 w 和 v 的协方差。测量噪声 w 主要来源于：（1）雷达本身对 d 和 Δv 的测量误差；（2）CAN 总线传输信号的量化误差。以车载雷达的实验数据为基础，分别统计 d 和 Δv 的方差，获得 w 的方差 δ_w^2 ：

$$\delta_w^2 = \begin{bmatrix} 0.8 & 0 \\ 0 & 0.5 \end{bmatrix} \quad (5-11)$$

本质上，系统噪声 v 反应了前车加速度导数的信息，同测量噪声方差的计算方法一样，它的方差可通过统计方法获得。但是前车加速度导数信号不一定是白噪声，而且随交通工况不同有很大差异，因此它的方差较难根据统计方法给定。从 Kalman 滤波的理论角度看， δ_v^2 可看作性能指标的设计参数，通过调整它

以获得近似最佳的滤波效果即可。因此,本文通过统计方法先大致设定一个 δ_v^2 的初始值,通过仿真不断调整该值,直到达到较好的相对加速度估计效果。按上述方法,确定系统噪声的方差为:

$$\delta_v^2 = 1.5 \quad (5-12)$$

对于 w 和 v 的协方差,易知系统噪声与测量噪声之间不相关,所以二者的协方差为零。利用离散 Riccati 方程求解得到 Kalman 估计器的增益矩阵 L 和新息矩阵 M :

$$L = \begin{bmatrix} 0.078 & 0.100 \\ 0.052 & 0.225 \\ 0.025 & 0.264 \\ 0.006 & 0.154 \end{bmatrix}, M = \begin{bmatrix} 0.074 & 0.079 \\ 0.049 & 0.199 \\ 0.025 & 0.248 \\ 0.006 & 0.154 \end{bmatrix} \quad (5-13)$$

式 (5-10) 所示的离散 Kalman 估计器中,状态估计值 $\hat{\xi}(k)$ 的第三个元素是相对加速度的估计值 $\Delta\hat{a}$ 。

5.2.3 前车加速度预测器的效果验证

为验证 Kalman 估计器对相对加速度的估计效果,利用 Simulink 搭建仿真模型,其结构如图 5.1 所示。它包括跟车系统模型,雷达模型和 Kalman 估计器。




图 5.1 Kalman 估计器仿真模型的结构

该仿真模型中,系统噪声 w 输入跟车系统模型,经三个积分器后有相对加速度、相对车速和车间距离。系统噪声 w 利用白噪声发生器生成,方差为 1.5。雷达模型模拟雷达测量及其信号传输过程,一是增加了 Δv 和 d 的测量噪声,二是采用量化器将 Δv 和 d 转化为数字量化信号。 Δv 和 d 测量噪声的方差分别为 0.8

和 0.5, 量化精度与雷达 CAN 总线的传输精度一致, 分别为 0.2m/s 和 1m。仿真模型中, 记 Δv_r 为 Δv 的测量值, d_r 为 d 的测量值, 相对加速度的测量值 Δa_r 与 Δa 一致。

图 5.2 是 Kalman 估计器的仿真结果, 其中, 灰线是测量值, 实线是估计值。由图 5.2 知, 所开发的 Kalman 估计器不仅可以较好估计跟车系统的相对加速度, 见图 (a), 而且平滑了雷达直接测量信号的噪声, 如图 (b) 的相对车速。




图 5.2 Kalman 估计器的仿真结果

另外, 利用一段实车测量的雷达信号, 验证零阶保持 (ZOH) 法对前车加速度的预测效果, 如图 5.3。图 5.3 中, 灰线是前车加速度估计值, 图 5.3 (a) 的粗点线是 ZOH 法的预测结果。图 (a) 中, 粗点线有六条, 分别表示 $k=20$ 、65、100、160、210 和 240 处的前车加速度预测值。作为 ZOH 法的对比, 以一阶保持 (FOH, First Order Hold) 法递推前车加速度预测值, 结果如图 (b) 的粗点线。




图 5.3 前车加速度干扰的预测

由图 5.3 知,当前车匀速行驶时,ZOH 和 FOH 预测值与估计值均比较吻合。当前车处于加速或减速阶段时,因 FOH 充分利用了加速度导数信息,其预测精度优于 ZOH 预测。但加速度导数突变点处,FOH 预测的效果很差,与前车加速度的误差较大。若前车处于加减速工况中,其加速度导数突变点很多,反而导致 FOH 预测性能比 ZOH 差。而且加速过程中,ZOH 预测值低于实际前车加速度,减速阶段,ZOH 的预测值高于实际前车加速度。从整体上看,ZOH 的预测值比实车加速度更舒缓。因新一代 ACC 系统中,MPC 控制算法是利用前车加速度预测值求解的,相对舒缓的预测值可降低最优控制输入量,这有利于提高燃油经济性,所以,ZOH 优于 FOH。

5.2.4 鲁棒跟车预测模型的矩阵型转化

为便于滚动时域优化求解,将鲁棒跟车预测模型转化为矩阵形式。定义预测时域的系统输出向量 \mathbf{Y} 、控制输入向量 \mathbf{U} 、控制增量向量 $\Delta \mathbf{U}$ 和外部干扰向量 \mathbf{V} :

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}(k+1|k) \\ \vdots \\ \mathbf{y}(k+P|k) \end{bmatrix}, \quad \mathbf{U} = \begin{bmatrix} \mathbf{u}(k+0|k) \\ \vdots \\ \mathbf{u}(k+P-1|k) \end{bmatrix} \quad (5-14)$$

$$\Delta U = \begin{bmatrix} \Delta u(k+0|k) \\ \dots \\ \Delta u(k+P-1|k) \end{bmatrix}, V = \begin{bmatrix} v(k+0|k) \\ \dots \\ v(k+P-1|k) \\ v(k+P|k) \end{bmatrix} \quad (5-15)$$

式(5-14)和(5-15)中, $Y \in R^{P \cdot n}$ 称为预测系统输出, $U \in R^{P \cdot m}$ 称预测控制输入, $\Delta U \in R^{P \cdot m}$ 称预测控制增量, $V \in R^{(P+1)q}$ 称预测外部干扰。将鲁棒跟车预测模型(5-6)代入预测系统输出 Y , 并结合 ΔU 、 U 和 V 定义式, 整理有:

$$Y = [S_x + S_e H]x(k) + S_{uI}u(k-1) + S_u \Delta U - S_e Hx(k|k-1) + H_v V \quad (5-16)$$

式(5-16)为鲁棒跟车预测模型的矩阵形式。其中, $S_x \in R^{(P \cdot n) \times l}$, $S_{uI} \in R^{(P \cdot n) \times m}$, $S_u \in R^{(P \cdot n) \times (P \cdot m)}$, $S_e \in R^{n \times P \cdot l}$, $H_v \in R^{(P \cdot n) \times (P+1)q}$ 为系数矩阵:

$$S_x = \begin{bmatrix} CA \\ CA^2 \\ \dots \\ CA^P \end{bmatrix}, S_{uI} = \begin{bmatrix} CB \\ C(AB+B) \\ \dots \\ \sum_{m=0}^{P-1} CA^m B \end{bmatrix}$$

$$S_u = \begin{bmatrix} CB & 0 & \dots & 0 \\ C(AB+B) & CB & \dots & 0 \\ \dots & \dots & \dots & \dots \\ \sum_{m=0}^{P-1} CA^m B & \sum_{m=0}^{P-2} CA^m B & \dots & CB \end{bmatrix} \quad (5-17)$$

$$S_e = \begin{bmatrix} C \\ CA \\ \dots \\ CA^{P-1} \end{bmatrix}, H_v = \begin{bmatrix} CG & 0 & 0, \dots & 0 \\ CAG & CG & 0, \dots & 0 \\ \dots & \dots & \dots & \dots \\ CA^{P-1}G & CA^{P-2}G & \dots & 0 \end{bmatrix}$$

本质上, 式(5-16)反映了预测时域内, 预测系统输出 Y 与预测控制增量 ΔU 的关系。此外, 预测控制输入 U 和预测控制增量 ΔU 也不是相互独立的, 它们之间服从关系式:

$$\begin{aligned} u(k+i|k) &= u(k+i-1|k) + \Delta u(k+i|k) \\ i &= 0:P-1 \end{aligned} \quad (5-18)$$

将式 (5-18) 代入预测控制输入 U 的定义式, 整理有:

$$U = T_{ul} \cdot u(k-1) + T_{\Delta u} \Delta U \quad (5-19)$$

式 (5-19) 中, $T_{ul} \in R^{(P \cdot m) \times m}$ 、 $T_{\Delta u} \in R^{(P \cdot m) \times (P \cdot m)}$ 为系数矩阵:

$$T_{ul} = \begin{bmatrix} I_{m \times m} \\ I \\ \dots \\ I \end{bmatrix}, T_{\Delta u} = \begin{bmatrix} I_{m \times m} & 0 & 0 \\ I & I & 0 \\ & \ddots & \\ I & I & I \end{bmatrix} \quad (5-20)$$

式 (5-20) 中, I 是 $m \times m$ 单位矩阵。式 (5-19) 反映了预测时域内, 预测控制输入 U 和预测控制增量 ΔU 的关系。同鲁棒预测模型的矩阵型一样, 它也是滚动时域优化求解的必要组成部分。

5.3 基于约束管理法的求解可行域扩展

由节 5.1 知, 最优控制量的非可解问题是由跟车系统的 I/O 硬约束造成的。本节将基于约束管理法修正预测优化问题的代价函数, 松弛 I/O 硬约束, 扩展车辆 MOCACC 控制算法的求解可行域。

5.3.1 输入输出硬约束的松弛化

约束管理法是解决非可解问题有效方法之一^[147]。其基本原理为: 当控制输入或系统输出超出约束范围时, 利用松弛因子扩大约束的上下界, 消除硬约束的强制性, 保证预测优化问题可解。按照松弛因子的类型, 它分为两类: 第一类称向量松弛因子法, 第二类称标量松弛因子法^[147]。前者中, 松弛因子是与 I/O 约束维数相同的向量, 可对 I/O 约束的各不等式分别松弛化。后者中, 松弛因子为标量, 它结合松弛系数对 I/O 约束进行整体松弛化。与前者相比, 后者虽然对约束的软化是整体性的, 不利于区别对待不同约束变量, 但它仅增大一维待优化变量, 对计算效率基本无影响, 适用于车辆 ACC 对象。

MOCACC 性能指标中, I/O 约束集包括纵向乘坐舒适性标准、驾驶员期望跟踪误差范围和跟车安全性条件, 均为硬约束。前两者反映了驾驶员乘坐舒适性要求和驾驶员对跟踪误差的容许程度, 后者用于保证跟车过程的安全性。对于前两者, 稍微扩大约束条件的上下界, 仅仅弱化舒适性程度和跟踪性能, 不影响 ACC 的正常工作, 但是对于跟车安全性约束, 降低其下界, 则意味着可能发生追尾碰撞事故, 不适合采用软约束。因此本文仅对前两者的约束 (4-46) 和 (4-47) 松弛化, 而不处理与跟车安全性相关的补充约束 (4-49)。对 (4-46) 和 (4-47) 进行松弛化, 有:

$$\begin{aligned}
 u_{\min} + \varepsilon v_{\min}^u &\leq u(k+i|k) \leq u_{\max} + \varepsilon v_{\max}^u \\
 \Delta u_{\min} + \varepsilon v_{\min}^{\Delta u} &\leq \Delta u(k+i|k) \leq \Delta u_{\max} + \varepsilon v_{\max}^{\Delta u}, \quad i=0, \dots, P-1 \\
 y_{\min} + \varepsilon v_{\min}^y &\leq y(k+i+1|k) \leq y_{\max} + \varepsilon v_{\max}^y \\
 \varepsilon &\geq 0 \\
 v_{\max}^u &\geq 0, v_{\max}^{\Delta u} \geq 0, v_{\max}^y \geq 0 \\
 v_{\min}^u &\leq 0, v_{\min}^{\Delta u} \leq 0, v_{\min}^y \leq 0
 \end{aligned} \tag{5-21}$$

式 (5-21) 中, $\varepsilon \in R^+$ 称为松弛因子, $v_{\min}^u \in R^m$ 为控制输入下界的松弛系数, $v_{\max}^u \in R^m$ 为控制输入上界的松弛系数, $v_{\min}^{\Delta u} \in R^m$ 为控制增量下界的松弛系数, $v_{\max}^{\Delta u} \in R^m$ 为控制增量上界的松弛系数, $v_{\min}^y \in R^n$ 为系统输出下界的松弛系数, $v_{\max}^y \in R^n$ 为系统输出上界的松弛系数。松弛系数用于反映松弛因子对不同变量以及变量各分量的松弛程度。因松弛因子是标量, 一旦松弛系数固定后, 式 (5-21) 中各变量以及变量各分量的松弛程度是等比例的, 也就是说, 它们的约束范围只能等比例增大或减小。

不等式 (5-21) 通过引入松弛因子和松弛系数, 作用于控制输入、控制增量和系统输出的约束条件被松弛化, 称为软约束。

5.3.2 带松弛因子的代价函数设计

为避免约束上下界被松弛因子无限扩大, 失去约束不等式对系统输入输出的限制作用, 通常将松弛因子的 2 范数融于代价函数, 对松弛因子进行惩罚。为此, 定义一种带松弛因子的代价函数:

$$\Psi(y, u, \Delta u, \varepsilon) \triangleq L(y, u, \Delta u) + \rho \varepsilon^2 \tag{5-22}$$

式 (5-22) 中, $\Psi(y, u, \Delta u, \varepsilon)$ 为带松弛因子的代价函数, $\rho \in R^+$ 为惩罚系数。以式 (5-22) 为代价函数, 式 (5-21) 为跟车系统的软 I/O 约束, 结合跟车系统的离散状态空间方程 (4-21) 以及补充约束 (4-49), 建立预测优化问题:

$$[\Delta u^*(k+i|k), \varepsilon^*] = \arg \min_{\varepsilon, \Delta u(k+i|k), i=0:P-1} \Psi(y, u, \Delta u, \varepsilon)$$

Subj. to:

- (1) 跟车系统离散状态空间方程: (4-21)
- (2) 跟车系统的 I/O 软约束: (5-21)
- (3) 系统输出的补充约束: (4-49)

(5-23)

上述预测优化问题中, 当系统输入输出不满足 I/O 硬约束时, 滚动时域优化求解会自动增大松弛因子 ε , 扩展 I/O 软约束的范围, 保证 $\Delta u(k+i|k)$ 的最优解存在。代价函数中, 松弛因子的二次项限制 ε 的增大, 惩罚软约束的松弛程度, 使闭环系统自动在求解可行性和约束松弛程度之间寻找平衡点。惩罚系数 ρ 越大, 松弛因子扩展约束范围的能力越弱, 反之, 能力增强。同一松弛因子下, 松弛系数越大或分系数越大, 对相应变量或变量分量的松弛程度越大, 反之越小。

当系统输入输出满足硬约束时, 松弛因子自动为零, I/O 软约束 (5-21) 退化为 I/O 硬约束 (4-46) 和 (4-47)。此时, 基于约束管理的预测优化问题等价于原问题 (4-51)。

另外, 自适应巡航过程中, 若车间距离接近跟车安全性条件的边界时, 因控制输入量为软约束, 预测优化问题 (5-23) 可自动降低期望加速度的下界, 采用大制动强度减速, 以减弱车间距离接近安全车距的速度, 避免追尾碰撞事故。这说明, 不对跟车安全性约束松弛化, 对保障跟车安全性是有利的, 而且因期望加速度软约束的存在, 不会导致非求解问题。

5.3.3 代价函数和约束条件的矩阵型转化

同鲁棒跟车预测模型的矩阵型转化一致, 为便于数值求解, 把带松弛因子的代价函数、I/O 软约束以及补充约束转化为矩阵形式。首先, 在预测时域内, 整理代价函数 (5-22) 为矩阵型, 有:

$$\begin{aligned}
 \Psi(y, u, \Delta u, \varepsilon) = & \begin{bmatrix} \omega_{CF} \cdot y(k+1|k) \\ \dots \\ \omega_{CF} \cdot y(k+P|k) \end{bmatrix}^T \begin{bmatrix} w_y & & 0 \\ & \ddots & \\ 0 & & w_y \end{bmatrix} \begin{bmatrix} \omega_{CF} \cdot y(k+1|k) \\ \dots \\ \omega_{CF} \cdot y(k+P|k) \end{bmatrix} \\
 & + \begin{bmatrix} u(k+0|k) \\ \dots \\ u(k+P-1|k) \end{bmatrix}^T \begin{bmatrix} w_u & & 0 \\ & \ddots & \\ 0 & & w_u \end{bmatrix} \begin{bmatrix} u(k+0|k) \\ \dots \\ u(k+P-1|k) \end{bmatrix} \\
 & + \begin{bmatrix} \Delta u(k+0|k) \\ \dots \\ \Delta u(k+P-1|k) \end{bmatrix}^T \begin{bmatrix} w_{\Delta u} & & 0 \\ & \ddots & \\ 0 & & w_{\Delta u} \end{bmatrix} \begin{bmatrix} \Delta u(k+0|k) \\ \dots \\ \Delta u(k+P-1|k) \end{bmatrix} \\
 & + \varepsilon(k) \rho \varepsilon(k)
 \end{aligned} \quad (5-24)$$

将预测系统输出 Y ，预测控制输入 U 和预测控制增量 ΔU 代入上式，并分离 Y 与跟驰特性矩阵 ω_{CF} ，整理有矩阵型代价函数：

$$\begin{aligned}
 \Psi(Y, U, \Delta U, \varepsilon) = & (\Omega_{CF} Y)^T W_y (\Omega_{CF} Y) + U^T W_u U \\
 & + \Delta U^T W_{\Delta u} \Delta U + \varepsilon(k) \rho \varepsilon(k)
 \end{aligned} \quad (5-25)$$

式 (5-25) 中， Ω_{CF} 为预测时域的跟驰特性矩阵， $W_y \in R^{P \cdot n \times P \cdot n}$ 为预测系统输出的权矩阵， $W_u \in R^{P \cdot m \times P \cdot m}$ 为预测控制输入的权矩阵， $W_{\Delta u} \in R^{P \cdot n \times P \cdot n}$ 为预测控制增量的权矩阵，有：

$$\begin{aligned}
 \Omega_{CF} = & \begin{bmatrix} \omega_{CF} & & 0 \\ & \ddots & \\ 0 & & \omega_{CF} \end{bmatrix} \\
 W_y = & \begin{bmatrix} w_y & & 0 \\ & \ddots & \\ 0 & & w_y \end{bmatrix}, W_u = \begin{bmatrix} w_u & & 0 \\ & \ddots & \\ 0 & & w_u \end{bmatrix}, W_{\Delta u} = \begin{bmatrix} w_{\Delta u} & & 0 \\ & \ddots & \\ 0 & & w_{\Delta u} \end{bmatrix}
 \end{aligned} \quad (5-26)$$

易知， W_y 、 W_u 、 $W_{\Delta u}$ 三者均对称正定。同理，预测时域内，将跟车系统的 I/O 软约束 (5-21) 和补充约束 (4-49) 转化为矩阵型。以控制输入的上界约束为例，说明矩阵型 I/O 约束的转化过程。

定义预测控制输入 U 的上界 U_{\max} 和上界松弛向量 V_{\max}^u ：

$$\mathbf{U}_{\max} \triangleq \begin{bmatrix} u_{\max} \\ \dots \\ u_{\max} \end{bmatrix}, \mathbf{V}_{\max}^u \triangleq \begin{bmatrix} v_{\max}^u \\ \dots \\ v_{\max}^u \end{bmatrix} \quad (5-27)$$

式 (5-27) 中, $\mathbf{U}_{\max} \in R^{P \cdot m}$, $\mathbf{V}_{\max}^u \in R^{P \cdot m}$ 。预测时域内, 将控制输入的上界约束写成向量形式:

$$\begin{bmatrix} u(k+0|k) \\ \dots \\ u(k+P-1|k) \end{bmatrix} \leq \begin{bmatrix} u_{\max} \\ \dots \\ u_{\max} \end{bmatrix} + \begin{bmatrix} v_{\max}^u \\ \dots \\ v_{\max}^u \end{bmatrix} \varepsilon \quad (5-28)$$

将 \mathbf{U} 、 \mathbf{U}_{\max} 和 \mathbf{V}_{\max}^u 的定义式代入式 (5-28), 整理有控制输入上界约束的矩阵型:

$$\begin{bmatrix} \mathbf{I}_U & -\mathbf{V}_{\max}^u \end{bmatrix} \begin{bmatrix} \mathbf{U} \\ \varepsilon \end{bmatrix} \leq \mathbf{U}_{\max} \quad (5-29)$$

式 (5-29) 中, $\mathbf{I}_U \in R^{mP \times mP}$ 为单位矩阵。类似, 控制输入下界约束的矩阵型, 见式 (5-30), 控制增量上下界约束的矩阵型, 见 (5-31) 和 (5-32), 系统输出上下界约束的矩阵型, 见 (5-33) 和 (5-34)。

$$\begin{bmatrix} -\mathbf{I}_U & \mathbf{V}_{\min}^u \end{bmatrix} \begin{bmatrix} \mathbf{U} \\ \varepsilon \end{bmatrix} \leq -\mathbf{U}_{\min} \quad (5-30)$$

$$\begin{bmatrix} \mathbf{I}_{\Delta U} & -\mathbf{V}_{\max}^{\Delta u} \end{bmatrix} \begin{bmatrix} \Delta \mathbf{U} \\ \varepsilon \end{bmatrix} \leq \Delta \mathbf{U}_{\max} \quad (5-31)$$

$$\begin{bmatrix} -\mathbf{I}_{\Delta U} & \mathbf{V}_{\min}^{\Delta u} \end{bmatrix} \begin{bmatrix} \Delta \mathbf{U} \\ \varepsilon \end{bmatrix} \leq -\Delta \mathbf{U}_{\min} \quad (5-32)$$

$$\begin{bmatrix} \mathbf{I}_Y & -\mathbf{V}_{\max}^y \end{bmatrix} \begin{bmatrix} \mathbf{Y} \\ \varepsilon \end{bmatrix} \leq \mathbf{Y}_{\max} \quad (5-33)$$

$$\begin{bmatrix} -I_Y & V_{\min}^y \end{bmatrix} \begin{bmatrix} Y \\ \varepsilon \end{bmatrix} \leq -Y_{\min} \quad (5-34)$$

式 (5-30) 中, $U_{\min} \in R^{P \cdot m}$ 为预测控制输入的下界, $V_{\min}^u \in R^{P \cdot m}$ 为预测控制输入的下界松弛向量, 定义为:

$$U_{\min} \triangleq \begin{bmatrix} u_{\min} \\ \dots \\ u_{\min} \end{bmatrix}, \quad V_{\min}^u \triangleq \begin{bmatrix} v_{\min}^u \\ \dots \\ v_{\min}^u \end{bmatrix} \quad (5-35)$$

式 (5-31) 和 (5-32) 中, $I_{\Delta U} \in R^{mP \times mP}$ 为单位矩阵, $\Delta U_{\max} \in R^{P \cdot m}$ 为预测控制增量的上界, $V_{\max}^{\Delta U} \in R^{P \cdot m}$ 为预测控制增量的上界松弛向量, $\Delta U_{\min} \in R^{P \cdot m}$ 为预测控制增量的下界, $V_{\min}^{\Delta U} \in R^{P \cdot m}$ 为预测控制增量的下界松弛向量, 定义为:

$$\begin{aligned} \Delta U_{\max} &\triangleq \begin{bmatrix} \Delta u_{\max} \\ \dots \\ \Delta u_{\max} \end{bmatrix}, \quad V_{\max}^{\Delta U} \triangleq \begin{bmatrix} v_{\max}^{\Delta U} \\ \dots \\ v_{\max}^{\Delta U} \end{bmatrix} \\ \Delta U_{\min} &\triangleq \begin{bmatrix} \Delta u_{\min} \\ \dots \\ \Delta u_{\min} \end{bmatrix}, \quad V_{\min}^{\Delta U} \triangleq \begin{bmatrix} v_{\min}^{\Delta U} \\ \dots \\ v_{\min}^{\Delta U} \end{bmatrix} \end{aligned} \quad (5-36)$$

式 (5-33) 和 (5-34) 中, $I_Y \in R^{nP \times nP}$ 为单位矩阵, $Y_{\max} \in R^{P \cdot n}$ 为预测系统输出的上界, $V_{\max}^y \in R^{P \cdot n}$ 为预测系统输出的上界松弛向量, $Y_{\min} \in R^{P \cdot n}$ 为预测系统输出的下界, $V_{\min}^y \in R^{P \cdot n}$ 为预测系统输出的下界松弛向量, 定义为:

$$\begin{aligned} Y_{\max} &\triangleq \begin{bmatrix} y_{\max} \\ \dots \\ y_{\max} \end{bmatrix}, \quad V_{\max}^y \triangleq \begin{bmatrix} v_{\max}^y \\ \dots \\ v_{\max}^y \end{bmatrix} \\ Y_{\min} &\triangleq \begin{bmatrix} y_{\min} \\ \dots \\ y_{\min} \end{bmatrix}, \quad V_{\min}^y \triangleq \begin{bmatrix} v_{\min}^y \\ \dots \\ v_{\min}^y \end{bmatrix} \end{aligned} \quad (5-37)$$

对于补充约束 (4-49), 转化为矩阵型, 有:

$$A_{safe} \cdot Y \geq D_{safe} + T_{safe} \cdot V_+ \quad (5-38)$$

式 (5-38) 中, $A_{safe} \in R^{P \cdot n \times P \cdot n}$, $D_{safe} \in R^{P \cdot n}$, $T_{safe} \in R^{P \cdot n \times q}$, $V_+ \in R^{P \cdot q}$, 定义为:

$$A_{safe} = \begin{bmatrix} a_{safe} & & \\ & \ddots & \\ & & a_{safe} \end{bmatrix}, D_{safe} = \begin{bmatrix} d_{safe} \\ \vdots \\ d_{safe} \end{bmatrix} \quad (5-39)$$

$$T_{safe} = \begin{bmatrix} \tau_{safe} \\ \vdots \\ \tau_{safe} \end{bmatrix}, V_+ = \begin{bmatrix} v(k+1|k) \\ \dots \\ v(k+P|k) \end{bmatrix}$$

综上所述, 代价函数的矩阵型由式 (5-25) 描述, 约束条件的矩阵型由式 (5-29)、(5-30)、(5-31)、(5-32)、(5-33)、(5-34) 和 (5-38) 描述。

5.4 基于规模缩减法的计算效率提升

本节以静态优化问题的规模分析为基础, 回顾变量集结策略的基本思想, 提出约束集压缩策略, 结合二者建立问题规模缩减的基本框架, 并推导出一种 MPC 快速算法, 为车辆 MOCACC 控制算法的实车应用奠定基础。

5.4.1 静态优化问题的计算复杂度分析

MPC 的预测优化问题均可转化静态优化问题, 如线性规划 (LP, Linear Programming)、二次规划 (QP, Quadratic Programming) 等, 以便于数值求解最优控制量。车辆 MOCACC 控制算法中, 因跟车系统的离散状态空间方程是准线性的, 代价函数为二次型, 约束条件为线性不等式, 其预测优化问题 (5-23) 可转化为形如 (5-40) 的 QP 问题。

$$\begin{aligned}
 & \min_{\Delta U, \varepsilon} \begin{bmatrix} \Delta U \\ \varepsilon \end{bmatrix}^T \begin{bmatrix} \mathbf{H} & \mathbf{0} \\ \mathbf{0} & \rho \end{bmatrix} \begin{bmatrix} \Delta U \\ \varepsilon \end{bmatrix} + 2 \begin{bmatrix} \mathbf{f} \\ 0 \end{bmatrix}^T \begin{bmatrix} \Delta U \\ \varepsilon \end{bmatrix} \\
 & \quad (1) \Omega_{\min}^U \cap \Omega_{\max}^U \\
 & \text{Subj. to.:} \quad (2) \Omega_{\min}^{\Delta U} \cap \Omega_{\max}^{\Delta U} \\
 & \quad (3) \Omega_{\min}^Y \cap \Omega_{\max}^Y \cap \Omega_{safe}^Y
 \end{aligned} \tag{5-40}$$

式 (5-40) 中, $\mathbf{H} \in R^{mP \times mP}$ 为正定 Hessian 矩阵, $\mathbf{f} \in R^{mP}$ 为一次项矩阵, Ω_{\min}^U 、 Ω_{\max}^U 为预测控制输入约束构成的集合, $\Omega_{\min}^{\Delta U}$ 、 $\Omega_{\max}^{\Delta U}$ 为预测控制增量约束构成的集合, Ω_{\min}^Y 、 Ω_{\max}^Y 和 Ω_{safe}^Y 为预测系统输出约束构成的集合, 有:

$$\begin{aligned}
 \Omega_{\max}^U & \triangleq \left\{ \mathbf{U}, \varepsilon \left| \begin{bmatrix} \mathbf{I}_U & -\mathbf{V}_{\max}^u \end{bmatrix} \begin{bmatrix} \mathbf{U} \\ \varepsilon \end{bmatrix}^T \leq \mathbf{U}_{\max} \right. \right\} \\
 \Omega_{\min}^U & \triangleq \left\{ \mathbf{U}, \varepsilon \left| \begin{bmatrix} -\mathbf{I}_U & \mathbf{V}_{\min}^u \end{bmatrix} \begin{bmatrix} \mathbf{U} \\ \varepsilon \end{bmatrix}^T \leq -\mathbf{U}_{\min} \right. \right\}
 \end{aligned} \tag{5-41}$$

$$\begin{aligned}
 \Omega_{\max}^{\Delta U} & \triangleq \left\{ \Delta \mathbf{U}, \varepsilon \left| \begin{bmatrix} \mathbf{I}_{\Delta U} & -\mathbf{V}_{\max}^{\Delta u} \end{bmatrix} \begin{bmatrix} \Delta \mathbf{U} \\ \varepsilon \end{bmatrix}^T \leq \Delta \mathbf{U}_{\max} \right. \right\} \\
 \Omega_{\min}^{\Delta U} & \triangleq \left\{ \Delta \mathbf{U}, \varepsilon \left| \begin{bmatrix} -\mathbf{I}_{\Delta U} & \mathbf{V}_{\min}^{\Delta u} \end{bmatrix} \begin{bmatrix} \Delta \mathbf{U} \\ \varepsilon \end{bmatrix}^T \leq -\Delta \mathbf{U}_{\min} \right. \right\}
 \end{aligned} \tag{5-42}$$

$$\begin{aligned}
 \Omega_{\max}^Y & \triangleq \left\{ \mathbf{Y}, \varepsilon \left| \begin{bmatrix} \mathbf{I}_Y & -\mathbf{V}_{\max}^y \end{bmatrix} \begin{bmatrix} \mathbf{Y} \\ \varepsilon \end{bmatrix}^T \leq \mathbf{Y}_{\max} \right. \right\} \\
 \Omega_{\min}^Y & \triangleq \left\{ \mathbf{Y}, \varepsilon \left| \begin{bmatrix} -\mathbf{I}_Y & \mathbf{V}_{\min}^y \end{bmatrix} \begin{bmatrix} \mathbf{Y} \\ \varepsilon \end{bmatrix}^T \leq -\mathbf{Y}_{\min} \right. \right\} \\
 \Omega_{safe}^Y & \triangleq \left\{ \mathbf{Y}, \varepsilon \left| \begin{bmatrix} -\mathbf{A}_{safe} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{Y} \\ \varepsilon \end{bmatrix}^T \leq -\mathbf{D}_{safe} - \mathbf{T}_{safe} \cdot \mathbf{V}_+ \right. \right\}
 \end{aligned} \tag{5-43}$$

注: 式 (5-41)、(5-42) 和 (5-43) 中, \mathbf{Y} 、 \mathbf{U} 和 $\Delta \mathbf{U}$ 不是独立的, \mathbf{Y} 和 $\Delta \mathbf{U}$ 的关系由鲁棒跟车预测模型 (5-16) 确定, \mathbf{U} 和 $\Delta \mathbf{U}$ 的关系由式 (5-19) 确定。

MPC 中, 除数值优化算法本身的效率外, 在线优化求解时间与静态优化问题的计算复杂度密切相关。一般来说, 优化问题的复杂度取决于问题类型和问题规模。前者由代价函数和约束集合的类型决定, 如代价函数的类型有 1 范数型、2 范数型和 ∞ 范数型, 约束条件的类型有线性约束集和椭圆约束集等。对于控制系统来说, 问题类型是由被控对象和性能指标唯一确定的, 难以进行修改, 因此计算复杂度主要与问题规模相关。而问题规模与待优化变量和约束集合的

维数相关。减小两者，均可有效降低问题规模，缩减数值求解的计算时间。以求解 QP 问题的 Dantzig-Wolfe 有效集法为例，其最优解的迭代次数 N_{iter} 不低于 [148]：

$$\begin{aligned} N_{iter} &\triangleq N_{cost} + N_{cstr} \\ N_{cost} &= mP + 1 \\ N_{cstr} &= 4mP + 3nP \end{aligned} \quad (5-44)$$

式 (5-44) 中， N_{cost} 为待优化变量的维数， N_{cstr} 为约束集合的维数。对于同一数值优化算法，迭代次数越少，它对问题的计算效率越高，计算时间越短。这说明，该算法的计算效率与待优化变量维数和约束集合维数直接相关。

注：本文中，约束集合的维数是指约束集合中标量约束不等式的数目，而不是受约束变量的维数。

5.4.2 静态优化问题的规模缩减框架

优化问题的规模缩减框架包括变量集结策略和约束集压缩策略。前者用于减小待优化变量的维数，后者用于减少约束集合的维数。

模型预测控制过程中，只有预测时域开环最优序列的首元素作用于被控对象，其余元素皆无作用。这表明，滚动时域优化求解中，只需待优化变量的首元素最优，对其他元素无要求，这是 MPC 数值优化与一般的优化问题的不同之处。因此，MPC 中，只要保证开环最优序列的首元素最优，不求解（或者少求解）其他待优化变量是可行的。这是变量集结策略的基本思路^[105]。为此，定义一集结变换：

$$\Delta U \triangleq M_T \cdot Z \quad (5-45)$$

式 (5-45) 中， $\Delta U \in R^{mP}$ 为预测控制增量， $Z \in R^{mQ}$ 称集结变量， M_T 称集结矩阵，维数为 $mP \times mQ$ ，列满秩，且矩阵结构满足式 (5-46) 和式 (5-47)：

$$M_T \triangleq \begin{bmatrix} I_{m \times m} & 0 \\ 0 & \bar{M}_T \end{bmatrix} \quad (5-46)$$

$$Q < P \quad (5-47)$$

式 (5-46) 中, $\bar{\mathbf{M}}_T$ 为列满秩的子矩阵, 式 (5-47) 中, Q 称为集结维数。易知, 将集结变换 (5-45) 代入预测优化问题 (5-23) 后, 可将后者转化为以 $[\mathbf{Z}, \varepsilon]^T$ 为待优化变量的问题。由集结矩阵满足式 (5-46) 知, 变量 \mathbf{Z} 的首元素与 $\Delta \mathbf{U}$ 首元素相同, 利用 \mathbf{Z}^* 的首元素代替 $\Delta \mathbf{U}^*$ 的首元素进行反馈, 同样获得最优控制输入量。而且, 由式 (5-47) 知, 变量 \mathbf{Z} 的维数小于变量 $\Delta \mathbf{U}$, 因此, 新静态优化问题的规模小于原静态优化问题。与后者相比, 前者的求解可提高在线优化的计算效率。

类似, 模型预测控制过程中, 静态优化问题的约束集合也只有 $i=0$ 处的约束不等式, 称首约束, 对被控对象起限制作用。因此, 与一般的优化问题不同, MPC 的静态优化问题中, 也不必要求预测时域的每点均满足约束条件。若仅选择部分预测点的控制输入和系统输出进行约束, 令其他预测点自由, 则可缩减约束集的维数, 进一步降低静态优化问题的规模。这是约束集压缩策略的基本思路。为建立约束集压缩策略, 首先定义一集合压缩映射 $\phi(\mathbf{M}_\phi)$:

$$\begin{aligned} \phi(\mathbf{M}_\phi): \Omega_\phi &\rightarrow \Theta_\phi \\ \Omega_\phi &= \{\zeta \mid \mathbf{A}_\phi \cdot \zeta < \mathbf{b}_\phi\} \\ \Theta_\phi &= \{\zeta \mid \mathbf{M}_\phi \cdot \mathbf{A}_\phi \cdot \zeta < \mathbf{M}_\phi \cdot \mathbf{b}_\phi\} \end{aligned} \quad (5-48)$$

式 (5-48) 中, Ω_ϕ 是原约束集, Θ_ϕ 为压缩约束集, \mathbf{M}_ϕ 称为压缩矩阵。对控制输入的约束集定义压缩映射 $\phi(\mathbf{M}_U)$, 对控制增量的约束集定义压缩映射 $\phi(\mathbf{M}_{\Delta U})$, 对系统输出的约束集定义压缩映射 $\phi(\mathbf{M}_Y)$:

$$\phi(\mathbf{M}_U): \Omega_{\max}^U \rightarrow \Theta_{\max}^U, \quad \Omega_{\min}^U \rightarrow \Theta_{\min}^U \quad (5-49)$$

$$\phi(\mathbf{M}_{\Delta U}): \Omega_{\min}^{\Delta U} \rightarrow \Theta_{\min}^{\Delta U}, \quad \Omega_{\max}^{\Delta U} \rightarrow \Theta_{\max}^{\Delta U} \quad (5-50)$$

$$\phi(\mathbf{M}_Y): \Omega_{\min}^Y \rightarrow \Theta_{\min}^Y, \quad \Omega_{\max}^Y \rightarrow \Theta_{\max}^Y, \quad \Omega_{\text{safe}}^Y \rightarrow \Theta_{\text{safe}}^Y \quad (5-51)$$

式 (5-49)、(5-50) 和 (5-51) 中, \mathbf{M}_U 、 $\mathbf{M}_{\Delta U}$ 和 \mathbf{M}_Y 是压缩矩阵, 维数分别为 $m\Omega \times mP$ 、 $m\Omega \times mP$ 和 $n\Omega \times nP$, 且矩阵结构满足式 (5-52) 和式 (5-53):

$$\mathbf{M}_U \triangleq \begin{bmatrix} \mathbf{I}_{m \times m} & \mathbf{0} \\ \mathbf{0} & \bar{\mathbf{M}}_U \end{bmatrix}, \quad \mathbf{M}_{\Delta U} \triangleq \begin{bmatrix} \mathbf{I}_{m \times m} & \mathbf{0} \\ \mathbf{0} & \bar{\mathbf{M}}_{\Delta U} \end{bmatrix}, \quad \mathbf{M}_Y \triangleq \begin{bmatrix} \mathbf{I}_{n \times n} & \mathbf{0} \\ \mathbf{0} & \bar{\mathbf{M}}_Y \end{bmatrix} \quad (5-52)$$

$$\Omega < P \quad (5-53)$$

式 (5-52) 中, $\bar{\mathbf{M}}_U$ 为 \mathbf{M}_U 的子矩阵, $\bar{\mathbf{M}}_{\Delta U}$ 为 $\mathbf{M}_{\Delta U}$ 的子矩阵, $\bar{\mathbf{M}}_Y$ 为 \mathbf{M}_Y 的子矩阵, 均为行满秩。式 (5-53) 中, Ω 称为压缩维数。式 (5-49)、(5-50) 和 (5-51) 中, Θ_{\max}^U 、 Θ_{\min}^U 、 $\Theta_{\max}^{\Delta U}$ 、 $\Theta_{\min}^{\Delta U}$ 、 Θ_{\max}^Y 、 Θ_{\min}^Y 和 Θ_{safe}^Y 是压缩约束集:

$$\begin{aligned} \Theta_{\max}^U &= \left\{ \mathbf{U}, \varepsilon \left| \begin{bmatrix} \mathbf{M}_U & -\mathbf{M}_U \mathbf{V}_{\max}^u \end{bmatrix} \begin{bmatrix} \mathbf{U} & \varepsilon \end{bmatrix}^T \leq \mathbf{M}_U \mathbf{U}_{\max} \right. \right\} \\ \Theta_{\min}^U &= \left\{ \mathbf{U}, \varepsilon \left| \begin{bmatrix} -\mathbf{M}_U & \mathbf{M}_U \mathbf{V}_{\min}^u \end{bmatrix} \begin{bmatrix} \mathbf{U} & \varepsilon \end{bmatrix}^T \leq -\mathbf{M}_U \mathbf{U}_{\min} \right. \right\} \end{aligned} \quad (5-54)$$

$$\begin{aligned} \Theta_{\max}^{\Delta U} &= \left\{ \Delta \mathbf{U}, \varepsilon \left| \begin{bmatrix} \mathbf{M}_{\Delta U} & -\mathbf{M}_{\Delta U} \mathbf{V}_{\max}^{\Delta u} \end{bmatrix} \begin{bmatrix} \Delta \mathbf{U}, \varepsilon \end{bmatrix}^T \leq \mathbf{M}_{\Delta U} \Delta \mathbf{U}_{\max} \right. \right\} \\ \Theta_{\min}^{\Delta U} &= \left\{ \Delta \mathbf{U}, \varepsilon \left| \begin{bmatrix} -\mathbf{M}_{\Delta U} & \mathbf{M}_{\Delta U} \mathbf{V}_{\min}^{\Delta u} \end{bmatrix} \begin{bmatrix} \Delta \mathbf{U}, \varepsilon \end{bmatrix}^T \leq -\mathbf{M}_{\Delta U} \Delta \mathbf{U}_{\min} \right. \right\} \end{aligned} \quad (5-55)$$

$$\begin{aligned} \Theta_{\max}^Y &= \left\{ \mathbf{Y}, \varepsilon \left| \begin{bmatrix} \mathbf{M}_Y & -\mathbf{M}_Y \mathbf{V}_{\max}^y \end{bmatrix} \begin{bmatrix} \mathbf{Y}, \varepsilon \end{bmatrix}^T \leq \mathbf{M}_Y \mathbf{Y}_{\max} \right. \right\} \\ \Theta_{\min}^Y &= \left\{ \mathbf{Y}, \varepsilon \left| \begin{bmatrix} -\mathbf{M}_Y & \mathbf{M}_Y \mathbf{V}_{\min}^y \end{bmatrix} \begin{bmatrix} \mathbf{Y}, \varepsilon \end{bmatrix}^T \leq -\mathbf{M}_Y \mathbf{Y}_{\min} \right. \right\} \\ \Theta_{\text{safe}}^Y &\triangleq \left\{ \mathbf{Y}, \varepsilon \left| \begin{bmatrix} -\mathbf{M}_Y \mathbf{A}_{\text{safe}} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{Y}, \varepsilon \end{bmatrix}^T \leq -\mathbf{M}_Y \mathbf{D}_{\text{safe}} - \mathbf{M}_Y \mathbf{T}_{\text{safe}} \cdot \mathbf{V}_+ \right. \right\} \end{aligned} \quad (5-56)$$

比较压缩约束集和原约束集知, 压缩映射 $\phi(\cdot)$ 相当于在原约束不等式两端同乘以一压缩矩阵。由压缩矩阵的结构满足 (5-52) 知, 压缩约束集的首约束与原约束集的首约束一致。静态优化问题中, 以压缩约束集代替原约束集为约束条件, 同样可限制系统输入输出的范围。而且由 $\Omega < P$ 知, 压缩约束集的维数小于原约束集的维数。因此, MPC 中, 以压缩约束集代替原约束集, 求解预测优化问题, 也可提高在线优化的计算效率。

另外, 滚动时域优化计算中, 单步计算超时也多发生于约束集起作用的期间, 故与变量集结策略相比, 约束集压缩策略更具针对性, 可有效提高约束集作用期间的计算效率, 避免单步计算超时。

5.4.3 基于规模缩减法的 MPC 快速算法

经变量集结和约束集压缩后，原 QP 问题 (5-40) 变为：

$$\begin{aligned} \min_{\mathbf{Z}, \varepsilon} & \begin{bmatrix} \mathbf{Z} \\ \varepsilon \end{bmatrix}^T \mathbf{H}_{opt} \begin{bmatrix} \mathbf{Z} \\ \varepsilon \end{bmatrix} + 2 \mathbf{f}_{opt}^T \begin{bmatrix} \mathbf{Z} \\ \varepsilon \end{bmatrix} \\ \text{Subj. to:} & \quad (1) \quad \Theta_{\min}^U \cap \Theta_{\max}^U \\ & \quad (2) \quad \Theta_{\min}^{\Delta U} \cap \Theta_{\max}^{\Delta U} \\ & \quad (3) \quad \Theta_{\min}^Y \cap \Theta_{\max}^Y \cap \Theta_{safe}^Y \end{aligned} \quad (5-57)$$

式 (5-57) 中， \mathbf{H}_{opt} 为二次项系数矩阵， \mathbf{f}_{opt} 为一次项的系数向量，为：

$$\mathbf{H}_{opt} = \begin{bmatrix} \mathbf{M}_T^T \mathbf{H} \mathbf{M}_T & \mathbf{0} \\ \mathbf{0} & \rho \end{bmatrix}, \mathbf{f}_{opt} = \begin{bmatrix} \mathbf{f} \cdot \mathbf{M}_T^T \\ \mathbf{0} \end{bmatrix} \quad (5-58)$$

由文献[149]的相似变换定理知，因 \mathbf{H} 矩阵对称正定且 \mathbf{M}_T 矩阵列满秩，经 \mathbf{M}_T 矩阵相似变换后， \mathbf{H}_{opt} 保持正定对称性，即问题 (5-57) 仍为凸优化问题，其最优解唯一。经集结变换后，待优化变量的维数由 $mP+1$ 维降为 $mQ+1$ 维；经约束集压缩后，约束集合的维数由 $(4m+3n)P$ 降低为 $(4m+3n)\Omega$ 。以规模缩减后的 QP 问题 (5-57) 取代原 QP 问题 (5-40)，求解开环最优序列 $\mathbf{Z}^*(k)$ ，利用 $\mathbf{Z}^*(k)$ 的首元素 $z^*(k+0|k)$ 进行反馈，可实现一种模型预测控制的快速算法。该算法的控制输入为：

$$u(k) = u(k-1) + z^*(k+0|k) \quad (5-59)$$

另外，尽管本节以 QP 问题说明规模缩减法的框架，但由变量集结策略和约束集压缩策略的设计过程知，它们不受静态优化问题的类型限制。这说明，规模缩减法同时适用于线性或非线性被控对象，线性约束集或椭圆约束集，1 范数型、2 范数型和 ∞ 范数型的代价函数。

5.4.4 集结矩阵和压缩矩阵的构造方法

规模缩减法中， \mathbf{Z} 首元素的最优性不是孤立的，它与其他待优化变量以及约束之外的约束不等式也密切相关。它们之间的关系由集结变换和压缩映射决定。因此，集结矩阵和压缩矩阵的构造方法是规模缩减法是否实用的关键。

5.4.4.1 集结矩阵的分段构造方法

分段构造法的基本思想是从待优化变量 ΔU 中，间隔选取部分元素，构成集结变量 Z 。集结矩阵的基本形式为：

$$M_T = \begin{bmatrix} I_{m \times m} & & & 0 \\ \hline & M_1 & 0 & 0 \\ & 0 & M_2 & 0 \\ & \vdots & \vdots & \vdots \\ & 0 & 0 & M_{Q-1} \end{bmatrix} \begin{matrix} \\ \text{第1段} \\ \text{第2段} \\ \vdots \\ \text{第}Q-1\text{段} \end{matrix} \quad (5-60)$$

式 (5-60) 中， M_j 为 $m q_j \times m$ 维矩阵，称为第 j 段列矩阵。其转置矩阵 M_j^T 定义为 ($j=1:Q-1$)：

$$M_j^T = \underbrace{\begin{bmatrix} I_{m \times m} & \cdots & I_{m \times m} \end{bmatrix}}_{q_j} \quad (5-61)$$

式 (5-61) 中， $q_j \in N$ 为各段长度，满足：

$$\sum_{j=1}^{Q-1} q_j = P-1 \quad (5-62)$$

易知，基于分段构造法设计的矩阵符合集结矩阵的维数和结构要求，且列满秩。为分析分段构造法的特点，以控制输入的维数 $m=1$ 为例，定义两种开环最优序列 ΔU^* 与 Z^* ，以及 Z^* 经集结变换得到的变量 ΔU^Z ：

$$\begin{aligned} \Delta U^* &= [\Delta u^*(k+i|k)]_{i=0:P-1} \\ Z^* &= [z^*(k+j|k)]_{j=0:Q-1} \\ \Delta U^Z &= [\Delta u^Z(k+i|k)]_{i=0:P-1} \end{aligned} \quad (5-63)$$

式 (5-63) 中， ΔU^* 是原 QP 问题 (5-40) 的最优开环序列， Z^* 是规模压缩后的 QP 问题 (5-57) 的最优开环序列。图 5.4 是 k 时刻 ΔU^* 、 Z^* 、 ΔU^Z 三者关系的示意图，其中，虚线表示 ΔU^* ，圆点表示 Z^* ，实线表示 ΔU^Z 。



由式(5-62)知,当预测时域 P 固定时, q_j 越小,则集结维数 Q 越大,即集结变换后 \mathbf{Z} 的维数越大, $\Delta \mathbf{U}^Z$ 对 $\Delta \mathbf{U}^*$ 的阶梯近似程度越好。这表明,集结变换策略对计算效率和控制最优性的影响是矛盾的。工程应用中,应根据具体需求合理选择集结维数 Q 和各段长度 q_j , 权衡计算效率和控制最优性。一般来说,首元素附近的阶梯近似程度对控制最优性影响最大,故选择 q_j 的原则是:靠近首元素的 q_j 尽量取小,以保证控制最优性;远离首元素的 q_j 可以取大,以减小集结维数 Q , 提高计算效率。

5.4.4.2 压缩矩阵的分段选点构造法

借鉴集结矩阵的分段构造思想，建立压缩矩阵的分段选点思想为：预测时域内，除首点 $i=0$ 外，将预测时域分为 $\Omega-1$ 段，每段长度为 ω_j 点；每段内，仅使用原约束不等式限制第一点的预测输入输出，令其余点自由。由此建立压缩矩阵的方法称为分段选点构造法。以 U 约束集的压缩映射 $\phi(M_U)$ 为例，说明压缩矩阵 M_U 的分段选点构造法：

$$M_U \triangleq \begin{bmatrix} I_{m \times m} & \cdots & \cdots & \cdots & \mathbf{0} \\ \vdots & M_1^U & 0 & \cdots & 0 \\ \vdots & 0 & M_2^U & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \vdots & 0 & 0 & \cdots & M_{\Omega-1}^U \end{bmatrix} \quad (5-64)$$

$\underbrace{\hspace{1.5cm}}_{\text{第1段}} \quad \underbrace{\hspace{1.5cm}}_{\text{第2段}} \quad \underbrace{\hspace{1.5cm}}_{\text{第}\Omega-1\text{段}}$

式 (5-64) 中， M_j^U 为 $m \times m\omega_j$ 维，称为第 j 段行矩阵，定义为：

$$M_j^U = \underbrace{[I_{m \times m}, 0, \dots, 0]}_{\omega_j} \quad (5-65)$$

式 (5-65) 中， $j=1:\Omega-1$ ， $\omega_j \in N$ 为各段长度，满足：

$$\sum_{j=1}^{\Omega-1} \omega_j = P-1 \quad (5-66)$$

由分段选点法的构造过程知，基于分段选点法设计的矩阵符合压缩矩阵的维数和结构要求，且行满秩。

令控制输入的维数 $m=1$ ，以控制输入的上界约束为例，说明分段选点构造法对预测时域内约束条件的影响。图 5.5 是 k 时刻预测时域内，控制输入上界约束的示意图。黑点表示预测时域内的原约束上界，圈点表示压缩映射后，压缩集合给出的上界，虚线表示控制输入的预测轨迹。压缩矩阵 M_U 中，第 j 段行矩阵的第一个元素为单位矩阵，而其他元素为零。这说明，经该矩阵压缩映射后，压缩集合第 j 段的第一个不等式保持原样，而其他不等式均变为零不等式，相当于第 j 段的其它预测点皆无约束。




图 5.5 分段选点构造法的示意图

以图 5.5 的第 2 段为例进一步阐述该特点。第 2 段长度为 $\omega_2=3$ 。压缩约束集在该段内，第一点的约束不等式存在，其上界如 $j=2$ 处的圈点所示，其他 2 点无约束不等式。因此， $j=2$ 和 $j=3$ 之间，压缩约束集对控制输入的预测轨迹无限制，此处轨迹可能超越上界 u_{\max} 。

预测轨迹越界会影响 ΔU 首元素求解的最优性。解决该问题的基本措施是减小段长 ω_j 。各段长度越短，压缩约束集中仍具有约束性的预测点也距离越近，控制输入轨迹越界的可能性也越小。由 (5-66) 知，当预测长度 P 固定时，段长 ω_j 越小，则段数 Ω 越大，即压缩约束集的维数也越大。因此，约束集压缩策略对计算效率和控制最优性的影响也是矛盾的。同变量集结策略类似，首约束附近预测轨迹越界对最优性的影响最大，故选择段长 ω_j 的基本原则是：靠近首约束的 ω_j 尽量取小，以保证控制最优性；远离首约束的 ω_j 可以取大，以提高计算效率。

类似，对于 ΔU 约束集的压缩映射 $\phi(M_{\Delta U})$ ，基于分段选点法建立压缩矩阵 $M_{\Delta U}$ 为：

$$M_{\Delta U} \triangleq \begin{bmatrix} I_{m \times m} & 0 & 0 & 0 \\ M_1^{\Delta U} & 0 & 0 & 0 \\ 0 & M_2^{\Delta U} & \ddots & 0 \\ 0 & 0 & M_{\Omega-1}^{\Delta U} & 0 \end{bmatrix} \quad (5-67)$$

式中， $M_j^{\Delta U}$ 为 $m \times m\omega_j$ 维的矩阵，定义为：

$$\mathbf{M}_j^{\Delta U} = [\underbrace{\mathbf{I}_{m \times m}, 0, \dots, 0}_{\omega_j}] \quad (5-68)$$

类似，对于 \mathbf{Y} 约束集的压缩映射 $\phi(\mathbf{M}_Y)$ ，基于分段选点法构造压缩矩阵 \mathbf{M}_Y 为：

$$\mathbf{M}_Y \triangleq \begin{bmatrix} \mathbf{I}_{n \times n} & | & & & \mathbf{0} \\ \hline & \mathbf{M}_1^Y & 0 & & 0 \\ & 0 & \mathbf{M}_2^Y & & 0 \\ & & & \ddots & \\ & 0 & 0 & & \mathbf{M}_{\Omega-1}^Y \end{bmatrix} \quad (5-69)$$

式中， \mathbf{M}_j^Y 为 $n \times n \omega_j$ 维的矩阵，定义为：

$$\mathbf{M}_j^Y = [\underbrace{\mathbf{I}_{n \times n}, 0, \dots, 0}_{\omega_j}] \quad (5-70)$$

分段选点法对 ΔU 约束集和 \mathbf{Y} 约束集的影响，与它对 \mathbf{U} 约束集的影响基本相同。它们的分析过程以及参数选择原则都是一致的，不再赘述。

5.4.4.3 压缩矩阵的分段平均构造法

分段选点法的主要缺陷是各段中间的预测点无约束，当系统输入输出越界严重时，可能极大影响闭环控制的最优性。为解决这一问题，提出另外一种构造方法，即分段平均构造法。分段平均法的基本思想类似于分段选点法，只不过每段内，对各点的约束不等式进行加权平均，作为本段的约束。对于 \mathbf{U} 约束集的压缩映射 $\phi(\mathbf{M}_U)$ ，给出基于分段平均法的压缩矩阵 \mathbf{M}_U 。该法中， \mathbf{M}_U 矩阵的形式同式 (5-64)，但各段行矩阵 \mathbf{M}_j^U 不同，定义为：

$$\mathbf{M}_j^U = [\underbrace{\lambda_{j,1} \mathbf{I}_{m \times m}, \lambda_{j,2} \mathbf{I}_{m \times m}, \dots, \lambda_{j,\omega_j} \mathbf{I}_{m \times m}}_{\omega_j}] \quad (5-71)$$

式 (5-71) 中， $\lambda_{j,k}$ 为加权系数， $0 \leq \lambda_{j,k} \leq 1$ ， $k=[1:\omega_j]$ ，且满足：

$$\sum_{k=1}^{\omega_j} \lambda_{j,k} = 1 \quad (5-72)$$

当同一段内加权系数皆相等, 即 $\lambda_{j,k}=1/\omega_j$ 时, 压缩映射相当于对约束集分段平均, 对本段内各点约束给予同等程度的重视。因为分段平均法对每段各预测点均有一定约束性, 所以可避免部分预测点严重越界的问题, 这有助于保持闭环控制的最优性。另外, 分段选点构造法也可看作分段平均法的一个特例。当 $\lambda_{j,k}=1$ ($k=1$) 而 $\lambda_{j,k}=0$ ($k=2:\omega_j$) 时, 式 (5-71) 等价于 (5-65)。

类似, 对于 ΔU 约束集的压缩映射 $\phi(\mathbf{M}_{\Delta U})$, 基于分段平均法建立压缩矩阵 $\mathbf{M}_{\Delta U}$ 。其形式同式 (5-67), 但各段行矩阵 $\mathbf{M}_j^{\Delta U}$ 不同, 定义为:

$$\mathbf{M}_j^{\Delta U} = \underbrace{\left[\lambda_{j,1} \mathbf{I}_{m \times m}, \lambda_{j,2} \mathbf{I}_{m \times m}, \dots, \lambda_{j,\omega_j} \mathbf{I}_{m \times m} \right]}_{\omega_j} \quad (5-73)$$

式 (5-73) 中, $\lambda_{j,k}$ 为加权系数, $0 \leq \lambda_{j,k} \leq 1$, $k=[1:\omega_j]$, 且满足条件 (5-72)。类似, 对于 \mathbf{Y} 约束集的压缩映射 $\phi(\mathbf{M}_Y)$, 基于分段平均法建立压缩矩阵 \mathbf{M}_Y 。其形式同式 (5-69), 但各行矩阵 \mathbf{M}_j^Y 不同, 定义为:

$$\mathbf{M}_j^Y = \underbrace{\left[\lambda_{j,1} \mathbf{I}_{n \times n}, \lambda_{j,2} \mathbf{I}_{n \times n}, \dots, \lambda_{j,\omega_j} \mathbf{I}_{n \times n} \right]}_{\omega_j} \quad (5-74)$$

式 (5-74) 中, $\lambda_{j,k}$ 为加权系数, $0 \leq \lambda_{j,k} \leq 1$, $k=[1:\omega_j]$, 且满足条件 (5-72)。

5.5 MOCACC 控制算法的滚动时域优化求解

第 2 章描述的控制方案中, 滚动时域优化环节是求解 MOCACC 控制算法的关键步骤。本节首先给出实用化处理后的预测优化问题, 然后将其转化为 QP 问题, 最后利用 Dantzig-wolfe 有效集法求解该问题, 给出车辆 MOCACC 系统的最优控制算法。

5.5.1 实用化处理后的预测优化问题

本章利用反馈校正法设计了鲁棒跟车预测模型, 采用约束管理法修正了预测优化问题, 使用规模缩减法进行了待优化变量的集结变换和约束集的压缩映

射。经实用化处理后，车辆 MOCACC 的预测优化问题转化为：

$$\min_{\mathbf{Z}, \varepsilon} \Psi(\mathbf{Y}, \mathbf{U}, \Delta \mathbf{U}, \varepsilon)$$

Subj. to:

- (1) 鲁棒跟车预测模型：(5-16)
- (2) 压缩约束集：(5-54) (5-55) 和 (5-56)
- (3) 集结变换：(5-45)

问题 (5-75) 中，待优化变量为集结变量 \mathbf{Z} 和松弛因子 ε ， $\Psi(\mathbf{Y}, \mathbf{U}, \Delta \mathbf{U}, \varepsilon)$ 为带松弛因子的代价函数，被控对象模型为鲁棒跟车预测模型，约束条件为压缩约束集， $\Delta \mathbf{U}$ 和 \mathbf{Z} 之间满足集结变换。预测优化问题 (5-75) 中，与实用化处理相关的参数见表 5.1。

表 5.1 实用化问题处理的参数

控制参数	参数值	控制参数	参数值
\mathbf{H}	diag([0.9, 0.9, 0.2])	ρ	3
$v_{\min}^{\Delta u}$	0	$v_{\max}^{\Delta u}$	0
v_{\min}^u	-0.1	v_{\max}^u	0.01
\mathbf{v}_{\min}^y	$[-3, -1, -0.1]^T$	\mathbf{v}_{\max}^y	$[3, 1, 0.1]^T$
Q	12	Ω	26
$q_1, q_2, q_3, q_4,$ q_5, q_6	2, 2, 2, 4, 4, 4	$q_7, q_8, q_9, q_{10}, q_{11}$	4, 4, 8, 8, 7
ω_1	1	$\omega_2 = \omega_3 = \dots = \omega_{24}$	2

与反馈校正法相关的参数只有校正矩阵 \mathbf{H} 。 \mathbf{H} 的主对角线包含三个元素，分别体现对状态 Δd 、 Δv 和 a_f 误差的校正能力。一般来说， \mathbf{H} 的元素值越大，对状态误差的校正能力越强，但同时也放大了状态测量的噪声。尤其是，利用加速度计测量的车辆纵向加速度，受车辆本身振动和俯仰过程的重力分量影响，存在较大的中、高频噪声，不易使用较大的反馈校正矩阵。基于上述考虑，设置 \mathbf{H} 的参数值如表 5.1。

与约束管理法相关的参数有惩罚系数和各松弛系数。对于惩罚系数，它越大，对约束的松弛程度越小，但同时求解可行域也随之缩小。兼顾可行解范围

和约束松弛程度,选择惩罚系数如表 5.1 所示。松弛系数体现了同一松弛因子下,对控制增量、控制输入以及系统输出各变量的不同松弛程度。控制输入的松弛系数设置为 $|v_{\min}''| > |v_{\max}''|$,使制动过程比加速过程的松弛度大,以保证跟车安全性。系统输出松弛系数的各元素则与车距误差、相对车速和加速度之间的相对大小有关。考虑正常行车工况中,驾驶员对加速度的敏感程度最强,对相对车速的敏感度次之,对距离误差的敏感度最弱,设置各分量的松弛系数如表 5.1。

规模缩减法中,集结矩阵采用分段构造法设计,压缩矩阵采用分段选点法构造。其参数有集结维数 Q 和段长度 q_i ,压缩维数 Ω 和段长度 ω_i 。兼顾控制的最优性和计算效率,设置 Q 、 Ω 以及 q_i 、 ω_i 如表 5.1。

5.5.2 代价函数的二次规划型转化

车辆 MOCACC 控制算法由求解预测优化问题 (5-75) 得到的。滚动时域优化计算的基本策略是消除预测量 Y 、 U 、 ΔU 以及鲁棒跟车预测模型,将预测优化问题转化为可数值计算的 QP 问题。

本节先将代价函数转化为二次规划型。将集结变换 (5-45) 代入鲁棒跟车预测模型 (5-16) 和 U 与 ΔU 的关系式 (5-19),建立 Y 、 U 与集结变量 Z 的关系式:

$$Y = \bar{S}_x x(k) + S_{u1} u(k-1) + \bar{S}_u Z - S_e H x(k|k-1) + H_v V \quad (5-76)$$

$$U = T_{u1} \cdot u(k-1) + \bar{T}_{\Delta u} Z \quad (5-77)$$

式 (5-76)、(5-77) 中, $\bar{S}_u \in R^{n_P \times m_Q}$, $\bar{S}_x \in R^{n_P \times l}$, $\bar{T}_{\Delta u} \in R^{m_P \times m_Q}$ 为系数矩阵,有:

$$\begin{aligned} \bar{S}_u &= S_u M_T \\ \bar{S}_x &= S_x + S_e H \\ \bar{T}_{\Delta u} &= T_{\Delta u} M_T \end{aligned} \quad (5-78)$$

式 (5-76)、(5-77) 和集结变换式 (5-45) 分别描述了 Y 、 U 、 ΔU 与集结变量 Z 的关系。为消除未知量 Y 、 U 和 ΔU ,将式 (5-76)、式 (5-77) 和式 (5-45) 代入到代价函数 (5-25),有:

$$\begin{aligned}
 & \Psi(Y, U, \Delta U, \varepsilon) \\
 &= (\bar{S}_x x(k) + S_{u1} u(k-1) + \bar{S}_u Z - S_e Hx(k|k-1) + H_v V)^T \Omega_{CF}^T W_y \Omega_{CF} \\
 & \quad \cdot (\bar{S}_x x(k) + S_{u1} u(k-1) + \bar{S}_u Z - S_e Hx(k|k-1) + H_v V) \\
 & \quad + (T_{u1} \cdot u(k-1) + \bar{T}_{\Delta u} Z)^T W_u (T_{u1} \cdot u(k-1) + \bar{T}_{\Delta u} Z) \\
 & \quad + (M_T Z)^T W_{\Delta u} (M_T Z) \\
 & \quad + \varepsilon(k) \rho \varepsilon(k)
 \end{aligned} \tag{5-79}$$

对上式整理并简化, 有 QP 问题的代价函数:

$$\Psi = \begin{bmatrix} Z \\ \varepsilon \end{bmatrix}^T \begin{bmatrix} H_{opt} & \mathbf{0} \\ \mathbf{0} & \rho \end{bmatrix} \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} + 2 \begin{bmatrix} f_{opt} \\ 0 \end{bmatrix}^T \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} + const \tag{5-80}$$

式 (5-80) 中, H_{opt} 为对称正定的 Hessian 矩阵, 维数为 $mQ \times mQ$, f_{opt} 为一次项矩阵, 维数为 $mQ \times 1$, $const$ 代表常数项的和, 有:

$$\begin{aligned}
 H_{opt} &= \bar{S}_u^T \Omega_{CF}^T W_y \Omega_{CF} \bar{S}_u + T_{\Delta u}^T W_u T_{\Delta u} + M_T^T W_{\Delta u} M_T \\
 f_{opt} &= \bar{S}_u^T \Omega_{CF}^T W_y \Omega_{CF} (\bar{S}_x x(k) + S_{u1} u(k-1) - S_e Hx(k|k-1) + H_v V) \\
 & \quad + \bar{T}_{\Delta u}^T W_u T_{u1} \cdot u(k-1) \\
 const &= (\bar{S}_x x(k) + S_{u1} u(k-1) - S_e Hx(k|k-1) + H_v V)^T \\
 & \quad \cdot \Omega_{CF}^T W_y \Omega_{CF} (\bar{S}_x x(k) + S_{u1} u(k-1) - S_e Hx(k|k-1) + H_v V) \\
 & \quad + u(k-1)^T T_{u1}^T W_u T_{u1} \cdot u(k-1)
 \end{aligned} \tag{5-81}$$

因为 $const$ 项不包含待优化变量, 故它对开环最优序列的求解无影响。

5.5.3 约束条件的二次规划型转化

将 Y 、 U 、 ΔU 与 Z 的关系式 (5-76)、(5-77) 和 (5-45) 代入压缩约束集, 整理为二次规划问题的约束条件, 如式 (5-82)、(5-83) 和 (5-84) 所示。

$$\begin{aligned} \begin{bmatrix} M_U \bar{T}_{\Delta u} & -M_U V_{\max}^u \end{bmatrix} \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} &\leq M_U U_{\max} - M_U T_{u1} \cdot u(k-1) \\ \begin{bmatrix} -M_U \bar{T}_{\Delta u} & M_U V_{\min}^u \end{bmatrix} \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} &\leq -M_U U_{\min} + M_U T_{u1} \cdot u(k-1) \end{aligned} \quad (5-82)$$

$$\begin{aligned} \begin{bmatrix} M_{\Delta U} M_T & -M_{\Delta U} V_{\max}^{\Delta u} \end{bmatrix} \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} &\leq M_{\Delta U} \Delta U_{\max} \\ \begin{bmatrix} -M_{\Delta U} M_T & M_{\Delta U} V_{\min}^{\Delta u} \end{bmatrix} \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} &\leq -M_{\Delta U} \Delta U_{\min} \end{aligned} \quad (5-83)$$

$$\begin{aligned} \begin{bmatrix} M_Y \bar{S}_u & -M_Y V_{\max}^y \end{bmatrix} \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} &\leq M_Y Y_{\max} - M_Y X_{new} \\ \begin{bmatrix} -M_Y \bar{S}_u & M_Y V_{\min}^y \end{bmatrix} \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} &\leq -M_Y Y_{\min} + M_Y X_{new} \\ \begin{bmatrix} -M_Y A_{safe} \bar{S}_u & 0 \end{bmatrix} \begin{bmatrix} Z \\ \varepsilon \end{bmatrix} &\leq -M_Y D_{safe} - M_Y T_{safe} \cdot V_+ + M_Y A_{safe} X_{new} \end{aligned} \quad (5-84)$$

式 (5-84) 中, X_{new} 称迭代向量, 定义为:

$$X_{new} \triangleq \bar{S}_x x(k) + S_{u1} u(k-1) + H_v V - S_e H x(k|k-1) \quad (5-85)$$

系数矩阵 \bar{S}_u , $\bar{T}_{\Delta u}$ 和 \bar{S}_x 的定义式见 (5-78), S_{u1} , S_e , H_v 的定义式见 (5-17), T_{u1} 的定义式见 (5-20), A_{safe} , D_{safe} , T_{safe} , V_+ 的定义式见 (5-39)。

5.5.4 基于 Dantzig-wolfe 有效集法的 QP 问题求解

由节 5.5.2 和节 5.5.3 知, 代价函数的二次规划型为 (5-80), 约束条件的二次规划型为 (5-82)、(5-83) 和 (5-84)。综合二者, 建立车辆 MOCACC 控制算法的 QP 问题:

$$\begin{aligned}
 & \min_{\mathbf{Z}, \varepsilon} \begin{bmatrix} \mathbf{Z} \\ \varepsilon \end{bmatrix}^T \begin{bmatrix} \mathbf{H}_{opt} & \mathbf{0} \\ \mathbf{0} & \rho \end{bmatrix} \begin{bmatrix} \mathbf{Z} \\ \varepsilon \end{bmatrix} + 2 \begin{bmatrix} \mathbf{f}_{opt} \\ 0 \end{bmatrix}^T \begin{bmatrix} \mathbf{Z} \\ \varepsilon \end{bmatrix} \\
 & \text{Subj. to:} \\
 & (a) \mathbf{A}_{cstr} \begin{bmatrix} \mathbf{Z} \\ \varepsilon \end{bmatrix} \leq \mathbf{b}_{cstr} \\
 & (b) \begin{bmatrix} \mathbf{Z} \\ \varepsilon \end{bmatrix} \geq \begin{bmatrix} \mathbf{M}_T^+ \cdot \Delta \mathbf{U}_{\min} \\ 0 \end{bmatrix}
 \end{aligned} \tag{5-86}$$

式(5-86)中, 约束条件(b)为待优化变量的最小值。利用数值优化算法求解QP问题时, 它是算法的输入条件。 \mathbf{M}_T^+ 为 \mathbf{M}_T 的广义逆矩阵:

$$\mathbf{M}_T^+ = (\mathbf{M}_T^T \mathbf{M}_T)^{-1} \mathbf{M}_T^T \tag{5-87}$$

式(5-86)中, 约束条件(a)由式(5-82)、(5-83)、(5-84)组合而成, \mathbf{A}_{cstr} 为系数矩阵, 维数为 $(4m+3n)\Omega \times (mQ+1)$, \mathbf{b}_{cstr} 为向量矩阵, 维数为 $(4m+3n)\Omega \times 1$, 有:

$$\begin{aligned}
 \mathbf{A}_{cstr} &= \begin{bmatrix} \mathbf{M}_U \bar{\mathbf{T}}_{\Delta u} & -\mathbf{M}_U \mathbf{V}_{\max}^u \\ -\mathbf{M}_U \bar{\mathbf{T}}_{\Delta u} & \mathbf{M}_U \mathbf{V}_{\min}^u \\ \mathbf{M}_{\Delta U} \mathbf{M}_T & -\mathbf{M}_{\Delta U} \mathbf{V}_{\max}^{\Delta u} \\ -\mathbf{M}_{\Delta U} \mathbf{M}_T & \mathbf{M}_{\Delta U} \mathbf{V}_{\min}^{\Delta u} \\ \mathbf{M}_Y \bar{\mathbf{S}}_u & -\mathbf{M}_Y \mathbf{V}_{\max}^y \\ -\mathbf{M}_Y \bar{\mathbf{S}}_u & \mathbf{M}_Y \mathbf{V}_{\min}^y \\ -\mathbf{M}_Y \mathbf{A}_{safe} \bar{\mathbf{S}}_u & \mathbf{0} \end{bmatrix} \\
 \mathbf{b}_{cstr} &= \begin{bmatrix} \mathbf{M}_U \mathbf{U}_{\max} - \mathbf{M}_U \mathbf{T}_{u1} \cdot u(k-1) \\ -\mathbf{M}_U \mathbf{U}_{\min} + \mathbf{M}_U \mathbf{T}_{u1} \cdot u(k-1) \\ \mathbf{M}_{\Delta U} \Delta \mathbf{U}_{\max} \\ -\mathbf{M}_{\Delta U} \Delta \mathbf{U}_{\min} \\ \mathbf{M}_Y \mathbf{Y}_{\max} - \mathbf{M}_Y \mathbf{X}_{new} \\ -\mathbf{M}_Y \mathbf{Y}_{\min} + \mathbf{M}_Y \mathbf{X}_{new} \\ -\mathbf{M}_Y \mathbf{D}_{safe} - \mathbf{M}_Y \mathbf{T}_{safe} \cdot \mathbf{V}_+ + \mathbf{M}_Y \mathbf{A}_{safe} \mathbf{X}_{new} \end{bmatrix}
 \end{aligned} \tag{5-88}$$

目前, QP 问题的数值求解已有不少成熟算法, 如 Fletcher 有效集法^[148], 源于线性规划单纯形的 Beale 法和 Dantzig-Wolfe 法^[150], Gill-Murray 有效集法^[151]以及 Lemke 法^[151]等。文献[148]指出, Dantzig-Wolfe 法也属于一种有效集法。它不仅数值计算稳定, 而且收敛速度较快, 适用于模型预测控制的在线优化求解。利用 Dantzig-Wolfe 有效集法 (DWAS, Dantzig-Wolfe Active-Set method) 数值求解 QP 问题 (5-86), 有最优开环序列 $[\mathbf{Z}^*, \varepsilon^*]^T$ 。

$$[\mathbf{Z}^*, \varepsilon^*]^T = \text{DWAS} \left(\begin{bmatrix} \mathbf{H}_{opt} & 0 \\ 0 & \rho \end{bmatrix}, \begin{bmatrix} \mathbf{f}_{opt} \\ 0 \end{bmatrix}, \mathbf{A}_{cstr}, \mathbf{b}_{cstr}, \mathbf{M}_T^+ \Delta \mathbf{U}_{min} \right) \quad (5-89)$$

式 (5-89) 中, $\text{DWAS}(\cdot)$ 表示 Dantzig-Wolfe 有效集法。DWAS 算法的具体步骤参考文献[148]和[150]。车辆 MOCACC 控制算法为:

$$u(k) = u(k-1) + z^*(k+0|k) \quad (5-90)$$

式 (5-90) 中, $z^*(k+0|k)$ 是 \mathbf{Z}^* 的首元素。至此, 基于 MPC 的车辆 MOCACC 控制算法的求解完毕。

5.6 实用化问题处理效果的仿真验证

5.6.1 车辆 MOCACC 系统的仿真工况设置

为验证 MPC 实用化问题处理的效果, 以车辆 MOCACC 系统为对象, 建立 Simulink 仿真模型, 结构如图 5.6 所示。




图 5.6 车辆 MOCACC 仿真模型的结构

该仿真模型包括 GVLD 系统、车间纵向动力学系统和 MOCACC 控制器。GVLD 系统的模型为一阶传递函数，其公称参数见节 4.2.2。MOCACC 控制器的参数见第 4 章表 4.5、表 4.6 和表 4.7。与实用化问题处理相关的参数见表 5.1。

参照城市快速路和高速公路的交通流特征，设计三类典型的前车工况：前车正弦加减速工况、前车定加速工况和前车制动减速工况。前车正弦加减速工况中，前车初始速度为 15m/s，以幅值 0.3m/s^2 、频率 0.03Hz 的正弦加速度行驶。前车定加速工况中，前车初始速度为 15m/s，从 5 秒起以 0.6m/s^2 的恒定加速度加速至 20m/s，然后保持匀速。前车制动减速工况中，前车初速度为 15m/s。5 秒后，前车以 -2m/s^2 的恒定减速度减速至 1m/s。三种工况中，ACC 车的初始速度均与前车相同。在三种前车工况下，进行车辆 MOCACC 系统的仿真，验证反馈校正法增强闭环系统鲁棒性、约束管理法扩展求解可行域和规模缩减法提升计算效率的效果。

5.6.2 反馈校正法增强系统鲁棒性的效果

采用前车正弦加减速工况，以不确定整车质量引起的跟车模型失配为例，说明反馈校正法对车辆 MOCACC 系统的影响。GVLD 系统中，整车质量决定了它的系统增益。由第 4 章知，公称整车质量下，GVLD 系统增益的公称值为 $K_G^* = 1.05$ 。假定 GVLD 系统增益变为公称值的 0.75 倍，此时，基于公称对象设计的跟车模型与实际跟车系统失配。为检验反馈校正法的效果，设置三组仿真工况，编号为 A1，A2 和 A3，如表 5.2 所示。

表 5.2 用于鲁棒性验证的仿真工况设置

工况	GVLD 系统增益	反馈校正	线型
A1	K_G^*	--	灰虚线
A2	$0.75K_G^*$	有	细实线
A3	$0.75K_G^*$	无	细虚线

三类工况的仿真结果如图 5.7 所示。图中，(a) 是期望加速度，(b) 是实际加速度，(c) 是相对车速，(d) 是因模型失配引起的相对车速变化量，(e) 是车距误差，(f) 是因模型失配引起的车距误差变化量。图中，仿真工况对应的曲线线型如表 5.2 所示。




图 5.7 鲁棒性验证结果

A1 工况时, GVLD 系统增益等于公称值, 即跟车预测模型与实际跟车系统的特性一致。A2 和 A3 工况时, GVLD 系统增益等于 0.75 倍公称值, 而跟车预测模型仍以公称值为参数, 它与实际跟车系统存在模型失配。A2 工况时, MPC 算法带反馈校正项, A3 是对比工况, 其 MPC 算法无反馈校正项。

因 A2、A3 工况中 GVLD 系统增益减小, 如图 5.7 (b), 两工况输出的实际加速度比 A1 小, 导致相对车速和车距误差增大, 跟踪性能降低, 如图 5.7 (c) 和 (e)。与 A3 的 MPC 算法相比, A2 的 MPC 算法是基于鲁棒跟车预测模型建立的, 其反馈校正项可补偿跟车状态预测误差。因此, A2 的 MPC 算法能够增大期望加速度输入量, 如图 5.7 (a), 减小因模型失配造成的跟踪误差变化量, 如图 5.7 (d) 和 (f)。这说明: 鲁棒跟车预测模型可更好地描述跟车系统的输入输出特性, 在一定程度上自适应跟车系统的特性变化。因此基于反馈校正法的车辆 MOCACC 系统对跟车模型失配具有更好的鲁棒性。

5.6.3 约束管理法扩展求解可行域的效果

为验证约束管理法的效果, 定义两种 MPC 算法, 记为 B1 和 B2, 如表 5.3 所示。算法 B1 带约束管理法, 算法 B2 无约束管理法。以车辆 MOCACC 系统为对象, 在前车定加速工况下, 分别对两种算法进行仿真。图 5.8 是仿真结果, (a) 是期望加速度, (b) 是相对车速, (c) 是车距误差, (d) 是松弛因子。图 5.8 中, 点线表示约束的上下界, ○表示 B2 中期望加速度超过约束上界, △表示 B2 中相对车速超过约束上界。

表 5.3 求解可行性验证的仿真设置

MPC 算法	约束管理	线型
B1	有	实线
B2	无	虚线

如图 5.8 所示, 前车定加速工况中, 因前车快速加速行驶, 自车加速度不能准确跟踪前车, 导致较大相对车速和车距误差。从 0 到 6 秒, 期望加速度、相对车速和车距误差处于约束范围内, 图 5.8 (a)、(b) 和 (c) 中实线和虚线重合, 说明 B1 和 B2 的控制效果是相似的。约 6 秒处, 期望加速度到达约束上界, 如 (a) 的圈点所示。约 7 秒处, 相对车速到达约束的上界, 如 (b) 的三角形所示。当相对车速超过约束上界, 算法 B2 中因硬约束条件不能满足, 预测优化问题的

最优解不存在，故对期望加速度的数值计算有误，如 (a) 的虚线所示。此后，车辆 MOCACC 系统是发散的，如 (b) 和 (c) 的虚线所示，相对车速和车距误差轨迹逐渐变大，不能收敛到平衡点。而同一时间段内，如 (d) 所示，带约束管理法的算法 B1 可自动增加松弛因子 ε ，扩展软约束的上下界，保证预测优化问题的可行解存在。因此，前车加速过程中，车辆 MOCACC 系统不会发散；当加速过程结束后，相对车速和车距误差仍可收敛为零，如 (b) 和 (c) 的实线所示。这说明：约束管理法可扩展最优控制量的求解可行域，避免车辆 MOCACC 控制算法的非可解问题。




图 5.8 求解可行性验证结果

5.6.4 规模缩减法提升计算效率的效果

与上两节采用离线仿真不同, 本节进行在线实时仿真, 验证规模缩减法提高 MPC 计算效率的有效性。实时仿真平台的硬件为一工控机, CPU 主频 2.4G, 512M 内存, 软件平台为 Matlab/xPC 工具箱。基于 Matlab/Simulink, 利用 C-Mex S 函数编写可实时运行的 MPC 代码。为对比规模缩减法与已有快速 MPC 算法的优缺点, 定义三种 MPC 算法, 记为 C1、C2 和 C3, 如表 5.4 所示。C1 无任何快速计算措施, C2 仅含变量集结策略, C3 同时包含变量集结策略和约束集压缩策略, 即: 规模缩减法。实时仿真结果如图 5.9、图 5.10 和图 5.11。

表 5.4 三种 MPC 算法

MPC 算法	变量集结策略	约束集压缩策略	线型
C1	无	无	X 标记线
C2	有	无	实线
C3	有	有	虚线

图 5.9 中, (a) 是期望加速度, (b) 是相对车速, (c) 是车距误差, (d) 是松弛因子。由图 5.9 (a)、(b)、(c) 和 (d) 知, 算法 C1、C2 和 C3 的期望加速度、相对车速、车距误差和松弛因子基本重合, 说明三算法下, 车辆 MOCACC 系统的控制结果基本一致。




图 5.9 车辆 MOCACC 系统的输入输出




图 5.9 车辆 MOCACC 系统的输入输出 (续)

图 5.10 中, (a) 是三算法的单步计算时间曲线, (b) 是单步计算时间的平均值和最大值。图 5.10 中, X 标记线、实线和虚线分别为算法 C1、C2 和 C3 的单步计算时间。由图 5.10 (a) 知, 算法 C1、C2、C3 的单步计算时间依次减小。由图 5.10 (b) 进一步知, 算法 C2 的平均计算时间约为算法 C1 的 1/3, 最大计算时间约为算法 C1 的 1/2, 算法 C3 的平均计算时间仅为算法 C1 的 1/8, 最大计算时间仅为算法 C1 的 1/5。这表明, 变量集结和约束集压缩策略可有效降低预测优化问题的规模, 降低其计算复杂度, 提高滚动时域优化的计算效率。




图 5.10 MPC 计算效率验证

因算法 C1 未应用任何快速性策略, 它对车辆 MOCACC 系统实施最优控制,

其结果可看作闭环系统的最优控制结果。以算法 C1 的控制结果为标准, 算法 C2、C3 控制结果与 C1 结果的误差如图 5.11 所示。图 5.11 中, (a) 是期望加速度的误差, (b) 是松弛因子的误差, (c)、(d) 分别为 Δv 和 Δd 的误差。图中, 误差大小反映了闭环系统偏离最优控制功能的程度。




图 5.11 控制最优性的验证

由图 5.11 (a) 易知, 算法 C2 对期望加速度的误差小于 0.5×10^{-2} , 对松弛因子的误差小于 0.5×10^{-2} , 远远低于正常的控制输入量和松弛因子量。而且, 它对相对车速的误差小于 0.1×10^{-2} , 对车距误差的误差小于 1.0×10^{-2} , 这说明: 算法 C2 的控制输入和系统输出与最优值基本一致, 变量集结策略基本不影响车辆 MOCACC 系统的最优性。图 5.11 中, 虚线是算法 C3 的误差。与 C2 相比, 算

法 C3 对松弛因子的误差略大。这是因为 C3 中松弛因子与约束条件密切相关, 约束集压缩策略本身是对约束条件进行处理, 不可避免地影响松弛因子的准确度。实际上, 松弛因子仅用于避免非可解问题, 其误差并不影响控制的最优性。而且与算法 C1 相比, 松弛因子的相对误差也仅为 1% 左右。另外, 考虑到算法 C3 不仅包括约束集压缩策略, 而且包括变量集结策略, 它的误差是由两部分组成。即使如此, 算法 C3 对期望加速度的误差小于 0.5×10^{-2} , 对相对车速的误差小于 0.2×10^{-2} , 对车距误差的误差小于 1.5×10^{-2} , 远小于三者的实际量。因此, 本文提出的约束集压缩策略也几乎不影响车辆 MOCACC 系统的最优性。

5.7 本章小结

为实现新一代 ACC 的实车应用, 本章分析了模型预测控制算法的低鲁棒性、非可解和高计算复杂度问题, 依次建立了基于反馈校正法的鲁棒跟车预测模型、基于约束管理法的预测优化问题、基于规模缩减法的 MPC 快速算法。理论分析及其仿真验证表明:

(1) 车辆对象中, 因参数误差、未建模动态及外部干扰等不确定性的存在, 跟车预测模型必然存在一定失配, 导致车辆 MOCACC 系统的性能下降。具有反馈校正项的鲁棒跟车预测模型, 可补偿因模型失配造成的状态预测误差, 在一定程度上自适应跟车系统的特性, 提高了闭环控制的鲁棒性。

(2) 跟车系统的 I/O 硬约束是最优控制量非可解的主要原因。利用约束管理法修正代价函数, 软化 I/O 硬约束后, MPC 算法具有自动放宽约束范围的能力, 扩展了最优控制量的求解可行域, 避免了车辆 MOCACC 的非可解问题。

(3) 优化问题规模缩减的基本框架包括变量集结策略和约束集压缩策略两部分。该法不受被控对象和性能指标的类型限制, 同时适用于线性或非线性被控对象, 线性约束集或椭圆约束集, 1 范数型、2 范数型或 ∞ 范数型的代价函数。基于规模缩减法的模型预测控制快速算法可有效降低静态优化问题的计算复杂度, 提高滚动时域优化的计算效率, 而且几乎不影响闭环控制的最优性。

第6章 车辆 MOCACC 系统的实验研究

本章针对已有实验平台的不足，提出一种改进的实验平台总体方案。该方案中，车辆及车间状态信息通过 CAN 总线采集，主控制器采用 xPC 技术设计，油门执行器为电子节气门，制动执行器为电子真空助力器。为验证 MOCACC 系统的有效性，以改进的实车实验平台为对象，在四类前车特定工况和两类前车循环工况下，对本文方法的性能进行实验研究，并与现有的 LQ 控制系统进行对比。实验结果表明，所开发的车辆 MOCACC 系统可同时降低跟踪误差和车辆油耗，且符合多类驾驶员跟车特性。

6.1 车辆实验平台的设计与开发

图 6.1 是课题组原车辆实验平台的总体方案。




图 6.1 原车辆实验平台的总体方案

该结构中，信号采集 ECU 直接与原车传感器电气连接，采集传感器的输出量，计算并输出车辆及其总成的状态信息。利用 AutoBox 建立的主控制器，运行驾驶员纵向辅助控制算法，输出期望节气门开度和期望制动压力。油门 ECU 和制动 ECU 控制相应的电机拖动式节气门和电控液压制动装置。平台中，所有

数据和信息由一条独立的 CAN 总线传输。该方案存在如下缺陷：

1. 信号采集 ECU 的 A/D、DI 端口直接连接原车传感器的电气输出端，一是对原车电路的改造大，二是易影响原车电控系统的信号采集；而且，原车 CAN 总线与平台 CAN 总线分离，难以实现二者的信息共享；

2. 主控制器 AutoBox 的软硬件过于昂贵，维护流程复杂；而且，受 dSPACE 公司的技术保密限制，其 Simulink 模块的内部代码是不公开的，用户难以进行二次开发，满足一些特殊的控制要求；

3. 原电子节气门采用直流电机拖动节气门体的方案，对原节气门机构的硬件改造大，而且机械连接件之间存在较大间隙、摩擦，对节气门控制精度的影响较大；制动执行器采用电控液压制动装置，成本偏高，而且它的油泵电机必须额外供电，装置的耗能大。

6.1.1 改进的实车实验平台总体方案

针对上述问题，考虑原车电控系统的特点，对原车辆平台进行改造。改造中，一是希望充分利用原车电控系统的特点，共享原车电控系统对车载传感器的处理信息，二是要求主控制器具有快速控制原型功能，且扩展性好，便于一些特殊控制算法（如 MPC）的开发；三是降低执行器的硬件成本，且维持节气门开度和制动压力的控制精度，满足高性能的驾驶员辅助需求。

图 6.2 是改进的车辆实验平台总体方案，它包括传感器子系统，控制器子系统和执行器子系统。传感器子系统包括毫米波雷达、雷达 ECU、信息采集 ECU 以及附加的车载传感器。控制器子系统包括 xPC 控制器和监控笔记本。执行器子系统包括电子节气门、电子真空助力器（EVB, Electronic Vacuum Booster）以及执行器 ECU。各子系统由平台 CAN 总线进行数据通讯，该总线与原车 CAN 相连接，具备共享原车电控系统信息的能力。




图 6.2 改进的车辆实验平台总体方案

传感器子系统中，毫米波雷达及其 ECU 的功能是探测前方车辆信息，提取目标车的相对车速和车间距离。信号采集 ECU 与附加传感器用于补充原车 CAN 未具备的信息，如纵向加速度等。控制器子系统中，xPC 主控制器从 CAN 总线获取车间和车辆状态信息，运行基于 MPC 的 MOCACC 算法，输出期望节气门开度和期望制动压力。监控笔记本通过以太网与 xPC 控制器相连，具有实时调整控制参数和保存实验数据的功能。执行器子系统中，执行器 ECU 以 xPC 主控制器的输出量为期望值，采用电子节气门控制发动机的油门开度，采用 EVB 调节制动系的制动压力。

依托课题组现有的工作基础，本文主要设计平台 CAN 的应用层协议，研制 xPC 控制器，完善电子节气门和 EVB 的控制算法，实现实车实验平台的集成。

6.1.2 平台 CAN 应用层协议的设计

目前，CAN 总线技术已有 ISO-11898 国际标准，针对汽车领域的应用，也

定义了 SAEJ1939 等应用层协议标准。本平台车中, 发动机 ECU、自动变速器 ECU、ABS ECU 等车身电子设备将与车辆相关的信息发送至原车 CAN 总线。车辆纵向运动控制所需信息中, 除车间状态信息、纵向加速度和制动压力外, 均可从原车 CAN 总线中提取。

为实现各子系统的通讯, 参考 CAN2.0 标准制定平台 CAN 应用层协议。因为平台 CAN 与原车 CAN 直接电气相连, 制定协议的一个关键是兼容原车 CAN 协议。采用 CANoe 等工具, 对原车进行逆向分析, 得到原车 CAN 协议的基本特性: (1) 符合 SAE1939 标准, 波特率为 500 bits/s; (2) 数据帧固定周期发送, 但各标识符的发送周期不同, 最低 1ms, 最高 100ms; (3) 标准数据帧, 长度 11 位, 属于 Motorola 格式。原车 CAN 协议中, 部分标识符及其数据帧如表 6.1 所示。

表 6.1 原车 CAN 的部分应用层协议

标识符	变量	字节	系数	偏移量	单位
0x201	加速踏板开度	7	0.5	0	%
0x201	车速	5,6	0.01	-100	km/h
0x201	发动机转速	0,1	0.25	0	rad/s
0x240	节气门开度	4	0.5	0	%
0x231	挡位	1	1	0	--
0x420	发动机油耗	2,3	0.017	0	g/s

为兼容原车 CAN 协议、满足实时通讯要求, 平台 CAN 协议应符合两个原则: (1) 控制优先原则: 与实时控制相关的标识符具有高优先权, 且原车 CAN 高于平台 CAN; 与信号采集相关的标识符次之; 最低为与控制无关的辅助性标识符; (2) 低负载率原则: 平台 CAN 总线接入原车 CAN 总线, 不应过多增加原车 CAN 的负载率, 保证 CAN 网络传输数据的可靠性。

为满足第一条原则, 考虑 CAN2.0 标准中, 标识符越小, 优先权越高, 建立平台 CAN 协议的仲裁场格式, 如图 6.3。图中, 前 3 位决定信息的优先权, 优先权越高, 越易取得 CAN 总线的使用权。后 8 位用于区分不同标识符, 用于传输不同的数据和信息。




图 6.3 平台 CAN 协议的仲裁场格式

平台 CAN 协议的优先权如表 6.2 所示（含原车 CAN 的部分信息帧）。

表 6.2 平台 CAN 的优先权分配

类型	标识符	优先权	前三位	关联内容
原车	0x201/0x240/0x231	最高	010	发动机、变速器电控
CAN	0x420	中	100	发动机状态
平台 CAN	0x319	次高	011	执行器电控
	0x311	次高	011	主控制器的控制命令
	0x418	中	100	信号采集 ECU 的输出
	0x439	中	100	雷达 ECU 的输出
	0x501/0x502	低	101	辅助功能及故障诊断

平台 CAN 中所有信息均采用固定周期型广播式发送，发送周期为 100ms。为了保证数据帧发送周期的准确性，各 ECU 由定时器产生的中断触发，xPC 主控制器采用与 Simulink 解法器同步的措施。对于数据帧的接收程序，为了避免丢失数据帧，采用中断方式接收。表 6.3 是执行器电控的 0x319 数据帧。

表 6.3 平台 CAN 的 0x319 数据帧

信号	字节	系数	偏移量	单位
制动压力（管路 A）	1	0.1	0	MPa
纵向加速度	3,4	0.02	0	m/s ²
进气歧管压力	5	0.1	0.05	V
制动压力（管路 B）	7	0.1	0	MPa
制动信号	8	1	0	0 或 1

6.1.3 xPC 控制器的软硬件设计与开发

因 xPC 技术具有下列优点，是设计实车平台主控制器的理想技术手段：（1）具有快速控制原型功能，可直接运行由 Simulink 框图编译的可执行程序；（2）扩展性好，其 Simulink 模块的 C/C++ 代码是开放的，便于用户二次开发；（3）与 AutoBox 控制器相比，其软硬件成本较低，维护方便，便于长期装车使用。

图 6.4 是 xPC 控制器的硬件组成，它包括工控机、网卡和 CAN 卡。




图 6.4 xPC 控制器的硬件组成

工控机的 CPU 主频为 2.4GHz，内存为 512M。CAN 卡为 Softing 公司的 CAN-AC2-PCI 型，用于工控机与 CAN 总线的数据通讯。网卡为 Intel Pro/100+ 型，用于监控笔记本和工控机之间的监控通讯。

图 6.4 是 xPC 控制器的 Simulink 软件结构，包括 CAN 接收模块、虚拟雷达模块、驾驶辅助控制模块以及 CAN 发送模块。




图 6.5 xPC 控制器的软件结构

CAN 接收模块用于采集原车 CAN 以及各 ECU 输出的车辆或车间状态信息。虚拟雷达模块利用开发人员设定的前车工况，结合实际的车辆状态信息，模拟雷达输出的车间状态信息。与实际雷达的输出相比，虚拟雷达的前车运动轨迹

固定，可多次重复同一工况的实验，便于比较不同控制方法的性能。虚拟雷达和实际雷达的输出通过软开关“S”切换。驾驶辅助控制模型运行纵向驾驶员辅助控制算法，输入是车间状态和车辆状态信息，输出是期望的执行器控制量 α_{thrdes} 、 P_{brkdes} 。

本文中，驾驶辅助控制模块运行车辆 MOCACC 算法，它包括外部干扰估计器、模型预测控制模块、加速度校正器、车辆逆纵向动力学模型和油门制动切换逻辑，其框图如图 6.6 所示。外部干扰估计器用于估计前车加速度。加速度校正器、车辆逆纵向动力学模型和油门制动切换逻辑相当于下位控制器，以期望加速度为输入，输出期望节气门开度和期望制动压力。模型预测控制模块是实现多目标协调式自适应巡航控制功能的关键，包括一个数值计算模块和两个延迟环节。




图 6.6 车辆 MOCACC 算法的框图

第 4 章和第 5 章已给出 MPC 算法的数学形式，本节进一步介绍其代码流程。模型预测控制模块的主体是数值计算模块。该模块由离线计算和在线计算两部分组成。表 6.4 是两部分的计算分工。

表 6.4 离线计算和在线计算的分工

步骤	计算内容		离线计算部分	在线计算部分
1	C-Mex S 函数的输入		○	$\hat{v}(k), y(k), v_f(k)$
2	离散跟车动力学模型		$A_{High}, B_{High}, G_{High}$ $A_{Low}, B_{High}, G_{Low}, C$	λ, A, B, G
3	MOCACC 性能指标	代价函数	$w_y, w_u, w_{\Delta u}$	SVE, SDE, ω_{CF}
		I/O 约束	$u_{\min}, u_{\max}, \Delta u_{\min}, \Delta u_{\max}, d_{safe}, \tau_{safe}$	$y_{\min}, y_{\min}, a_{safe}$
4	反馈校正处理	外部干扰	--	V
		鲁棒跟车预测模型	--	$S_x, S_{u1}, S_u, S_e, H_v$
		U 与 ΔU 的关系	$T_{u1}, T_{\Delta u}$	--
5	约束管理处理	矩阵型代价函数	$W_y, W_u, W_{\Delta u}$	Ω_{CF}
		矩阵型 I/O 约束	$U_{\max}, U_{\min}, V_{\max}^u, V_{\min}^u$ $\Delta U_{\max}, \Delta U_{\min}, V_{\max}^{\Delta u}, V_{\min}^{\Delta u}$ $V_{\max}^y, V_{\min}^y, D_{safe}, T_{safe}, V_+$	$Y_{\max}, Y_{\min}, A_{safe}$
6	规模缩减处理	集结矩阵	M_T	--
		压缩矩阵	$M_{\Delta U}, M_U, M_Y$	--
7	二次规划问题	二次规划的代价函数	--	$\bar{S}_u, \bar{S}_x, \bar{T}_{\Delta u}$ H_{opt}, f_{opt}
		二次规划的约束集	--	$A_{cstr}, b_{cstr}, M_T^+$
8	二次规划数值求解		○	Z^*, ε^*
9	预测 k+1 的状态		○	$x(k+1 k)$
10	C-Mex S 函数的输出		○	$z(k), a(k), x(k+1 k)$

注：表中各矩阵表示该步计算的输出结果。




图 6.7 数值计算模块的组成

图 6.7 展示了数值计算模块的组成。离线计算部分的代码由 M 语言编写，用于计算 MPC 算法的时不变矩阵，仅在 xPC 控制器启动之前运算一次。它的结果以参数的形式输入在线计算部分，以减少在线优化的计算量。在线计算部分利用 C-Mex S 函数建立，代码由 C 语言编写，主循环与 Simulink 解法器同步，即：Simulink 模型每循环一次，在线计算部分运算一遍，它与两个延迟环节共同完成 MPC 的滚动时域优化计算。

表 6.4 中，表格内容是每步计算得到的系数矩阵。表 6.4 中，第 2~7 步是离线计算部分的计算步骤。与之相比，在线计算部分增加了第 1、8、9 和 10 步。xPC 控制器运行之前，离线计算部分从步骤 2 到步骤 7 依次计算时不变矩阵，作为 C-Mex S 函数的参数输入在线计算部分。xPC 控制器运行时，C-Mex S 函数首先初始化离线计算得到的参数，然后，每个 Simulink 循环，由在线计算部分依次计算步骤 1 到步骤 10，直至控制器停止运行。

6.1.4 执行器控制算法的设计与验证

实验平台采用电子节气门和 EVB 对发动机节气门开度和制动系制动压力进行控制。

平台车装有 2.0L 电喷汽油机，图 6.8 是其电子节气门总成的基本结构。它包括角位移传感器、发动机 ECU 和电子节气门阀体三部分。油门踏板开度经角位移传感器测量后，转化为电压信号 V_{thr} ，输入至发动机 ECU，由发动机 ECU 根据发动机状态和油门踏板位置，控制电子节气门阀体与驾驶员期望的节气门开度一致。




图 6.8 电子节气门总成的基本结构

为充分利用已有电子节气门总成的功能，将踏板开度传感器与发动机 ECU 的电气连接断开，中间连接执行器 ECU，如图 6.9 所示。




图 6.9 执行器 ECU 的电气连接方式

电子节气门控制时，执行器 ECU 的输入为 xPC 控制器输出的期望节气门开度 α_{thrdes} 和驾驶员的加速踏板开度 V_{thr} ，输出为虚拟的加速踏板开度电压 U_{thr} 。图 6.10 是与节气门控制相关的 ECU 电路原理图。该电路中，16 单片机用于计算与期望节气门开度对应的虚拟电压 V_{thrdes} ，电压比较器比较虚拟电压 V_{thrdes} 和驾驶员踏板电压 V_{thr} ，输出较大的电压值，经电压保持后，作为发动机 ECU 的输入电压 U_{thr} 。




图 6.10 电子节气门控制的电路原理图

电压比较器的作用在于避免驾驶员操作与自动控制的干涉，选择控制输入

量较大者作为发动机 ECU 的输入量。与软件判断相比,电压比较器可避免单片机代码跑飞、出错造成的故障,提高了电子节气门控制的可靠性。

单片机的控制代码中,为利用期望节气门开度 α_{thrdes} 计算虚拟电压 V_{thrdes} ,须先建立原电子节气门总成中节气门开度 α_{thr} 与加速踏板电压 V_{thr} 的对应关系。为此,对原节气门总成进行实验,建立 α_{thr} 与 V_{thr} 的关系,如图 6.11 所示。




图 6.11 α_{thr} 与 V_{thr} 的关系曲线

利用三次函数拟合二者的数据点,建立 α_{thr} 与 V_{thr} 的关系,如式 (6-1) 所示。

$$V_{thr} = 9 \times 10^{-6} \alpha_{thr}^3 - 1.3 \times 10^{-3} \alpha_{thr}^2 + 0.075 \alpha_{thr} + 0.73 \quad (6-1)$$

记 α_{thr} 与 V_{thr} 的拟合函数为 $V_{thr} = \text{THR}(\alpha_{thr})$ 。单片机的控制代码中,若仅以拟合函数 $\text{THR}()$ 建立 α_{thrdes} 和 V_{thrdes} 的关系,相当于对电子节气门进行开环控制。开环控制中,因实验数据的测量误差、发动机进气干扰以及单片机 D/A 输出的不准确性,节气门开度跟踪不可避免存在较大稳态误差。为提高电子节气门的稳态控制精度,以拟合函数 $\text{THR}()$ 为前馈补偿器,结合 PI 反馈建立电子节气门的控制算法,如图 6.12 所示。

前馈控制器利用 $\text{THR}()$ 函数设计,输入为期望节气门开度 α_{thrdes} ,输出为期望加速踏板电压 V_{thrdes} 。PI 控制器中,常数系数为 0.04,积分系数为 0.006,它利用节气门开度的跟踪误差反馈补偿 V_{thrdes} ,以提高节气门控制的精度。




图 6.12 电子节气门的控制框图

图 6.13 是电子节气门控制的实验结果，(a) 是阶跃输入的响应曲线，(b) 是正弦输入的响应曲线。由图易知，所设计的节气门控制系统的响应时间约为 0.15 秒，稳态跟踪误差约小于 0.5%。




图 6.13 电子节气门控制结果

目前，EVB 因具有硬件成本低，对原车结构改动小，可反馈制动感至驾驶员等优点，在乘用车 ACC 中广泛应用。本章将课题组开发的 EVB 用于实车实验平台，设计增量式 PI 控制算法实现制动压力的准确控制。图 6.14 是 EVB 控制的电路原理，图 6.15 是 EVB 控制算法的原理图。其基本原理是：由 16 位单片机计算占空比，由 PWM 发生器生成相应的 PWM 信号，经功率放大后，驱动 EVB 电磁铁。EVB 中，由电磁铁调节膜片气室的进排气速率，控制膜片气室的真空度，从而实现制动系制动压力的调节。




图 6.14 EVB 控制的电路原理




图 6.15 EVB 的控制框图

为准确实现制动压力跟踪,将 EVB 工作状态分为增压、保压和减压。当 P_{brkdes} 大于 P_{brk} 时,处于增压过程;当 P_{brkdes} 等于 P_{brk} 时,处于保压过程;当 P_{brkdes} 小于 P_{brk} 时,处于减压过程。实际控制中, P_{brkdes} 准确等于 P_{brk} 的过程几乎不存在,而且因压力传感器噪声的存在,当 P_{brkdes} 近似等于 P_{brk} 时, EVB 会在增压状态和减压状态频繁切换。为避免该问题,设置状态判断阈值 e_{Δ} ,建立 EVB 状态的判断条件:

$$\begin{aligned} & \text{增压, if } e_p(k) > e_{\Delta} \\ & \text{保压, if } -e_{\Delta} \leq e_p(k) \leq e_{\Delta}, \quad e_p = P_{brkdes} - P_{brk} \\ & \text{减压, if } e_p(k) < -e_{\Delta} \end{aligned} \quad (6-2)$$

式 (6-2) 中, e_p 为制动压力误差, $e_{\Delta}=0.1\text{MPa}$ 为判断阈值。各状态下,增量式 PI 控制器如式 (6-3) 所示。

$$\Delta u_p(k) = \begin{cases} k_{p1}(e_p(k) - e_p(k-1)) + k_{i1}e_p(k)T_s & \text{增压} \\ 0 & \text{,保压} \\ k_{p2}(e_p(k) - e_p(k-1)) + k_{i2}e_p(k)T_s & \text{减压} \end{cases} \quad (6-3)$$

式 (6-3) 中, Δu_p 为占空比增量, T_s 为控制频率, k_{p1} 和 k_{i1} 为增压过程的控制系数, k_{p2} 和 k_{i2} 为减压过程的控制系数。根据实验,控制系数选为 $k_{p1}=5$,

$k_{I1}=0.2$, $k_{P2}=4$ 和 $k_{I2}=0.125$ 。图 6.16 是 EVB 控制的实验结果, 图 (a) 是阶跃输入的响应曲线, 图 (b) 是正弦输入的响应曲线。由图知, EVB 控制下, 制动压力的动态响应时间小于 0.2 秒, 稳态跟踪误差小于 0.2MPa。




图 6.16 EVB 的控制结果

6.1.5 实车平台各部件的集成

在完成平台 CAN 网络和各部件设计基础上, 对实验平台进行集成。实验平台中, 各部件与车辆各总成多具有电气或机械连接关系。考虑硬件改装的便利性、信号传输的可靠性以及各部件的功能要求, 进行如下的部件安装、电源标配、线束布置等工作。

原车拆掉真空助力器, 在原位置安装 EVB, 如图 6.17 (a)。执行器 ECU 和信号采集 ECU 安装于前面板下, 如图 6.17 (b)。毫米波雷达及其 ECU 安装于前保险杠处, 如图 6.17 (c)。xPC 控制器安装于后备箱, 如图 6.17 (d)。监控笔记本放置在副驾驶或后座位置。平台 CAN 总线采用双绞屏蔽线, 沿车内地板左侧布置。

实验车中, EVB 直接采用原车 12V 电源供电, 各 ECU 自带 DCDC 模块, 将 12V 转为直流 5V, 作为单片机供电电源, xPC 主控制器和监控笔记本由 12V~220V 逆变器供电。改造的实验平台中, 加速度计是重要的附加传感器, 安装于平台车的质心附近。图 6.18 是改造完成的实车实验平台。




图 6.17 平台主要部件的安装位置



图 6.18 实车实验平台

6.2 对比 ACC 系统与实验工况设计

本节首先基于线性最优二次型 (LQ, Linear Quadratic) 控制方法设计对比 ACC 系统; 其次, 考虑城市道路和高速公路的典型交通流特征, 设计“虚拟雷达”的前车工况; 最后, 在汽车实验场进行实车实验, 对开发的 MOCACC 系统及其对比 ACC 系统进行验证。

6.2.1 用于性能对比的 ACC 控制算法设计

因 LQ 是一类适用于线性对象的最优控制方法, 故基于 LQ 方法设计的 ACC 系统也具备一定的多目标协调控制功能。与其他单一目标的控制方法相比, 如自适应控制法^[130], 滑模变结构法^[113]等, LQ 方法更适合作为 MPC 方法的对比算法。

参照 K. Yi 等人的成果^[27,28,133,134], 对比 ACC 系统采用分层控制结构, 包括上位控制器和下位控制器。下位控制器的设计同节 4.2, 包括加速度校正器、车辆逆纵向动力学模型和油门制动切换逻辑。设计上位控制器时, 被控对象为跟车系统动力学模型 (4-13), 但在平均车速 $v_f=17.5\text{m/s}$ 处 Taylor 线性化, 以满足 LQ 对线性被控对象的要求。上位控制器的性能指标为:

$$J = \int_0^{\infty} (\mathbf{x}^T \mathbf{w}_y \mathbf{x} + u^T \mathbf{w}_u u) dt \quad (6-4)$$

由 (6-4) 知, 选择 LQ 性能指标的权系数与 MOCACC 性能指标的权系数一致, 以避免参数不同引起的控制算法特性差异。利用代数 Riccati 方程可求解线性反馈控制算法:

$$\mathbf{u} = \mathbf{K}\mathbf{x} \quad (6-5)$$

式 (6-5) 中, $\mathbf{K}=[-0.06, -0.30, 0.17]$ 为反馈增益。上位控制器 (6-5) 和下位控制器构成第一种对比 ACC 系统, 简记为 LQACC。为了提高驾驶员纵向乘坐舒适性, 进一步在控制输入量 u 上增加饱和约束, 建立带输入约束的 LQ 上位控制器, 称为 CLQ(Constrained LQ) 控制器:

$$\mathbf{u} = \begin{cases} u_{\max} & \mathbf{K}\mathbf{x} > u_{\max} \\ \mathbf{K}\mathbf{x}, & u_{\min} \leq \mathbf{K}\mathbf{x} \leq u_{\max} \\ u_{\min} & \mathbf{K}\mathbf{x} < u_{\min} \end{cases} \quad (6-6)$$

式(6-6)中, u_{\min} 为控制输入下界, u_{\max} 为控制输入上界, 二者也与 MOCACC 性能指标中控制输入约束一致, 为 $u_{\min}=-1.5\text{m/s}^2$, $u_{\max}=0.5\text{m/s}^2$ 。上位控制器(6-6)和下位控制器构成第二种对比 ACC 系统, 简记为 CLQACC。

6.2.2 “虚拟雷达”的前车工况设计

本文采用“虚拟雷达”输出的车间距离和相对车速作为车间状态信息。与直接使用雷达相比, 虚拟雷达以固定的前车工况计算车间运动信息, 可保证各控制器实验时的前车工况是一致的。

为了充分展现新一代 ACC 系统的性能, 设计两类“虚拟雷达”工况。第一类称为前车特定工况, 由四组持续时间较短的前车运动工况组成, 反映某一特定场景, 例如: 加速、制动或前车切入切出等。第二类称为前车循环工况, 由两组持续时间较长的前车运动工况组成, 分别反映城市道路交通流、高速公路交通流的整体特性。

前车特定工况包括: 前车定加速工况、前车紧急制动工况、前车切出工况和前车正弦加减速工况。前车定加速工况用于模拟典型的加速行车过程, 如图 6.19 所示。为反映交通流的不同加速度水平, 前车定加速工况包含两个子工况, 即前车小定加速工况和前车大定加速工况。前者中, 初始车速为 10m/s , 从 15 秒开始, 以 0.3m/s^2 的定加速度行驶, 至 15m/s 结束。后者中, 初始车速为 10m/s , 从 15 秒开始, 以 0.6m/s^2 的定加速度行驶, 至 18m/s 结束。




图 6.19 前车定加速工况

前车紧急制动工况用于模拟因危险障碍物造成的前车快速制动过程, 如图 6.20 所示。该工况中, 前车初始车速为 18m/s , 从 15 秒开始, 以 -2.5m/s^2 的减

度紧急制动至 4m/s。




图 6.20 前车紧急制动工况

前车切出工况用于模拟目标车切出本车道的过程。该工况中，原前方目标车的车速为 10m/s，15 秒时该车切出本车道，雷达探测到新的前方目标车。新目标车在原目标车前方 12m 处，车速也为 10m/s。这相当于前车车速保持不变，车间距离阶跃增加 12m 的前车运动工况。

前车正弦加减速工况用于模拟典型的动态行车过程，如图 6.21 所示。为反映交通流的不同加速度水平，它也包括两个子工况，即前车小正弦加减速工况和前车大正弦加减速工况。前者中，前车初始车速为 10m/s，正弦加速度幅值为 0.3m/s^2 ，周期为 20s。后者中，前车初始车速和加速度周期同前者，但加速度幅值为 0.6m/s^2 。




图 6.21 前车正弦加减速工况

前车循环工况的设计依据是日本 ISUZU 公司制定的 ACC 前车循环工况。

ISUZU 设计的前车循环工况分为城市道路工况和高速公路工况两组，每组工况约持续 13.3min，如图 6.22 所示。




图 6.22 ISUZU 公司的 ACC 前车循环工况

图 6.22 中，虚线主要反映城市道路中，车辆频繁加减速的拥堵交通流特性；实线则反映高速公路中，前车小加速度、大车速变化的舒缓交通流特性。考虑本文不控制车辆起-停过程，而且受场地长度和安全性的限制，不宜使用过高的实验车速，故带起步、停车和高速行车过程的 ISUZU 循环工况不完全适用于车辆 MOCACC 系统的场地实验。在保持工况所反映交通流特性不变的基础上，将 ISUZU 城市道路工况的车速增加 5m/s，将 ISUZU 高速公路工况的车速乘以因子 0.6，建立本文实验用的前车循环工况。修正后的前车循环工况中，车速处于 5m/s 到 20m/s 之间，分别保持了城市道路交通流和高速公路交通流的特点。下文仍沿用原有称呼，将两种修正的前车循环工况称为“城市道路工况”和“高速公路工况”。

6.2.3 实验场的实车实验过程描述

北京通县汽车实验场，道路为干燥沥青路面，坡度小于 0.5%，道路直线段长度约为 3km，天气晴朗，风速小于 2 级。考虑增加的硬件设备以及实验人员，所以，实验车相当于满载质量。实验过程中，“虚拟雷达”前车工况以及对应的 ACC 系统如表 6.5 所示。

为简化下文的叙述，本文将基于 MPC 理论设计的车辆 MOCACC 系统，简记为 MOCACC。将基于 LQ 理论设计的 ACC 系统，简记为 LQACC。

表 6.5 前车工况和 ACC 系统

类别	工况编号	工况名称		ACC 系统
前车 特定工况	1	前车定加速工况	小定加速度	MOACC LQACC
	2		大定加速度	
	3	前车紧急制动工况		
	4	前车切出工况		
	5	前车正弦加减速 工况	小正弦加速度	
	6		大正弦加速度	
前车 循环工况	7	城市道路工况		MOCACC
	8	高速公路工况		CLQACC

实验场景如图 6.23 和图 6.24 所示。图 6.23 是起步阶段的实验场景。图 6.24 是行驶阶段的实验场景。



图 6.23 实车实验场景（起步阶段）




图 6.24 实车实验场景（行驶阶段）

实验过程中, 含 ACC 控制信号、车辆状态、车间状态以及控制器内部状态的实验数据均由 xPC 主控制器发送至监控笔记本, 由监控笔记本实时显示并保存数据。

6.3 前车特定工况的实验验证

本节利用前车特定工况的实验结果, 对比分析车辆 MOCACC 系统的特性。前车定加速工况主要用于检验纵向乘坐舒适性标准对加速度水平以及跟踪性能的影响; 前车紧急制动工况主要用于检验跟车安全性条件的有效性以及约束管理法对跟车安全性的影响; 前车切出工况主要用于检验驾驶员期望跟踪误差范围对相对车速和车距误差的影响; 前车正弦加减速工况主要用于检验驾驶员参考模型对跟车轨迹的影响, 以及整车的油耗特性。

6.3.1 前车定加速工况

图 6.25 是前车小定加速度工况 (工况 1) 的实验结果。图中, (a) 是期望加速度, (b) 是实际加速度, (c) 是相对车速, (d) 是车距误差, (e) 是松弛因子, (f) 是 xPC 控制器单步计算时间。图中, 粗实线代表 MOCACC, 细实线代表 LQACC, 点线为 I/O 约束的上下界。图 6.26 是前车大定加速度工况 (工况 2) 的实验结果。图例与工况 1 完全一致。

工况 1 中, 加速阶段的前车加速度为 0.3m/s^2 , 小于纵向乘坐舒适性标准的上界。由图 6.25 (a) (b) (c) (d) 知, LQACC 和 MOCACC 的期望加速度、实际加速度、相对车速和车距误差均处于 I/O 硬约束的上下界之内, 而且两种 ACC 系统的控制结果比较接近, 无明显差别。由图 6.25 (e) 知, MOCACC 的松弛因子近似为零, 对 I/O 硬约束基本无松弛作用。

值得注意的是, 从 15 秒到 32 秒, 松弛因子近似为零, 但不等于零。这是因为: 尽管跟车系统的当前时刻输入输出均处于 I/O 约束之内, 但预测时域内, 尤其是预测点靠近末尾处, 系统输入输出的预测值会超过约束范围, 松弛因子不为零与之相关, 是合理的。




图 6.25 前车小定加速度工况




图 6.26 前车大定加速度工况

工况 2 中，加速阶段的前车加速度为 0.6m/s^2 ，大于纵向乘坐舒适性标准的上界。由图 6.26 (a) 和 (b) 知，LQACC 中，因控制输入无约束，期望加速度和实际加速度超过纵向乘坐舒适性标准的上界，这不可避免降低乘坐舒适性，增加车辆的油耗。由图 6.26 (a) 和 (b) 知，MOCACC 中，因控制输入约束的存在，期望加速度基本处于纵向乘坐舒适性标准之内，有力地保障了自适应巡航过程的乘坐舒适性。

受纵向乘坐舒适性标准的限制，与 LQACC 相比，MOCACC 的加速性能相对较弱。如图 6.26 (c) 和 (d) 知，MOCACC 的相对车速和车距误差较大，跟踪性能低于 LQACC。然而，从多目标协调控制的角度看，这并没有妨碍跟踪性能目标的实现。这是因为：由图 6.26 (d) 知，MOCACC 的车距误差仍处于驾驶员期望跟踪范围之内，不会引入频繁的前车切入。跟车过程中，只要旁道车辆不切入本车道，稍大的跟踪误差不影响自动跟车功能的实现。而且，由图 6.26 (e) 知，当相对车速大于其上界时，MOCACC 可增大松弛因子量，扩展控制输入的上界。如图 6.26 (a) 知，因控制输入上界的升高，期望加速度略高于硬边界，车辆加速能力有所提高，这有利于减小相对车速和车距误差，提高 MOCACC 的跟踪性能。这一特性在前车紧急制动工况中体现更加明显。

另外，综合图 6.25 (f) 和图 6.26 (f) 知，两类工况中，xPC 控制器的最大单步计算时间不超过 40ms，小于 ACC 的控制周期 100ms，这说明本文开发的快速 MPC 算法以及 xPC 控制器满足车辆对象的实时性要求。

6.3.2 前车紧急制动工况

图 6.27 是前车紧急制动工况（工况 3）的实验结果。图中，(a) 是车距，(b) 是松弛因子，(c) 是期望加速度，(d) 是制动压力。图 6.27 (a) 中，点划线代表安全车距。各图中，菱形线是 LQACC 中车距为零的时刻，其它图例同工况 1。

新一代 ACC 系统中，因燃油经济性目标的介入， Δd 和 Δv 的权系数 $w_{y\Delta d}$ 、 $w_{y\Delta v}$ 较小， a_f 和 a_{fdes} 的权系数 w_{ya} 、 w_u 较大，这导致车辆的加速/制动能力较低。工况 3 中，前车的减速度为 -2.5m/s^2 ，由 18m/s 急减速至 4m/s 。由图 6.27 (c) 和 (d) 知，LQACC 作用下，自车制动压力较低，制动减速度的绝对值较小。如图 6.27 (a) 所示，因自车制动强度不足，当前车紧急减速时，车间距离迅速减小，越过安全车距的边界。约 22 秒处，车距为零，发生追尾碰撞事故。

与之不同，MOCACC 具有控制输入的软约束，当车间距离接近安全车距时，

MPC 算法可自动增大松弛因子, 如图 6.27 (b) 所示。而且松弛控制输入下界的同时, 安全约束性条件可使车辆以更强的制动强度减速, 降低自车接近前车的速度。由图 6.27 (d) 知, 17 秒到 25 秒内, MOCACC 的制动压力大于 LQACC 的制动压力, 自车以更大的减速度制动, 避免了追尾碰撞事故的发生。




图 6.27 前车紧急制动工况

6.3.3 前车切出工况

图 6.28 是前车切出工况 (工况 4) 的实验结果。图中, (a) 是车距, (b) 是车速, (c) 是期望加速度, (d) 是节气门开度, (e) 是瞬时油耗, (f) 是发动机转速。图例的含义同工况 1。

由图 6.28 (c) 知, MOCACC 因具有纵向乘坐舒适性标准的约束, 期望加

速度量不仅变化舒缓，而且最大值有界。如图 6.28 (d) 和 (f)，前车切出 3 秒内（约从 13 秒到 16 秒），与 LQACC 相比，MOCACC 的节气门开度和发动机转速上升过程略慢，而且最大值也较小。这不仅有利于降低了发动机的瞬时油耗，而且有助于减少发动机及传动系的磨损，延长车辆的使用寿命。而该时间段内，LQACC 因车间距离发生阶跃变化，导致期望加速度突然增大，节气门开度急剧上升，这虽然有利于提高车距和车速的早期收敛速度，但发动机转速的变化幅度较大，容易恶化发动机的混合气燃烧过程，导致燃油消耗量增加。

前车切出 3 秒之后（约 16 秒之后），MOCACC 持续保持略大于 0.5m/s^2 的期望加速度，如图 6.28 (c)。该时间段内，自车保持更长的加速行驶过程，补偿因乘坐舒适性约束造成的跟踪性能降低。图 6.28 (b) 显示 MOCACC 下，自车车速的最大值与 LQACC 近似。图 6.28 (a) 显示 MOCACC 下，车距收敛至平衡点的时间与 LQACC 也基本一致。这说明：前车切出工况中 MOCACC 的跟踪性能与 LQACC 基本一致。

利用瞬时油耗的积分计算车辆的燃油消耗量，如表 6.6。积分时间段为 10s 到 35s。由表易知，前车切出工况中，自车从接近过程开始到跟踪误差收敛结束，MOCACC 比 LQACC 约省油 3.03%。

表 6.6 前车切出工况的油耗

	LQ ACC	MOCACC	省油率
燃油消耗量 (g)	17.0	16.5	3.03%




图 6.28 前车切出工况




图 6.28 前车切出工况

6.3.4 前车正弦加减速工况

前车正弦加减速工况按照加速度水平也分为两种，如表 6.5 的工况 5 和工况 6。实验结果分别如图 6.29 和图 6.30 所示。因为 ACC 启动时刻，前后车速不相同，故两种工况下，ACC 系统均先经过一段瞬态收敛过程（约 0 秒到 25 秒），后进入动态跟车过程（约 25 秒到 60 秒）。

图 6.29 是工况 5 的实验结果。图中，(a) 是实际加速度，(b) 是瞬时油耗，(c) 是相对车速，(d) 是车距误差，(e) 是瞬态收敛阶段的 $\Delta v-d$ 相轨迹，(f) 是动态跟车阶段的 $\Delta v-d$ 相轨迹。图中，点划线是跟车系统的参考轨迹。参考轨迹是以前车工况为输入，包含 MLCF 模型的跟车系统的输出，代表了驾驶员期

望的动态跟车轨迹。(e), (f) 中, Δ 表示相轨迹的起点, \bigcirc 表示相轨迹的终点。

瞬态收敛过程(0 秒到 25 秒)中, 因为前车车速大于后车车速且二者的误差大于相对车速约束的上界, 所以 MOCACC 和 LQACC 均采用增大自车加速度, 减小跟踪误差的控制措施。MOCACC 中, 因纵向乘坐舒适性标准约束车辆加速度, 自车加速度水平低于 LQACC, 如图 6.29 (a)。尽管这有利于降低发动机的燃油消耗量, 但造成: (1) 跟车轨迹偏离驾驶员期望的参考轨迹, 如图 6.29 (e); (2) 跟踪误差的收敛速度相对缓慢, 如图 6.29 (c) 和 (d) (0 秒到 25 秒)。

进入动态跟车阶段(约 25 秒到 60 秒)后, MOCACC 中因实际加速度处于纵向乘坐舒适性标准之内, 故加速度约束解除, 驾驶员跟驰模型的作用显现。MPC 算法通过最小化加速度和参考加速度的误差, 使跟踪误差接近参考轨迹。由图 6.29 (c) 和 (d) 知, 与 LQACC 相比, MOCACC 的相对车速和车距误差更加接近参考轨迹。另外, 动态跟车阶段的 $\Delta v-d$ 相轨迹图 (f) 也证明 MOCACC 的跟车系统轨迹与驾驶员参考轨迹更加接近。这表明: 进入动态跟车阶段后, MOCACC 系统的控制特性与驾驶员动态跟车特性更加接近。

图 6.30 是工况 6 的实验结果。图例与工况 5 一致。它的实验结果与工况 5 基本类似, 不再赘述。

表 6.7 是前车正弦加减速工况的车辆油耗。由表 6.7 易知, 小正弦加减速工况下, MOCACC 比 LQACC 省油约 2.9%; 大正弦加减速工况下, MOCACC 比 LQACC 省油约 8.1%。这表明: 随着前车频繁加减速强度的增加, MOCACC 的省油能力也显著提高。

表 6.7 前车正弦加减速工况的车辆油耗

	LQACC 油耗 (g)	MOCACC 油耗 (g)	省油率
工况 5	39.0	37.9	2.9%
工况 6	50.9	47.1	8.1%




图 6.29 前车小正弦加减速工况




图 6.30 前车大正弦加减速工况

6.4 前车循环工况的实验验证

利用前车循环工况的实验结果,对车辆 MOCACC 系统的燃油经济性和跟踪性能进行综合评价。由前车特定工况的实验结果知,加速度约束对于降低车辆油耗具有重要作用。带控制输入约束的 CLQACC 也具有限制期望加速度的能力,因此与 LQACC 相比,它具有进一步降行车过程油耗的性能。本节以 CLQACC 作为对比系统,可更好地评价本文方法的特点。

6.4.1 城市道路工况

图 6.31 和图 6.32 是城市道路工况中,从 110 秒到 160 秒的实车实验结果。图 6.31 中,(a) 是加速度,(b) 是松弛因子,(c) 是车速,(d) 是车距,(e) 是相对车速,(f) 是车距误差。图 6.32 中,(a) 是节气门开度,(b) 是制动压力,(c) 是变速器挡位,(d) 是瞬时油耗。图中,粗实线代表 MOCACC,细实线代表 CLQACC,虚线代表前车状态或期望车距。

由图 6.31 (a) 知,因 MOCACC 和 CLQACC 系统均具有控制输入约束,因此,它们的加速度均处于纵向乘坐舒适性标准之内,但是 MOCACC 的加速度更加准确地跟踪前车加速度,其绝对值也低于 CLQACC。由图 6.31 (c)、(d)、(e) 和 (f) 知,MOCACC 中,车速和车距的跟踪精度更高,相对车速和车距误差也小于 CLQACC。这说明:MOCACC 的跟踪性能优于 CLQACC。

由图 6.32 (a) 知,MOCACC 在驱动工况中采用较小的节气门开度,与 CLQACC 相比,可减少发动机的瞬时油耗。由图 6.32 (b) 知,与 CLQACC 相比,MOCACC 在制动工况中采用较小的制动强度,减少了制动过程的能量损耗。而且,由挡位信号知,MOCACC 具有加速阶段提前升挡,减速阶段延迟降挡的特性,这有利于增大发动机的负荷率,降低燃油消耗率。图 6.32 (d) 的瞬时油耗曲线证明了上述分析。多数时间段内,MOCACC 的瞬时油耗低于 CLQACC。这说明,前者的燃油经济性优于后者。




图 6.31 城市道路工况的实验结果 (第一部分)




图 6.32 城市道路工况的实验结果（第二部分）

6.4.2 高速公路工况

图 6.33 和图 6.34 是高速公路工况中,从 330 秒到 380 秒的实验数据。图 6.33 中, (a) 是加速度, (b) 是松弛因子, (c) 是车速, (d) 是车距, (e) 是相对车速, (f) 是车距误差。图 6.34 中, (a) 是节气门开度, (b) 是制动压力, (c) 是变速器挡位, (d) 是瞬时油耗。图中, 粗实线代表 MOCACC, 细实线代表 CLQACC, 虚线代表前车状态或期望车距。




图 6.33 高速公路工况的实验结果 (第一部分)




图 6.34 高速公路工况的实验结果 (第二部分)

由图 6.33 (c) 的虚线知, 该时间段内前车运动近似速度阶跃工况。MOCACC 因具有前车加速度预测器, 当前车加速度阶跃时, 它可有效预测前车的加速状态。对性能指标进行优化的结果是使车辆尽快提升节气门开度 (如图 6.34 (a)), 增大实际加速度, 如图 6.33 (a) 的 340~342 秒处所示。由图 6.33 (c) 和 (d) 知, 因车辆加速度的快速提升, 从 340 秒~342 秒, MOCACC 的车速也提升较快, 使车间距离不会快速扩大。因此, 342 秒之后, 尽管 MOCACC 的最大加速度量较小, 但相对车速仍小于 CLQACC, 车距误差也没有明显变差。

另外, 从图 6.34 (d) 知, 与节气门开度的变化趋势一致, MOCACC 的瞬时油耗也具有提升快速, 但最大值小于 CLQACC 的特点。

6.4.3 燃油经济性和跟踪性能对比

为综合评价车辆 MOCACC 系统的功能,定义燃油经济性和跟踪性能的评价指标。以百公里油耗 (FCH, Fuel Consumption per Hundred km) 为燃油经济性的评价指标为:

$$FCH \triangleq 100 \frac{L_Q}{s} \quad (6-7)$$

$$L_Q = \rho_g \cdot \sum_{i=1}^N Q_s(i) \cdot T_s, \quad s = \sum_{i=1}^N v_f(i) \cdot T_s$$

式 (6-7) 中, ρ_g 为汽油密度, 为 $0.725 \times 10^{-3} \text{ L/g}$, s 为实验过程的行车距离, 单位为 km, N 为实验过程的数据点数, Q_s 为瞬时油耗, 单位为 g/s。参照第 3 章驾驶员期望跟踪误差特性的二维分布模型, 定义跟踪性能的评价指标 TEI (Tracking Error Index), 称为跟踪性能指标:

$$TEI \triangleq \frac{1}{N} \sum_{i=1}^N \left(\left| \Delta v(i) \cdot SVE \right| + \left| \frac{\Delta d(i) \cdot SDE}{K_{TE}} \right| \right) \quad (6-8)$$

式 (6-8) 中, Δv 为相对车速, Δd 为车距误差, SVD/SDE 为驾驶员对跟踪误差的敏感度模型, K_{TE} 为二维分布模型的系数。

以 ACC 前车循环工况的实验结果为数据, 利用式 (6-7) 和式 (6-8) 分别计算 MOCACC 系统和 CLQACC 系统控制过程的燃油消耗、行车距离、百公里油耗和跟踪性能指标, 如表 6.8 和表 6.9 所示。表中, 百分比是指相对于 CLQACC 系统, MOCACC 系统减少百公里油耗 (或跟踪性能指标) 的百分比。

表 6.8 城市道路工况的性能对比

评价量	单位	MOCACC	CLQACC	百分比
整车油耗	L	0.77	0.81	--
行车距离	km	7.4	7.4	--
百公里油耗	L/100km	10.4	11.0	5.3 %
跟踪性能指标	--	1.33	1.56	14.9 %

表 6.9 高速公路工况的性能对比

评价量	单位	MOCACC	CLQ ACC	百分比
整车油耗	L	0.81	0.83	--
行车距离	km	10.3	10.3	--
百公里油耗	L/100km	7.8	8.1	2.5 %
跟踪性能指标	--	0.31	0.33	1.8 %

图 6.35 是两种 ACC 系统的百公里油耗比较图，图 6.36 是两种 ACC 系统的跟踪性能指标比较图。




图 6.35 前车循环工况的百公里油耗




图 6.36 前车循环工况的跟踪性能指标

由图表数据易知，城市道路工况中，与 CLQACC 相比，MOCACC 的百公

里油耗降低 5.3%，跟踪误差指标约降低 14.9%。高速公路工况中，与 CLQACC 相比，MOCACC 的百公里油耗约降低 2.5%，跟踪误差指标约降低 1.8%。这说明：本文设计的 MOCACC 系统可同时提高车辆的跟踪性能和燃油经济性。

MOCACC 系统和 CLQACC 系统中，上位控制器的代价函数是基本相同的，但实验结果表明：前者的燃油消耗和跟踪误差均低于后者。从 MPC 和 LQ 方法的基本原理上看，导致这一结果的原因有两点：

第一、应用 LQ 方法设计上位控制器的一个默认前提是外部干扰为零。对于跟车系统来说，外部干扰是前车加速度，行车过程中不恒为零。因此，处于前车加减速工况时，LQ 控制系统对式 (6-4) 的性能指标 J 不具备最优性。而 MPC 方法中，外部干扰预测器会估计预测时域的前车加速度量，这相当于 MPC 已知未来一段时间的外部干扰量。当优化求解控制量时，它作为已知量代入预测时域的性能指标，闭环系统的最优性自然得以提高。因此，当前车加减速干扰不为零时，MPC 方法的最优性优于 LQ 方法。而且，比较城市道路工况和高速公路工况的结果知（或者节 6.3.4 的小正弦加减速工况和大正弦加减速工况），前车加速度干扰越大，MPC 方法相对于 LQ 方法的优化效果越显著。

第二、MPC 具有优化约束非线性对象的能力，而 CLQ 对带控制输入约束的性能指标不具备最优性。对于式 (6-4) 的性能指标 J ，LQ 算法是最优，经控制输入约束后，LQ 算法变为 CLQ 算法。带约束的 CLQ 算法对性能指标 J 不具备最优性。而 MPC 算法对带 I/O 约束的代价函数具有最优性，因此相同控制输入约束条件下，它对代价函数的最小化程度优于 CLQ 方法。

6.5 实验结果的补充说明

值得注意的是，本文使用的对比控制系统已经考虑燃油经济性的问题，其代价函数中，跟踪误差的的权系数远小于加速度的权系数。而对于传统 ACC 系统，文献[27]、[28]、[132]和[133]给出的权系数为：

$$\mathbf{w}_y = \begin{bmatrix} 1 & 0 & 1.2 \\ 0 & 4 & 0 \\ 1.2 & 0 & 1.44 \end{bmatrix}, \mathbf{w}_u = 5 \quad (6-9)$$

比较式 (6-9) 和本文使用的权系数，易知本文采用的对比控制系统已具有

低油耗的优势，而车辆 MOCACC 系统在此基础上进一步提高了车辆的燃油经济性，它在降低车辆油耗方面的优越性显而易见。而且，本文实验对象为乘用车，对于多目标协调式自适应巡航控制功能更具现实意义的商用车辆，尤其是重型商用车辆，车辆 MOCACC 系统的燃油消耗低、跟踪性能好等优点会更加显著。

6.6 本章小结

本章以 LQACC 和 CLQACC 为对比控制系统，在四类前车特定工况和两组前车循环工况下，对车辆 MOCACC 系统的性能进行实验验证。实验结果及分析表明：

车辆 MOCACC 系统中，自车加速度符合纵向乘坐舒适性标准，满足驾驶员乘坐舒适性要求；车间距离大于安全车距，可避免追尾碰撞事故的发生。当跟踪误差超过驾驶员期望跟踪误差范围时，松弛因子与 I/O 软约束共同作用可增强加速度水平，加快跟踪误差的收敛，避免前车切入或追尾危险；当跟踪误差处于驾驶员期望跟踪误差范围之内，因驾驶员参考模型的存在，跟车系统的状态轨迹与驾驶员参考轨迹更加接近，使自适应巡航控制特性与驾驶员动态跟车特性相符合。跟车过程中，车辆 MOCACC 系统可使自车尽量缓加速度、轻制动、发动机工作于经济区，提高车辆燃油经济性的同时，且不降低跟踪性能。

第7章 结 论

为满足新一代 ACC 系统中自动跟车行驶、低燃油消耗和符合驾驶员特性三类功能要求,研究了基于模型预测控制理论的车辆多目标协调式自适应巡航控制方法,并完成实车实验验证。通过理论分析和实车实验,得到以下几点结论:

(1) 所提出的车辆 MOCACC 体系结构,以性能指标反映跟踪性能、燃油经济性和驾驶员感受的矛盾性,通过在线优化求解跟车系统的最优控制量,是解决自适应巡航过程中多目标协调控制问题的有效方案之一。

(2) 驾驶员对跟踪误差的敏感度模型可有效描述驾驶员控制增益随车速时变的特性。基于驾驶敏感度的跟驰模型具有模型精度高、结构准线性、参数物理含义明确等特点,适用于自适应巡航控制器的设计过程。

(3) 基于假设检验理论的模型比较验证方法证明了本文提出的跟驰模型优于现有的线性跟驰模型。该方法可以消除驾驶随机性对跟驰模型性能评价的影响,为跟驰模型的验证提供了一种相对客观的评价手段。

(4) 跟车系统动力学特性建模中,逆模型法具有补偿车辆纵向非线性的能力,T-S 模糊化法可避免多模型离散化法带来的控制器切换问题。

(5) 以二次型代价函数和线性不等式约束为框架的 MOCACC 性能指标,满足跟踪性能目标、燃油经济性目标和驾驶员感受目标的数学量化要求,且有助于降低控制算法在线优化的计算复杂度。

(6) 跟车模型失配是车辆 MOCACC 系统低鲁棒性的主要原因。利用反馈校正法建立的鲁棒跟车预测模型,可补偿因模型失配造成的状态预测误差,是改善车辆 MOCACC 系统鲁棒性的有效措施。

(7) 跟车系统的 I/O 硬约束是导致非可解问题的主要原因。基于约束管理法设计 I/O 软约束具有自动放宽约束范围的能力,扩展了预测优化问题的可行域,有效地避免了最优控制量的非可解问题。

(8) 基于规模缩减法的快速模型预测控制算法不受被控对象和性能指标的类型限制,提高在线优化计算效率的同时,几乎不影响闭环控制的最优性。

(9) 实车实验表明:本文设计的车辆 MOCACC 系统可同时提升跟踪性能和燃油经济性,且符合多类驾驶员跟车特性。

本研究的主要创新之处在于:

(1) 建立了基于模型预测控制理论的车辆 MOCACC 体系结构。该体系结构下,新一代 ACC 系统具有优化跟踪误差、燃油消耗和驾驶员特性误差的功能,且符合驾驶员期望跟踪误差特性、纵向乘坐舒适性标准,满足跟车安全性条件,达到协调跟踪性能、燃油经济性和驾驶员感受三个目标的目的。

(2) 提出了基于驾驶敏感度的驾驶员跟驰模型和相应的模型性能验证方法。所提出的跟驰模型具有精度高、结构近似线性、参数物理意义明确等优点,适用于自适应巡航控制器的设计过程。基于假设检验的模型比较验证方法消除了驾驶随机性对跟驰模型性能评价的影响,为驾驶员跟驰模型提供了一种相对客观的评价手段。

(3) 建立了适用于车辆对象的模型预测控制理论实用化问题处理方法。采用反馈校正法建立鲁棒跟车预测模型,增强了车辆 MOCACC 系统对模型失配的鲁棒性;利用约束管理法松弛跟车系统的输入输出硬约束,避免了最优控制量的非可解问题;提出预测优化问题的规模缩减法,建立一种模型预测控制快速算法,提高在线优化计算效率的同时基本不影响闭环控制的最优性。

参考文献

- [1] Cai H, Xie S. Estimation of vehicular emission inventories in China from 1980 to 2005. *Atmospheric Environment*, 2007, 41(39): 8963-8979.
- [2] Romm J. The car and fuel of the future. *Energy Policy*, 2006, 34(7): 2609-2614.
- [3] 李开兵, 李素艳, 钱红波. 我国道路交通安全改善策略研究. *交通科技*, 2007, 221: 65-67.
- [4] Huh K, Seo C, et al.. An experimental investigation of a CW/CA system for automobile using hardware in the loop simulation. *Proc. of the American Control Conf.*, San Diego, USA, 1999:724-728.
- [5] Godbole D, Kourjanskaia N, et al. Breaking the highway capacity barrier: adaptive cruise control-based concept. *Transportation Research Record*, 1999, No. 1679: 148-157.
- [6] Wang Y, Bin Y, Li K. Longitudinal acceleration tracking control of low speed heavy-duty vehicles. *Tsinghua Science and Technology*, 2008, 13(5): 636-643.
- [7] Zhang J, Ioannou P. Longitudinal control of heavy trucks in mixed traffic: Environmental and fuel economy considerations. *IEEE Transactions on Intelligent Transportation Systems*, 2006, 7(1): 92-104.
- [8] Zheng P, McDonald M. Manual vs. adaptive cruise control-Can driver's expectation be matched. *Transportation Research Part C: Emerging Technologies*, 2005, 13(5-6): 421-431.
- [9] Marsden G, McDonald M, Brackstone M. Towards an understanding of adaptive cruise control. *Transportation Research Part C: Emerging Technologies*, 2001, 9(1): 33-51.
- [10] Tai M. Advanced Vehicle Control of Heavy Vehicles for Automated Highway Systems [博士学位论文]. Berkeley: University of California at Berkeley, 2001.
- [11] 大前 学. プラトーン走行の高度化を実現するための制御システムに関する研究 [博士学位论文]. 东京:东京大学, 1999.
- [12] Fritz A, Schiehlen W. Nonlinear ACC in simulation and measurement. *Vehicle System Dynamics*, 2001, 36(23):159-177.
- [13] Latteman F, Neiss K, et al. The predictive cruise control- A system to reduce fuel consumption of heavy duty trucks. *SAE Transactions*, 2004, 113(2): 139-146.
- [14] Huo H, Li J. Cruise control based on gain scheduling PI diesel engine speed controller. *Proc. of the IEEE International Vehicle Electronics Conf.*, Changchun, China, 1999: 22-25.
- [15] 王红岩, 秦大同. 无级变速汽车速度巡航模糊控制器的研究. *汽车工程*, 22(4), 2000: 230-235.
- [16] Hellstrom E, Ivarsson M, et al. Look-ahead control for heavy trucks to minimize trip time and fuel consumption. *Control Engineering Practice*, 17(2), 2008: 245-254.

-
- [17] Tsugawa S. An overview on energy conservation in automobile traffic and transportation with ITS. Proc. of the IEEE International Vehicle Electronics Conf., Tottori, Japan, 2001: 137-142.
- [18] Bose A, Ioannou P. Analysis of traffic flow with mixed manual and semiautomated vehicles. IEEE Transactions on intelligent transportation systems, 4(4), 2003: 173-188.
- [19] Petros A. Ioannou P, et al. Evaluation of ACC vehicles in mixed traffic: Lane change effects and sensitivity analysis. IEEE Transactions on Intelligent Transportation Systems, 6(1), 2005: 79-89.
- [20] 王红岩, 秦大同, 舒红. 无级变速汽车自动驾驶系统模糊控制策略. 中国公路学报, 14(1), 2001: 109-204.
- [21] Ino J, Ishizu T, Sudou H. Adaptive cruise control system using CVT gear ratio control. SAE Transactions, 2001, 110(7): 675-680.
- [22] Li S, Bin Y, Li K. A control strategy of ACC system considering fuel consumption. Proc. of 2006 Advanced Vehicle Engineering Control conf., Taipei, China, 2006: 851-855.
- [23] Zhang J, Ioannou P. Longitudinal control of heavy trucks: Environmental and fuel economy considerations. Proc. of 2004 IEEE Intelligent Transportation Systems Conf., Washington D.C., USA, 2004: 761-766.
- [24] Jonsson J. Fuel optimized predictive following in low speed conditions [Thesis]. Linköping: Linköping University, 2003.
- [25] Jonsson J. Fuel optimized predictive following in low speed conditions. IFAC Symposium on Advances in Automotive Control, Salerno, Italy, 2004.
- [26] Yamamura Y, Tabe M, et al. Development of an adaptive cruise control system with Stop and Go capability. SAE transactions, 110(7), 2001: 413-419.
- [27] Yi. K, Han D. A vehicle cruise control design based on human drivers driving pattern. Proc. of 9th World Multi-Conf. on Systemics, Cybernetics and Informatics, Florida, USA, 2005.
- [28] Yi K, Moon I. A driver-adaptive stop-and-go cruise control strategy. Proc. of the 2004 IEEE Intl. Conf. on Networking, Sensing and Control, Taipei, China, 2004: 601-606.
- [29] Simosson S. Car-following as a tool in road traffic simulation. Proc. of IEEE-IEE Vehicle Navigation & Information Systems Conference, Ottawa, Canada, 1993: 150-153.
- [30] Bengtsson J. Adaptive cruise control and driver modeling [Thesis]. Lund: Lund Institute of technology, 2001.
- [31] Brackstone M, Madonald M. Car-following: a historical review. Transportation Research Part F: Traffic Psychology and Behaviour, 1999, 2(4): 181-196.
- [32] Suzuki H, Ranjitkar P. An extended car-following model combined with a driver model. Journal of the Eastern Asia Society for Transportation Studies, 2005, Vol. 6: 1545-1556.

- [33] Minderhoud M, Zuurbier F. Empirical data on driving behavior in Stop and Go traffic. Proc. of 2004 IEEE Intelligent Vehicle Symposium, Parma, Italy, 2004: 676-681.
- [34] Chen L, Ulsoy A. Driver model uncertainty. Proc. of the 1999 American Control Conf., San Diego, USA, 1999: 714-718.
- [35] Shiga T, Wakita T. Estimation of driver's characteristics using car following data. Proc. of 10th World Congress and Exhibition on ITS and Services, Madrid, Spain, 2003.
- [36] Choi S, Hedrick J. Vehicle longitudinal control using an adaptive observer for automated highway systems. Proc. of the 1995 American Control Conference, Washington, USA, 1995: 3106-3110.
- [37] Ferrara A, Pisu P. Minimum sensor second-order sliding mode longitudinal control of passenger vehicles. IEEE Transactions on Intelligent Transportation Systems, 2004, 5(1): 20-32.
- [38] Canale M, Malan S. Tuning of Stop and Go driving control strategies using driver behavior analysis. Proc. of IEEE 2002 Intelligent Vehicle Symposium, Versailles, France, 2002: 407-412.
- [39] Persson M, Botling F, et al. Stop and Go Controller for Adaptive Cruise Control. Proc. of the 1999 IEEE Intl. Conf. on Control Applications, Hawaii, USA, 1999: 1692-1697.
- [40] Higashimata A, Adachi K, et al. Design of a headway distance control system for ACC. JSAE Review 2001, 22(1): 15-22.
- [41] Yamamura Y, Seto Y, et al. An ACC design method for achieving both string stability and ride comfort. Journal of System Design and Dynamics, 2008, 2(4): 979-990.
- [42] 褚健,潘红华,苏宏业. 预测控制技术的现状和展望. 机电工程, 5(1),1999: 3-7.
- [43] 李少远. 全局工况系统预测控制及其应用. 北京:科学出版社, 2008.
- [44] Dorado F, Bordons C. Constrained nonlinear predictive control using volterra models. Proc. of 10th IEEE Conf. on Emerging Technologies and Factory Automation, Catania, Italy, 2005: 1007-1012.
- [45] Zhu X, Seborg D. Nonlinear predictive control based on Hammerstein models. Control theory and applications, 1994, 11(5): 564-572.
- [46] Rawlings J. Tutorial: Model predictive control technology. Proc. of the 1999 American Control Conf., California, USA, 1999: 662-676.
- [47] Camacho E, Bordons C. Model Predictive Control in the Process Industry. London: Springer-Verlag London Limited, 1995.
- [48] 苏宏业,李林欢,褚健. 预测控制的新进展. 机电工程, 2001, 18(5): 4-8.
- [49] 舒迪前.预测控制系统及其应用. 北京:机械工业出版社, 1996.

- [50] Garcia C. Quadratic dynamic matrix control of nonlinear process. Proc. of AICHE Annual Meeting, San Francisco, USA, 1984.
- [51] 席裕庚. 预测控制. 北京:国防工业出版社, 1993.
- [52] Seoterboek R. Predictive Control: A Unified Approach. London: Prentice Hall International (UK) Limited, 1992.
- [53] 钱积新, 赵均, 徐祖华. 预测控制. 北京:化学工业出版社, 2007.
- [54] 王景润. 约束滚动时域预测控制鲁棒性问题研究[硕士学位论文]. 哈尔滨:哈尔滨理工大学, 2004.
- [55] 刘斌. 非线性系统建模及预测控制若干问题研究[博士学位论文]. 杭州:浙江大学, 2004.
- [56] Rawlings J, Muske K. Stability of constrained receding horizon control. IEEE Transactions on Automatic Control, 1993, AC-38(10): 1512-1516.
- [57] Scokaert P, Mayne D. Stabilizing properties of constrained predictive control. IEE Proc. on Control Theory and Applications, 1994, 141(5): 295-304.
- [58] 孙俊. 非线性模型预测控制理论及应用研究[博士学位论文]. 西安:西北工业大学, 2002.
- [59] Garca-Nieto S, Martnez N, et al. Nonlinear predictive control based on local model networks for air management in diesel engines. Control Engineering Practice, 2008, 16(12): 1399-1413.
- [60] Ferreau H, Ortner P, et al. Predictive control of a real-world Diesel engine using an extended online active set strategy. Annual Reviews in Control, 2007, 31(2): 293-301.
- [61] Saerens B, Vandersteen J, et al. Minimization of the fuel consumption of a gasoline engine using dynamic optimization. Applied Energy, 2009, Vol. 7. <http://www.elsevier.com/locate/apenergy>.
- [62] Yoon Y, Shin S, et al. Model-predictive active steering and obstacle avoidance for autonomous ground vehicles. Control Engineering Practice, 2009, Vol. 15. <http://www.elsevier.com/locate/conengprac>.
- [63] Anwar S. Generalized predictive control of yaw dynamics of a hybrid brake-by-wire equipped vehicle. Mechatronics, 2005, 15(9): 1089-1108.
- [64] Baskar L D, Schutter D B, Hellendoorn H. Model-based predictive traffic control for intelligent vehicles: dynamic speed limits and dynamic lane allocation. Proc. of 2008 IEEE IV Symp., Eindhoven, The Netherlands, 2008.
- [65] Coen T, Anthonis J, et al. Cruise control using model predictive control with constraints. Computers and Electronics in Agriculture, 2008, 63(2): 227-236.
- [66] Nouveliere L, Menhour L, et al. Infrastructure based fuel consumption optimization of a vehicle. Proc. of the 9th Intl. Symp. on Advanced Vehicle Control, Kobe, Japan, 2008: 300-305.

-
- [67] Bageshwar L, Garrard L, Rajamani R. Model predictive control of transitional maneuvers for adaptive cruise control vehicles. *IEEE Transactions on Vehicular Technology*, 2004, 53(5): 1573-1585.
- [68] Corona D, Lazar M, Schutter D, Heemels M. A hybrid MPC approach to the design of a Smart adaptive cruise controller. *Proc. of the 2006 IEEE Intl. Conf. on Control Applications*, Munich, Germany, 2006: 231-236.
- [69] Corona D, Schutter D. Adaptive cruise controller design: A comparative assessment for PWA Systems. *Preprints of the 2nd IFAC Conf. on Analysis and Design of Hybrid Systems*, Alghero, Italy, 2006: 253-257.
- [70] Corona D, Necoara I, et al. Robust hybrid MPC applied to the design of an adaptive cruise controller for a road vehicle. *Proc. of the 45th IEEE Conf. on Decision and Control*, San Diego, California, 2006: 1721-1726.
- [71] Corona D, Schutter D. Comparison of a linear and a hybrid adaptive cruise controller for a SMART. *Proc. of the 46th IEEE Conf. on Decision and Control*, New Orleans, USA, 2007: 4779-4784.
- [72] Corona D, Schutter D. Adaptive cruise control for a SMART car: A comparison benchmark for MPC-PWA control methods. *IEEE Transactions on Control Systems Technology*, 2008, 16(2): 365-372.
- [73] Naus G, Ploeg J, et al. Explicit MPC design and performance-based tuning of an adaptive cruise control Stop-&-Go. *Proc. of 2008 IEEE IV Symp.*, Eindhoven, The Netherlands, 2008: 434-439.
- [74] 张聚, 仇耀鑫. 约束线性二次优化控制的多参数规划求解. *清华大学学报:自然科学版*, 2007, 47(S2): 1936-1940.
- [75] Kothare M, Nevistic V, Morari M. Robust constrained model predictive control for nonlinear systems: A comparative study. *Proc. of the 34th Conf. on Decision & Control*, New Orleans, USA, 1995: 2884-2885.
- [76] Kothare M, Balakrishnan V, Morari M. Robust constrained model predictive control using linear matrix inequalities. *Automatica*, 1996, 32(10): 1361-1379.
- [77] Richalet J, Rault A, et al. Model predictive heuristic control: applications of industrial processes. *Automatic*, 1978, 14(5): 413-428.
- [78] Lee J, Yu Z. Worst-case formulations of model predictive control for systems with bounded parameters. *Automatic*, 1997, 33(5): 763-781.
- [79] Scokaert M, Mayne Q. Min-max feedback model predictive control for constrained linear systems. *IEEE Transactions on Automatic Control*, 1998, 43(8): 1136-1142.
- [80] Casavola A, Giannelli M, Mosca E. Min-max predictive control strategies for input-saturated polytopic uncertain systems. *Automatica*, 2000, 36(36): 125-133.

- [81] 盛云龙, 苏宏叶, 褚健. 一种基于闭环优化的新型鲁棒预测控制方法. 浙江大学学报: 理学版, 2003, 30(1): 50-55.
- [82] Corradini M, Orlando G. A VSC algorithm based on generalized predictive control. *Automatica*, 1997, 33(5): 927-932.
- [83] 周建锁, 刘志远, 裴润. 一种非线性连续预测边界控制方案. 电机与控制学报, 2000, 4(4): 227-238.
- [84] 胡剑波, 陈新海. 反馈线性化系统的非线性预测滑模控制. 航空学报, 1997, 18(5): 579-582.
- [85] 宋立忠, 陈少昌, 姚琼荟. 多输入离散时间系统滑模预测控制. 电机与控制学报, 2005, 19(12): 128-132.
- [86] 宋立忠, 陈少昌, 姚琼荟. 滑模预测离散变结构控制. 控制理论与应用, 2004, 21(5): 826-827.
- [87] Zheng A. Robust stability analysis of constrained model predictive control. Proc. of the 1998 American Control Conf., Philadelphia, USA, 1998: 786-790.
- [88] Nicolao D, Magni L, Scattolini R. On the robustness of receding horizon control with terminal constraints. *IEEE Transactions on Automatic Control*, 1996, 41(3): 451-453.
- [89] Kwon W, Pearson A. A modified quadratic cost function problem and feedback stabilization of a linear system. *IEEE Transactions on Automatic Control*, 1977, AC-22(5): 838-842.
- [90] Mayne D, Michalska H. Receding horizon control of nonlinear systems. *IEEE Transaction on Automatic Control*, 1990, 35(5): 814-824.
- [91] Lu H, Arkun Y. A Scheduling quasi-min-max model predictive control algorithm for nonlinear systems. *Journal of Process Control*, 2002, 12(5): 589-604.
- [92] Ding C, Xi G, Li Y. A synthesis approach of on-line constrained robust model predictive control. *Automatica*, 2004, 40(1): 163-167.
- [93] Wan Y, Kothare V. Efficient robust constrained model predictive control with time-varying terminal constraint set. *Systems and Control Letters*, 2003, 48(5): 375-383.
- [94] 李德伟, 席裕庚. 一种基于衰减集结的鲁棒预测控制器. 自动化学报, 2008, 33(1): 48-54.
- [95] 郑鹏远, 席裕庚, 李德伟. 一种改进的鲁棒约束预测控制器的综合设计方法. 控制与决策, 2008, 23(9): 1041-1044.
- [96] Zheng A. A computationally efficient nonlinear MPC algorithm. Proc. of the American Control Conference, NM, USA, 1997: 1623-1627.
- [97] Mutha R, Cluett W, Penlidis A. Nonlinear model-based predictive control of control nonaffine system, *Automatica*, 1997, 33(5): 907-913.

-
- [98] Kurtz M, Henson. Input-output linearizing control of constrained nonlinear processes, *Journal of Process Control*, 1997, 7(1): 3-17.
- [99] Slupphaug O, Foss B. Bilinear matrix inequalities and robust stability of nonlinear multi-model MPC. *Proc. of American Control Conf.*, Philadelphia, USA, 1998: 1680-1694.
- [100] Biegler L. Advances in nonlinear programming concepts for process control. *Journal of Process Control*, 1998, 8(5): 301-311.
- [101] Borrelli F. *Constrained Optimal Control of Linear and Hybrid Systems*. Berlin: Springer, 2003.
- [102] Bemporad A, Morari M, et al. The explicit linear quadratic regulator for constrained systems. *Automatica*, 2002, 38 (1): 3- 20.
- [103] Borrelli F, Bemporad A, Morari M. A geometric algorithm for multi-parametric linear programming. *Journal of Optimization Theory and Applications*, 2003, 118(3): 515-540.
- [104] 陈 薇. 非线性预测控制快速算法的研究与应用[博士学位论文]. 合肥:中国科技大学, 2007.
- [105] 杜晓宁, 席裕庚. 预测控制优化变量的集结策略. *控制与决策*, 2002, 17(5): 563-566.
- [106] 罗国娟, 吴 刚. 阶梯式模型预测控制中控制权重的下限值研究. *信息与控制*, 2006, 35(3): 290-293.
- [107] Magni L, Scattolini R. Control design for nonlinear systems: Trading robustness and performance with the model predictive control approach. *IEE Proc. on Control Theory and Applications*, 2005, 152 (3): 333~339.
- [108] Imsland L, Bar N, Foss A. More efficient p redictive control. *Automatica*, 2005, 41 (8) : 1395~1403.
- [109] 李德伟, 席裕庚, 秦辉. 预测控制等效集结优化策略的研究. *自动化学报*, 2007, 33(3): 302-308.
- [110] Gilliespie T. *Fundamentals of vehicle dynamics*. Warrendale: Society of Automotive Engineers Inc., 1992.
- [111] 胡广书. *数字信号处理*. 北京:清华大学出版社, 2003.
- [112] Ma X, Jansson M. Model estimation for car-following dynamics based on adaptive filtering approach. *Proc. of the 2007 IEEE Intelligent Transportation Systems Conf.*, Seattle, USA, 2007: 821-829.
- [113] Gerdes J, Hedrick J. Vehicle speed and spacing control via coordinated throttle and braking actuation. *Control Eng. Practice*, 1997, 5(11): 1607-1614.
- [114] Yanakiev D, Kanellakopoulos I. Longitudinal control of heavy-duty vehicles for automated highway systems. *Proc. of the American Control Conference*, Seals, Washington, 1995: 3096-3100.

- [115] Yanakiev D, Kanellakopoulos I. Nonlinear spacing policies for automated heavy-duty vehicles. *IEEE Transactions on Vehicular Technology*, 1998, 47(4): 1365-1377.
- [116] Piao J, McDonald M. Low speed car following behaviour from floating vehicle data. *Proc. of IEEE Intelligent Vehicles Symp.*, 2003, Columbus, USA: 462-467.
- [117] 方崇智, 萧德云. 过程辨识. 北京:清华大学出版社, 1988.
- [118] 薛毅. 最优化原理与方法. 北京:北京工业大学出版社, 2001.
- [119] 盛聚, 谢式千, 潘承毅 等. 概率论与数理统计:第三版. 北京:高等教育出版社, 2001.
- [120] 刘次华, 万建平. 概率论与数理统计. 北京:高等教育出版社, 1999.
- [121] Wang W. Modeling scheme for vehicle longitudinal control. *Proc. of the 31th conf. on decision and control*, Tucson, Arizona, U.S.A., 1992: 549-554.
- [122] Ohtsuka H, Vlacic L. Stop and Go vehicle longitudinal model. *Proc. of the IEEE 5th Intl. Conf. on ITS*, Singapore, 2002: 206-209.
- [123] 侯德藻, 高峰, 李克强, 等. 应用于汽车主动避撞系统的车辆纵向动力学模型. *清华大学学报:自然科学版*, 2004, 44(2): 258-261.
- [124] Cho D, Hedrick J. Automotive powertrain modeling for control. *Journal of Dynamics, Measurement and Control*, 1989, 111: 568-576.
- [125] Chevalier A, Muller M, Hendricks E. On the validity of mean value engine models during transient operation. *SAE Transactions*, 2000, 109(3): 1571-1592.
- [126] Chaing W, Zhu L, Patankar R. Mean value engine modeling and validation for a 4-stroke single cylinder gasoline engine. *Trends in Applied Sciences Research*, 2007, 2(2): 124-131.
- [127] Cappiello A, Chabini I, et al. A statistical model of vehicle emissions and fuel consumption. *Proc. of IEEE 5th Intl. Conf. on ITS*, Singapore, 2002: 801-809.
- [128] 黎 苏. 汽车发动机动态过程及其控制. 北京:人民交通出版社, 2001.
- [129] 余志生. 汽车理论. 北京:机械工业出版社, 2004.
- [130] Xu Z, Ioannou P. Adaptive throttle control for speed tracking. *Vehicle Systems Dynamics*, 1994, 23(4): 293-306.
- [131] 宾洋, 李克强, 王建强, 连小珉. 低速行驶重型车辆的动力学系统建模与非线性控制. *自动化学报*, 2007, 33(3): 265-272.
- [132] Yi K, Moon I, Kwon Y. A vehicle-to-vehicle distance control algorithm for stop-and-go cruise control. *Proc. of 2001 IEEE Intelligent Transportation Systems*, Oakland, USA, 2001: 478-482.
- [133] Yi K, Kwon Y. Vehicle-to-vehicle distance and speed control using an electronic-vacuum booster. *JSAE Review*, 2001, Vol.22: 403-412.
- [134] Rajamani R. *Vehicle dynamics and control*. New York: Springer US, 2005.

- [135] Lu X, Hedrick J. Longitudinal control design and experiment for heavy-duty trucks. Proc. of the 2003 American Control Conf., Denver, USA, 2003: 36-41.
- [136] 高 锋. 汽车纵向运动多模型分层切换控制[博士学位论文]. 北京:清华大学汽车工程系, 2007.
- [137] 侯德藻. 汽车纵向主动避撞系统的研究[博士学位论文]. 北京:清华大学汽车工程系, 2004.
- [138] 吴麟 等. 现代控制理论. 北京:高等教育出版社, 1990 .
- [139] Rantzer A, Johansson M. Piecewise linear quadratic optimal control. IEEE Transactions on Automatic Control, 2000, 45(4): 629-637.
- [140] Schutter D, Boom V. MPC for continuous piecewise-affine systems. Systems & Control Letters, 2004, 2004, 52(3-4): 179-192.
- [141] 曾 锋, 高东杰, 李秀改. 一类有约束的分段线性系统双模预测控制. 控制与决策, 2006, 21(5): 597-601.
- [142] Judith H, Sanjeev K, Peter R. Controller switching based on output prediction errors. IEEE Transactions on Automatic Control, 1996, 41(10): 1413-1431.
- [143] 邢宗义, 胡维礼, 贾利民. 基于 T-S 模型的模糊预测控制研究. 控制与决策, 2005, 20(5): 495-504.
- [144] Hagan M, Fancher P, et al. An instrumentation system for gathering information pertinent to the performance of an adaptive cruise control system. Proc. of IEEE Conf. on ITS, Boston, USA, 1997: 858-863.
- [145] 张磊. 基于驾驶员行为特性的车辆前撞报警系统[硕士学位论文]. 北京:清华大学, 2006.
- [146] Garcia C, Prett D, et al. Model predictive control: Theory and practice-A Survey. Automatica, 1989, 25(3): 335-348.
- [147] Maciejowski J. Predictive control with constraints. London: Pearson Education, 2002.
- [148] Fletcher R. Practical methods of optimization. Chichester: John Wiley & Sons, 1987.
- [149] 董增福. 矩阵分析教程. 哈尔滨:哈尔滨工业大学出版社, 2003.
- [150] 赵瑞安, 吴方. 非线性最优化的理论与方法. 杭州:浙江科学技术出版社, 1992.
- [151] 陈宝林. 最优化理论与算法:第二版. 北京:清华大学出版社, 2005.

致 谢

博士生学习、科研和撰写论文期间，始终得到导师李克强教授的悉心指导与帮助。导师一丝不苟的治学态度、深厚扎实的理论功底、为人谦和的处事风范、诲人不倦的高尚师德使我受益终身。在此，致以崇高的敬意和由衷的感谢。

博士期间，一直得到了王建强教授的热心指导与无私关怀，向他表示诚挚的谢意。同时，感谢实验室连小珉教授、罗禹贡老师、杨殿阁老师和郑四发老师的帮助和支持。另外，诚挚地感谢美国 University of Minnesota 的 Prof. Rajamani、美国 Stanford University 的 Prof. Gerdes 的帮助与支持。

最后，感谢所有帮助我、照料我、爱护我的亲戚、同事和朋友们，是你们的爱支持了我，鼓励我不断成长。

本课题承蒙国家自然科学基金、国家 863 项目和日本 ISUZU 公司资助，特此致谢。



声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：_____日 期：_____

个人简历、在学期间发表的学术论文及研究成果

个人简历

1982 年 2 月 19 日出生于山东日照市。

2000 年 9 月考入北京科技大学机械学院，机械工程专业，2004 年 7 月本科毕业，并获得工学学士学位。

2004 年 9 月免试进入清华大学汽车工程系，机械工程专业，直接攻读博士学位至今，师从李克强教授。

发表的学术论文

- [1] Shengbo Li, Keqiang Li, Jianqiang Wang. Development and Experimental Verification of Vehicular Multi-Objective Coordinated Adaptive Cruise Control System. AVEC 2010, UK. (已录用)
- [2] 李升波, 王建强, 李克强. 软约束线性模型预测控制系统的一类稳定性方法. 清华大学学报(自然科学版). (已录用, EI 源刊)
- [3] Shengbo Li, Keqiang Li, Rajesh Rajamani, Jianqiang Wang. Model Predictive Multi-Objective Vehicular Adaptive Cruise Control. IEEE TCST (Be accepted as Full paper, SCI Factor: 2.7)
- [4] 李升波, 王建强, 李克强, 张磊. MPC 实用化问题处理及其在车辆 ACC 中的应用. 清华大学学报(自然科学版). (已录用, EI 源刊)a
- [5] Shengbo Li, Keqiang Li, Jianqiang Wang, Hiroshi Ukawa, Dongsheng Bai. Modeling of heavy-duty truck driver's car-following characteristics and its comparative verification. International Journal of Automotive Technology, vol. 11, no. 1., pp. 81-87. (SCI Factor: 0.6, EI 检索号: 20101412825291)
- [6] Shengbo Li, Keqiang Li, Rajesh Rajamani, Jianqiang Wang. Model Predictive Multi-Objective Vehicular Adaptive Cruise Control. The 48th IEEE Conference on Decision and Control, Shanghai, December 16-18, 2009. (EI 检索号: 20101612850031)
- [7] 李升波, 李克强, 王建强, 杨波. 非奇异快速 TSM 控制方法及其跟车控制应用. 控制理论与应用. Vol. 27 No. 5, 2010, pp. 1-8. (EI 源刊)
- [8] 李升波, 王建强, 李克强. 基于 xPC 的驾驶员辅助系统硬件在环仿真试验台. 中国机械工程, 2007, 18(16): 2012-2015.(EI 检索号: 073910835364)

- [9] 李升波, 王建强, 李志强. 硬件在环仿真试验台监控系统的设计与开发. 系统仿真学报, 2007, 19(16): 3684- 3687. (EI 检索号: 073710811166)
- [10] 李升波, 李志强, 王建强, 高峰. 非奇异快速的终端滑模控制方法. 信息与控制, 2009, 38(1): 1-8.
- [11] Shengbo Li, Keqiang Li, Jianqiang Wang, Lei Zhang, Xiaomin Lian, Hiroshi Ukawa, Dongsheng Bai. MPC based Vehicular Following Control Considering both Fuel Economy and Tracking Capability. Proceedings of 2008 IEEE Vehicle Power and Propulsion Conference, Harbin, China, 2008. (EI 检索号: 090111823872)
- [12] Shengbo Li, Jianqiang Wang, Keqiang Li, Dezhao Zhang. Study on Robustness and Feasibility of MPC based Vehicular MO-ACC algorithm. Proc. of 2009 IEEE Intelligent Vehicles Symposium, Xi'an, 2009: 1297-1301. (EI 检索号: 10763070)
- [13] Shengbo Li, Jianqiang Wang, Keqiang Li, Dezhao Zhang. Non-singular fast TSM control method and its application to vehicular following control. The 15th World Congress on Intelligent Transport Systems, New York, USA, 2008.
- [14] LI Shengbo, BIN Yang, LI Keqiang, Hiroshi Ukawa, Dongsheng Bai, Masatoshi Handa. A Control Strategy of ACC System Considering Fuel Consumption. Proceedings of The 8th International Symposium on Advanced Vehicle Control, Taipei, China, 2006: 851-855.
- [15] WANG Jianqiang, LI Shengbo, HUANG Xiaoyu, LI Keqiang. A Driving Simulation Platform Applied to Develop Driver Assistance Systems. VPPC 2009.(EI 检索号: 10928946)
- [16] 张磊, 李升波, 王建强, 李志强. 基于神经网络方法的集成式驾驶员跟车模型. 清华大学学报, 2008, 48(11): 1809-1812. (EI 检索号: 20085111797565)
- [17] Dezhao Zhang, Jianqiang Wang, Shengbo Li, Lei Zhang, Keqiang Li. Double-Mode Vehicular Electronic Throttle for Driver Assistance Systems. Proc. of 2009 IEEE Intelligent Vehicles Symposium, Xi'an, 2009: 1312-1317. (EI 检索号: 20094712492585)
- [18] Li-jun Wu, Jian-qiang Wang, Sheng-bo Li. A Hardware-in-the-Loop Simulator for Vehicle Adaptive Cruise Control Systems by Using xPC Target. Asia Pacific Automotive Engineering Conference, Hollywood, CA, USA, 2007.
- [19] 宾洋, 李志强, 李升波, 王建强. 重型车辆走-停巡航系统的干扰解耦控制. 机械工程学报, 2006, 42(9): 207-213.(EI 检索号: 064710258062)

参与的科研项目

- [1] 国家自然科学基金项目“基于广义多目标控制理论的汽车底盘系统集成控制”，项目编号：60604013，时间：2007年-2009年
- [2] 日本五十铃公司合作项目“Advanced Adaptive Cruise Control System”，项目编号：20083000359，时间：2008年至2009年
- [3] 日本五十铃公司合作项目“Development of Adaptive Cruise Control System with Stop&Go Capability”，项目编号：20063000307，时间：2006年至2008年
- [4] 国家863项目“交通要素自适应式车辆纵向安全驾驶辅助系统”，项目编号：2007AA11Z232，时间：2008年至2009年
- [5] 日本日产公司合作项目“ITS Evaluation and Driver Characteristics”，项目编号：20083000349，时间：2008年
- [6] 国家十五科技攻关课题“汽车安全辅助装置开发”，项目编号：2002BA404A21，时间：2002年至2005年

申请的专利

- [1] 李克强，李升波，王建强，Hiroshi Ukawa, Dongsheng Bai. 一种车辆多目标协调式自适应巡航控制方法. 中国发明专利，申请号：200810224248.0.
- [2] 李克强，李升波，王建强. 车辆多目标协调式自适应巡航控制性能的数学量化方法. 中国发明专利，申请号：200810225585.1.
- [3] 李克强，李升波，王建强，刘佳熙，张德兆. 一种快速模型预测控制方法. 中国发明专利，申请号：200810227346.X.
- [4] 王建强，李克强，李升波，张德兆. 货车偏载动态检测方法及其报警系统. 中国发明专利，申请号：200810119656.X.
- [5] 李克强，王建强，李升波，吴利军，等. 基于快速控制原型的开发型汽车驾驶模拟方法. 中国发明专利，申请号：200810117172.1.
- [6] 王建强，李克强，李升波，张德兆. 货车偏载动态检测报警系统. 中国实用新型，申请号：200820122442.3.

- [7] 王建强, 李克强, 杨波, 李升波, 贾立山, 等. 一种气压电控辅助制动装置. 中国专利. 200910080657.2.
- [8] 王建强, 李克强, 张德兆, 李升波, 连小珉. 货车质心高度自动检测方法. 中国发明专利, 申请号: 200810119683.7.
- [9] 王建强, 李克强, 张德兆, 李升波, 连小珉, 等. 货车弯道防侧翻动态检测方法 & 预警装置. 中国发明专利, 申请号: 200810119658.9.
- [10] 王建强, 李克强, 张德兆, 李升波, 连小珉, 等. 货车弯道防侧翻动态检测预警装置. 中国实用新型, 申请号: 200820122443.8.
- [11] 王建强, 李克强, 张磊, 张德兆, 杨波, 李升波. 一种振动式汽车追尾报警装置. 中国发明专利, 申请号: 200810006472.2.
- [12] 王建强, 李克强, 张德兆, 连小珉, 杨波, 张磊, 李升波, 刘志峰. 一种汽车制动效能监测及报警系统. 中国发明专利, 申请号: 200810117851.9.